单位代码：10293　密　级：

南京邮电大学

专业学位硕士论文

论文题目：基于 TI-LDA 和融合多源数据的广告推荐系统设计与实现

学　　号	1220096720
姓　　名	马小宁
导　　师	曹亚东
专业学位类别	工程管理硕士
类　　型	全日制
专业（领域）	物流工程与管理
论文提交日期	2023.06

中国知网　https://www.cnki.net

Design and implementation of advertising recommendation system based on TI-LDA and multi-source data

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of Master of Engineering Management

By

Ma Xiaoning

Supervisor: Prof. Cao Yadong

June 2023

中国知网 https://www.cnki.net

摘要

互联网的迅速发展带动了电子商务的蓬勃发展，促进了广告的新一轮竞争。在移动互联网的高速发展下，信息流广告由于其效益转化优势，迎来了爆发式的增长，成为各主流电商及社交媒体平台如抖音、小红书等的流量变现的主要广告模式。在当今互联网发展下，广告受大数据技术的推动，通过数据挖掘和知识关联发现技术的优化。不仅具备传播范围广、传播效率高的特点，更呈现出精准推荐人群和高效营销的新特征。广告的推荐可以提升品牌的曝光，一定程度上影响商品的销量。因此如何将广告推荐精准给能够实现高效转化的人群成为当前电子商务中的热门问题。

本文对广告推荐系统进行研究。首先，基于改进 LDA 模型，基于改进后的模型实现文本数据用户行为兴趣特征的提取，并以此在兴趣行为特征上进行用户分类，实现用户在兴趣行为上的精准描述。其次构造用户特征向量，融合用户的基本特征和兴趣行为特征来生成用户画像，并进行相似度计算，从而实现了用户多维度的特征描述，有效改善推荐中的冷启动和数据稀疏性问题。最后计算用户和广告目标人群之间的相似度，从而实现广告推荐。

在本文的实证研究中，将某电子商务平台的用户作为研究对象，使用本文提出的方法对用户特征进行提取，融合用户多维度特征进行相似度计算，从而进行广告推荐。实验表明，本文提出的方法能够有效改善推荐中的稀疏性和冷启动问题，提高用户平台使用满意度，实现广告的精准营销。

关键词：特征提取，LDA，用户画像，推荐系统

中国知网 https://www.cnki.net

Abstract

The rapid development of the Internet has led to the vigorous development of e-commerce and promoted a new round of competition in advertising. Under the rapid development of the mobile Internet, information flow advertising has ushered in explosive growth due to its efficiency conversion advantages, and has become the main advertising mode for traffic monetization on mainstream e-commerce and social media platforms such as Douyin and Xiaohongshu. Under the development of today's Internet, advertising is driven by big data technology and optimized through data mining and knowledge association discovery technology. It not only has the characteristics of wide dissemination and high communication efficiency, but also presents new characteristics of accurate recommendation of people and efficient marketing. The recommendation of advertising can increase the exposure of the brand and affect the sales of the product to a certain extent. Therefore, how to accurately recommend ads to people who can achieve efficient conversion has become a hot issue in e-commerce.

This article examines ad recommendation systems. Firstly, based on the improved LDA model, the extracted interest features of user behavior in text data are realized based on the improved model, and the user classification is carried out on the interest behavior features to achieve accurate description of user interest behavior. Secondly, the user feature vector is constructed, the basic characteristics and interest behavior characteristics of users are integrated to generate user portraits, and the similarity is calculated, so as to realize the multi-dimensional feature description of users, and effectively improve the cold start and data sparsity problems in recommendation. Finally, the similarity between users and the target group of the ad is calculated to achieve ad recommendations.

In the empirical research of this paper, the users of an e-commerce platform are taken as the research object, and the user features are extracted using the method proposed in this paper, and the similarity calculation is calculated by integrating the multi-dimensional characteristics of users, so as to make advertising recommendations. Experiments show that the method proposed in this paper can effectively improve the sparsity and cold start problems in recommendation, improve user platform satisfaction, and realize precision marketing of advertising.

keyword ： Feature extraction， LDA， User portrait， Referral system

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....1
1.2 课题来源和研究内容.....2
1.3 章节安排.....2
第二章 相关理论与技术研究.....4
2.1 基础知识.....4
2.2 推荐系统.....5
2.2.1 基于内容的推荐.....6
2.2.2 协同过滤推荐.....7
2.2.3 混合推荐.....8
2.2.4 基于知识的推荐.....8
2.3 推荐系统中的特征提取方法.....9
2.3.1 LFM.....10
2.3.2 p LSA.....11
2.3.3 LSI.....11
2.3.4 LDA.....12
2.4 推荐系统中的特征融合方法.....14
2.5 本章小结.....14
第三章 广告推荐系统的总体设计.....16
3.1 需求设计.....16
3.1.1 设计目标.....16
3.1.2 功能性需求分析.....17
3.1.3 非功能性需求分析.....18
3.2 总体框架构建.....18
3.3 系统功能设计.....20
3.3.1 功能模块设计.....20
3.4 数据库设计.....21
3.5 本章小结.....23
第四章 基于 TI-LDA 的文本特征提取及分类.....24
4.1 问题分析.....24
4.2 基于改进 LDA 的文本特征提取和分类方案.....25
4.2.1 系统算法流程.....25

中国知网 https://www.cnki.net

4.2.2 特征提取和分类.....25
4.3 仿真实例.....28
4.3.1 数据集.....28
4.3.2 仿真实例.....29
4.4 实验结果与分析.....30
4.4.1 评价指标.....30
4.4.2 实验结果.....30
4.5 本章小结.....32
第五章 融合多源数据的广告推荐方法.....33
5.1 问题分析.....33
5.2 融合多源数据的广告推荐系统.....34
5.2.1 算法设计.....34
5.3 仿真与实验.....37
5.3.1 仿真实例.....37
5.4 本章小结.....40
第六章 系统实现与测试.....41
6.1 环境搭建.....41
6.1.1 硬件环境.....41
6.1.2 软件环境.....42
6.2 系统实现.....42
6.2.1 数据存储与管理子模块.....42
6.2.2 特征提取子模块.....43
6.2.3 用户画像与特征融合子模块.....44
6.2.4 推荐召回子模块.....44
6.2.5 排序过滤子模块.....46
6.3 功能测试.....47
6.3.1 前台个人用户端.....47
6.3.2 后台管理员端.....49
6.4 本章小结.....51
第七章 总结与展望.....52
7.1 总结.....52
7.2 展望.....53
参考文献.....54

中国知网 https://www.cnki.net

专用术语注释表

缩略词说明：

LDA	Latent Dirichlet Allocation	隐式狄利克雷分布
pLSA	Probabilistic Latent Semantic Analysis	概率潜在语义分析
LFM	Latent Factor Model	隐语义模型
LSI	Latent Semantic Index	潜语义标号
CPM	cost per mille	千次展示计费
CB	Content-Base	基于内容
CF	Collaborative Filterin	协同过滤
KB	Knowledge-based	基于知识
CPA	cost per action	转化计费
CPC	cost per click	点击计费
NLP	natural language processin	自然语言处理
GRU	Gated Recurrent Units	门控循环单元
BS- LDA	Biterm Sentiment Latent Dirichlet Allocation	无监督可信度判断方法
L-LDA	Linear Discriminant Analysis Algorithm	线性判别分析算法

中国知网 https://www.cnki.net

第一章 绪论

推荐系统是一类重要的人工智能技术，尤其应用在当前的大数据商业性背景中。推荐系统为用户推荐对其有用的信息和物品，利用物品和用户之间的关联关系，通过不同的形式，最终得到精准的个性化推荐结果，推荐系统前景无限，被广泛应用在教育、购物、娱乐、金融等不同领域中。

1.1 研究背景及意义

1.1.1 研究背景

互联网的高速发展和大数据技术的迭代更新，驱动了商业和营销模式的变革。使得互联网公司获得更高价值的服务。推荐系统作为信息搜索和过滤工具，旨在支持用户找到他们可能喜欢、感兴趣或认为有用的项目。随着大数据时代的到来，互联网上的信息呈指数级增长。人们从过去的信息稀缺时代进入了信息爆炸时代。然而，这些海量信息中的大部分是毫无价值的。信息爆炸使得人们越来越难从网上获取有价值的信息。为了提高生产生活的效率，人们需要一些信息过滤技术来过滤掉无用的信息。推荐系统是为用户有用的项目提供建议的软件工具和技术。个性化推荐系统作为一种有效的信息过滤工具，可以帮助用户在需求不明确的情况下高效地获取满足自己需求的信息。

随着电子商务和互联网技术的不断进步，信息流广告成为企业传播品牌知名度和寻找目标客户实现收益转换的中流砥柱。

1.1.2 研究意义

互联网上的信息海量冗杂，一方面，信息生产者很难将自己的信息高效精准推送给合适的用户；另一方面，信息使用者很难从海量数据中快速准确地获取需求信息。本文研究推荐系统，缓解信息过载问题，将信息生产者和使用者链接起来，一来提高用户信息检索效率；二来提高平台广告效益。

平台方是信息的载体，用户和商家在平台上的交互行为产生数据生成流量。对于平台方而言，推荐系统最大化物品点击率，最大化用户转化率，从而提高平台的成交概率。能够实现产品对用户的个性化展示，帮助用户找到喜欢和适合的东西，增加用户粘性，提高用户满

中国知网 https://www.cnki.net

意度与忠诚度。平台上内容和用户的匹配度，是衡量平台的重要指标，而推荐系统为平台匹配需求和供给，推荐能力决定了平台和系统的商业价值。对于用户而言，推荐系统帮助其从海量数据中快速找到感兴趣的信息，搜索式推荐满足了有明确需求的用户；对于需求不明确的用户，推荐可以带来额外的惊喜，提升用户体验度。对于信息生产者来说，推荐系统帮助其高效精准触达目标人群，带来更多的曝光，提高收益效率。

广告推荐系统是互联网大时代的趋势，通过广告的个性化穿插，让广告效果增加的同时降低了成本。

1.2 课题来源和研究内容

本文研究课题来源于导师团队与企业的合作研究项目中的一部分，该项目研究需求是完成一个线上电子商务平台。本文研究的主要内容是电子商务平台中的信息流广告推荐系统，该系统的设计目的是在用户浏览过程中向其穿插适宜的广告，一来提高用户信息检索效率；二来提高平台广告效益。

1.3 章节安排

第一章 绪论。阐述了本文研究背景和意义、项目来源和本文主要研究内容和研究路线。

第二章 相关理论与技术研究。本章内容是对相关理论和技术的研究。首先，研究目前几种主流的推荐模型，包括模型的应用领域、国内外学者的研究内容和各个模型实践中的优缺点；其次研究了基于推荐系统中，基于机器学习的几种主流的特征表示模型；最后研究了推荐系统中的特征融合方式。

第三章 系统总体设计。首先分析信息流广告推荐系统的设计需求和目标，其次分别设计总体架构和各个功能模块。最后构建数据库的关系模型图，进行系统的数据库设计，并完成系统的实体关系图。

第四章 基于 TI-LDA 的文本特征提取及分类。本章改进了 LDA 模型，引入 TF-IDF 计算用户数据的重要性，进行了用户特征提取，并通过 K-means 聚类算法对主题相似的用户进行人群分组。为了证明所提出系统的性能，采集了小红书电商平台的用户数据进行实验。实验结果表明，该系统能够根据用户的互动数据实现用户特征特征提取对用户进行分类。尤其改进 LDA 模型提取主题构建关键词字典时，我们的分类系统具有更好的聚类性能和更高的分类性能。

第五章 融合多源数据的广告推荐方法。本章将结合结构性数据构建来用户画像模型和广

中国知网 https://www.cnki.net

告的特征向量，深度挖掘用户与项目之间的关联，从而提出一种融合多源异构数据的信息流广告推荐算法。本章对最后进行了实例，并在在数据集上进行实验，实验结果表明该方法优于传统方法。本章针对上述问题提出一种融合用户兴趣行为特征和基本人口属性特征的信息流广告推荐模型，在广度上剔除冗余特征，同时深度挖掘候选集与用户间的关联，以缓解冷启动问题。

第六章 系统实现与测试。首先介绍系统搭建的软硬件环境，其次对系统的主要功能进行了详细的步骤展示，最后实现了系统仿真，从用户和管理员两个角度进行了功能测试。

第七章 总结与展望。总结本文研究内容的主要贡献和不足，并为后续研究提供方向和思路。

中国知网 https://www.cnki.net

第二章 相关理论与技术研究

本章内容是对本文涉及到的理论和技术及其国内外学者的相关研究。一是主要研究目前几种主流的推荐模型，包括模型的应用领域、国内外学者的研究内容和各个模型在实践中的优缺点；二是研究了推荐系统中，基于机器学习的几种主流的特征表示模型；最后研究了推荐系统中的特征融合方式。

2.1 基础知识

信息流广告由 Facebook 首先推出，是存在于在互联网社交媒体平台上的用户动态、各视听或资讯媒体内容中的在线广告。信息流广告形式丰富，主要包括视频、图文、链接等。这是一种穿插在内容中的广告，减弱了传统形式广告在推荐产品时的生硬，可以潜移默化地向用户推荐产品，用户在接受过程中体验较好。信息流广告不仅可以获得大量的流量曝光，更重要的优势在于，可以利用算法推荐，通过定向的手段，精准满足广告主的不同需求来实现产品和品牌的曝光，提高广告主的效益。影响信息流广告投放的决定性因素是创意设计、定向推荐和竞价。在移动互联网的高速发展下，信息流广告由于其效益转化优势，迎来了爆发式的增长，成为各主流电商及社交媒体平台如抖音、小红书等的流量变现的主要广告模式[1]。

通过广告推荐平台，可以制定不同的广告推荐目标[2]。平台根据广告主设置的不同优化目标，如根据图片文案类或视频类，设置商品购买、软件下载、品牌曝光、活动推广、直播视频引流等。平台根据用户自定义的计划完成进行定向投放，如选择广告投放人群的年龄、投放地区、投放时段、投放的用户移动端、KOL 投放渠道、投放人群类目关键词标签，过程中通过 CPA、CPM、CPC 等的出价方式进行广告收费。信息流广告的常见的主要计费模式为 CPC（cost per click，点击计费），按点击扣费，每当有用户执行点击广告链接行为，则广告系统产生扣费。CPA（cost per action，转化计费），按转化产生扣费，当用户做出根据广告主不同需求指定的动作，如购买行为、下载行为或填写行为后，广告系统产生扣费，这类广告获得有效回应的转化高，但单次获客成本非常高。CPM（cost per mille，千次展示计费），按实际展示付费，媒体只需向用户展示广告，系统即按千次展示产生扣费，这种广告计费方式成为目前兴趣电商的主流，是因为在这种模式下一方面平台的推广风险较低，另一方面企业广告主或者个体用户能用低成本获得高曝光。

中国知网 https://www.cnki.net

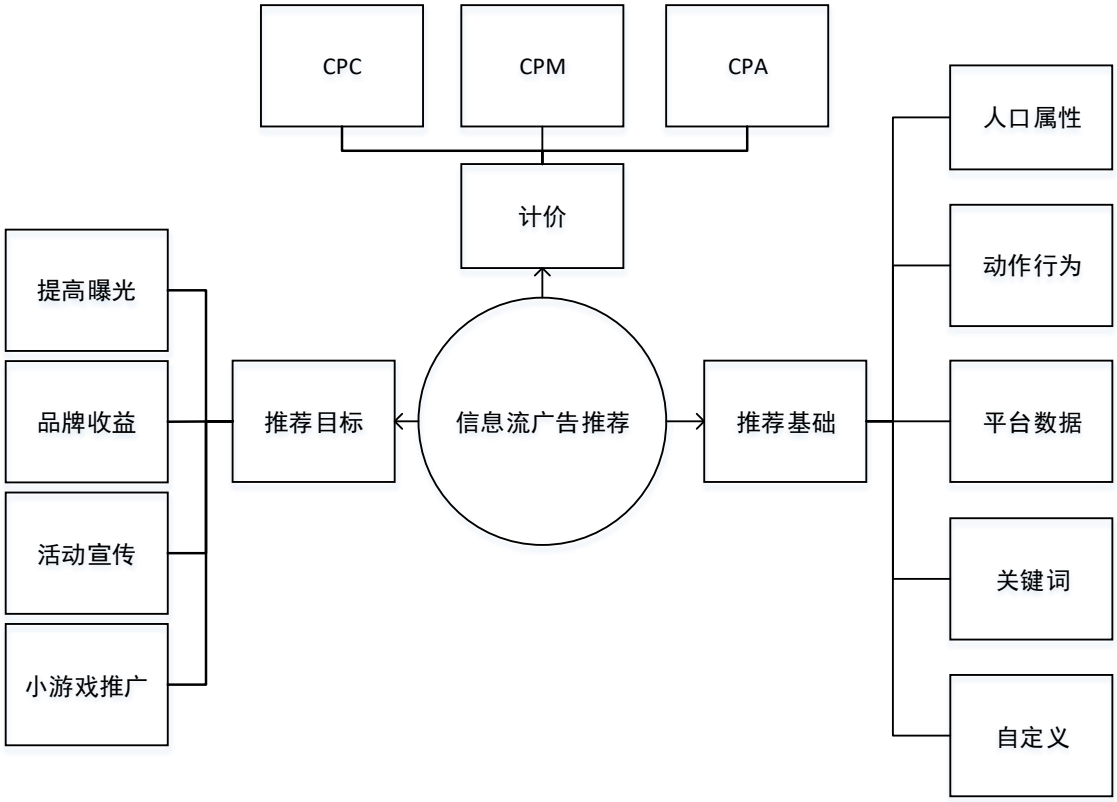

图 2. 1 信息流广告推荐

2.2 推荐系统

互联网的普及为人们的生活带来了巨大的机会。与此同时，网络上海量和丰富的信息决定了我们找到真正需要的东西的难度迅速增加。推荐系统有效解决此类问题，系统通过分析相关的信息，主动推荐满足用户需求的数据。如今推荐系统被应用于不同的应用领域，如图书情报领域[3]、音乐推荐[4]、论文推荐[5]、电子商务购物平台领域[6]和电影推荐[7]等方面。

目前国内外应用于推荐系统的算法多种多样，主要的推荐算法有：基于内容的推荐算法[8]、协同过滤推荐算法[9]、多种混合推荐算法[10]和基于知识的推荐系统算法[11]。

中国知网 https://www.cnki.net

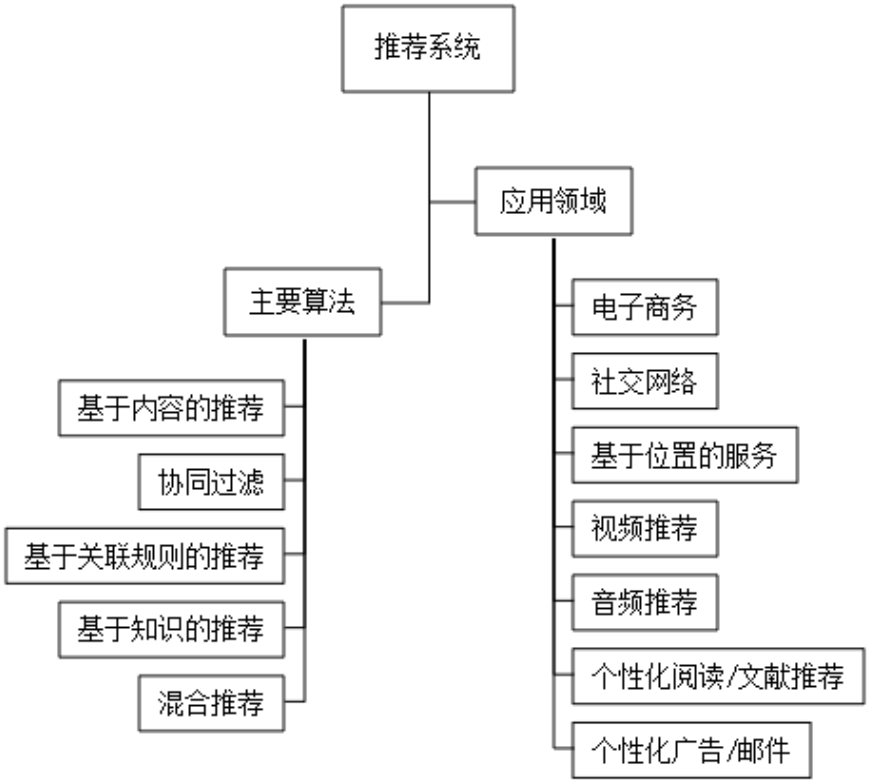

图 2. 2 推荐系统的主要算法和应用

2.2.1 基于内容的推荐

在目前相当多的推荐算法中，基于内容的算法是最基本的方法[12]。基于内容的推荐可以被看作是一个机器学习分类任务，在这个过程中，推荐系统根据候选集与目标用户历史喜欢的项目的相似性来识别潜在感兴趣的项目。基于内容的推荐系统使用通常是非结构化的文本内容的所有或特定属性，这些内容描述了用户评估的项目的特征，以便了解用户的配置文件，可以通过各种方式来发现适合用户偏好的有趣项目。

基于内容的推荐在候选集的特征和用户对这些特征的兴趣之间进行匹配。例如将已经消费的商品的内容与可能推荐给用户的新商品进行比较，找到与用户已经给出积极评价的商品相似的商品。基于内容的推荐系统关注项目的属性，项目的相似性通过测量其属性的相似性来确定。由于基于内容的推荐倾向于使用由文本表示的项目，内容通常由使用简单检索模型的关键词表示，最具代表性的例子是向量空间模型。

文献[13]提出了一种基于内容的评级奇异值分解推荐方法，利用奇异值分解属性来计算评级预测。通过详细描述用户和物品配置文件，以获得与利用奇异值分解的方法获得的数据相关的矩阵。提高了推荐精度和改善了数据稀疏性问题。

中国知网 https://www.cnki.net

文献[14]提出了一种基于内容特征的推荐系统算法和潜在项列表排序相似度方法，根据这些属性的分布利用高斯混合模型将所有项目聚类到不同的组中，然后使用高斯滤波函数作为计算相似度的方法对推荐项目结果进行排序，并提高了在基于内容的分发推荐系统的准确性和时间效率。

文献[15]处理了多个用户建模问题，提出一种基于否定的动态的基于兴趣的推荐系统，它建模了多个用户依赖和项目依赖的时间动态以及用户偏好中的否定，以提高语义和时间属性级配置文件的一致性，从而实现更准确和个性化的推荐。

根据国内外已有的研究内容，基于内容的推荐算法一方面基于内容的推荐算法有许多优势，原理上简单有效，用户透明度高，由于其在任何推荐系统的初始阶段冷启动问题效率高而被广泛应用。但是另一方面，还存在分析内容有限、过于专业化和缺乏用户评价数据等不足问题。

2.2.2 协同过滤推荐

协同过滤推荐算法基于历史交互模式的数据对用户的偏好进行建模，是当前推荐系统中最流行的方法之一[16]。目前研究内容主要有矩阵分解[17]和词嵌入方式[18]。

矩阵分解原理简单，易于实现，主要思想是将交互矩阵分解为更小的矩阵，将原有的高维稀疏特征转换为低维潜在向量，将用户和物品的潜在向量相乘，得到用户对物品的评分值，这是原本缺失的。将计算得到的预测值赋给数据。传统矩阵分解主要是在显示反馈数据上进行，利用分解后的用户矩阵与项目矩阵的乘积，得到用户对未交互项目的预测评分值。然而在实际应用中隐式反馈效果更好，一是电子商务通过根据用户购买商品属性进行推荐而不是基于其评级，忽略用户与商品之间的非线性关系会降低推荐的准确性。二是隐式反馈数据比显式反馈数据更方便获取，数据样本更丰富。

近年来，词嵌入模型越来越流行，深度学习可以有效地获取数据内部的深层关系，并具有自动组合的能力，在自然语言处理、人脸识别等领域取得了巨大的成功。词嵌入模型的特征表示方法在文本图像上处理上具有较好的效果，但只考虑了项目之间的局部关联，而忽略了用户本身与项目之间的联系。用户和项目的融合训练有助于模型学习全局参数，更好的特征向量表示可以有效提高模型在推荐任务中的效果。最大优点是它不依赖于任何要推荐的候选项目的系统表示，并且可以很好地运行复杂项目，如音乐电影等。

由于大量的隐性反馈，如浏览和点击，国内外学者正在设计基于隐性反馈的推荐系统。虽然隐式反馈在构建推荐系统中具有很高的适用性，但隐式反馈更具有挑战性。传统的协同

中国知网 https://www.cnki.net

过滤技术，如矩阵分解，将用户偏好视为用户和物品潜在特征的线性组合，其学习能力有限，因此存在冷启动和数据稀疏问题。为了解决这些问题，研究方向是考虑将传统的协同过滤与深度神经网络相结合来映射用户和物品的特征。

文献[19]提出了一种专门用于二元数据表示的变分自编码器模型，其中测量数据被分解为基于项目和用户对象两类。然后，通过改变推理模型中参数调整的目标函数来优化体系结构，并将用户和项目属性作为隐式交互值，提高了召回精度。

文献[20]提出了一种基于多模型深度学习的协同过滤方法，通过整合用户和项目函数构建混合推荐系统。将深度自编码器与一维卷积神经网络模型相结合，该模型学习用户和项目特征来预测用户的兴趣偏好。

文献[21]引入了一种支持深度学习的自动编码器架构，。所提出的深度学习模型被设计为具有三个关键网络的混合架构，即自编码器(AE)、多层感知器(MLP)和广义矩阵分解(GMF)。通过烧蚀实验验证了所提模型的有效性，改善了额定值数据稀疏性问题和冷启动问题。

2.2.3 混合推荐

协作过滤推荐和基于内容的推荐方法各有优缺点，为了克服每种方法种可能存在缺点，通过组合的方式将两种方法统一到一个模型中来实现更高的性能。例如，当将基于内容的过滤与协同推荐相结合时，基于内容的推荐有助于推荐未评级的项目。

目前国内外研究中混合推荐的方式有两种，一是存在于一个推荐系统中[22]，即系统组合使用 CF（Collaborative Filterin，协同过滤）和 CB（Content—Base，基于内容的推荐）方法。如通过 CB 技术构建用户特征向量文件，然后直接比较这些数据以评估用户的相似性，从而提供推荐建议。二是使用两个独立的系统[23]，即 CF 推荐器和 CB 推荐器。可以将两个系统的推荐组合到一个公共推荐合集中，设定适当的规则进行优先展示排序。混合推荐方法更符合实际应用，比常规推荐方法精度更高，然而也更复杂，需要经过大量的示例与训练，在实现这种解决方案较为困难。

2.2.4 基于知识的推荐

基于知识的推荐系统，该系统明确地表示了对候选集的需求。知识库用于编码与项目和用户有关的信息，以及项目和用户特征之间的关系。例如，关系可以指用户兴趣和项目之间以及项目本身之间的约束。基于知识的推荐非常强调领域模型的作用，从规则（将要推荐的项目映射到用户特征和偏好）到覆盖模型（将用户的属性与要推荐的项目相关联），本体（描

中国知网 https://www.cnki.net

述领域并可能与覆盖模型相关联），依赖（因果关系）网络等[24]。

KB（Knowledge-based，基于知识的过滤）方法被认为是其他方法的补充。这个 KB 推荐器根据领域知识提供推荐，这些知识包括哪些项目的特性将与用户的兴趣相匹配。知识可以表示为详细的用户模型、选择过程模型或将被建议的项目的描述。KBF 推荐系统需要更详细的推荐知识规范（以属性、约束和/或相似度度量表示）和相应的项目（必须指定语义属性）。

KB 方法最重要的优点是推荐只依赖于领域知识和用户偏好的约束，而不依赖于(完全)用户的费率，从而避免了前面提到的自举系统的困难。然而，提取所需的知识和构建所需的模型（知识表示）通常是复杂且容易出错的过程，这被视为这种方法的一个限制。

CF 和 CB 的主要区别在于，在 KB 推荐系统中，用户交互式地指定单个感兴趣的示例，并且检索该示例的最近邻居作为用户可能感兴趣的项。KB 推荐系统很容易解释。此外，在相似函数的设计中使用了大量的领域知识，因为只有单个示例可用。这个示例可以更恰当地视为用户需求，而不是历史评级，因为它是以交互方式指定的。在 KB 系统中，不太强调使用历史评级。

与其他推荐算法相比，一方面基于知识的推荐系统需要获取更高的知识，然而另一方面，它不需要处理关于项目或其他用户的历史数据，如评级评分行为等。

文献[25]提出了一个基于知识的推荐框架，该框架利用了一个经过专家验证的明确数据集，为健康受试者和有健康问题受试者的用户组提供高度准确的饮食计划。建立了一个新颖的架构包括一个定性层，用于验证成分的定性层和用于合成计划的定量层。实验结果显示，在大多数用户类别中推荐精度和召回率得到了提高。

文献[26]提出了一种新的在移动设备上使用的旅行推荐方法，以生成包含多个兴趣点的个性化旅行计划。将通过生成已访问兴趣点的热图来预测推荐的个性化旅行地点列表，并将选择高度相关的兴趣点作为目的地进行推荐。利用时间特征来增加用户访问量，基于用户选择的兴趣点向用户推荐个性化的旅行计划，并使用实时大规模数据集对所提出的旅行 RS 进行实验评估。提高了推荐结果的多样性和丰富性。

文献[27]利用 NLP（natural language processin，自然语言处理）技术实现了一个基于知识的推荐系统。提出了三种提高关键词抽取性能的策略。利用传统的自然语言处理技术结合特定语言和领域的有效地提高医疗知识推荐系统性能。

2.3 推荐系统中的特征提取方法

主题模型是特征提取的主要模型，在数据挖掘和自然语言处理的计算机科学领域中具有

中国知网 https://www.cnki.net

重要作用[28]。主题模型是对文本集合进行聚类的统计分析模型，以非监督学习的方式对文本集合的隐含语义结构进行分析。目前在自然语言处理领域有着广泛的应用，主要用于对文本表示进行特征提取和降维处理，文本语义分析和文本聚类等。主题建模是文本挖掘中最强大的技术之一，用于数据挖掘、潜在数据发现以及查找数据和文本文档之间的关系。用于文本数据挖掘的主题模型主要有 pLSA（概率潜在语义分析，Probabilistic Latent Semantic Analysis）[29]、LFM（隐语义模型，Latent Factor Model）[30]、LSI（潜语义标号，Latent Semantic Index）[31]、LDA（潜在狄利克雷分布，Latent Dirichlet Allocation）[32]，本节将总结目前主要的特征提取主题模型及国内外学者的研究内容。

在主题建模中，主题是以统计显著方法出现的单词列表。文本可以是电子邮件、书籍章节或电商评论等任何类型的非结构化文本。主题模型无法理解用于主题建模的文本文档中单词的含义和概念[33]。相反，主题模型假设文本的任何部分都是通过从可能的单词集合中选择单词来组合的，其中每个集合对应一个主题。该工具一次又一次地完成这个过程，直到它停留在最有可能将单词分配到称为主题的集合中。主题建模可以从整个集合、单个文档以及文档之间的关系方面为大型集合提供有用的视图[34]。

2.3.1 LFM

LFM（Latent Factor Model，隐语义模型）通过潜在因素联系用户的偏好和项目。潜在因素可以理解为用户喜欢某个项目的潜在原因。矩阵分解技术建立了用户与潜在因素之间以及潜在因素与项目之间的关系。可以通过用户潜在因素矩阵和项目潜在因素矩阵的内部乘积运算来预测每个用户对项目的偏好。它将用户和项目之间的评级矩阵设置为 $R_{m\times n}$，其中 m 是用户数量，n 是项目数量，R_{ij} 是用户 i 对项目 j 的评级。通过 LFM 建模，评级矩阵 $R_{m\times n}$ 可以分解为两个具有潜在因素的低维矩阵。通过将两个潜在因素模型相乘，可以计算每个项目的预测评级。

文献[35]提出了一种基于模糊聚类和 LFM 模型的课程教师推荐模型（FCTR-LFM）来为课程推荐合适的教师。首先，在教育学理论和方法的指导下对教师和课程的相关特征进行量化建模，并将量化结果与历史教学分数相结合，以建立大规模的稀疏课程教学评估矩阵作为推荐数据集,接下来采用改进的模糊聚类模型，根据教师的特点实现教师的自动聚类,然后使用改进的 LFM 来预测评估矩阵中的得分项。最后根据课程对预测评价得分进行排序，实现课程教师的 TOP-N 推荐。

文献[36]提出了一种基于改进的潜在因素模型 LFM 和改进的 PersonalRank 算法的教师推

中国知网 https://www.cnki.net

荐算法（PRLFM）。最后通过实验表明，PRLFM 算法可以有效提高预测和 top-N 推荐的准确性。它解决了在为大学课程推荐合适的教师和提高教学质量方面缺乏科学依据的问题。

2.3.2 pLSA

pLSA（Probabilistic Latent Semantic Analysis，概率潜在语义分析）是一个统计聚类模型，它通过潜在的主题变量将文档和单词关联起来，将每个文档表示为主题的混合。它被证明在许多文档分析任务中具有优于传统共聚类模型的能力[37]。pLSA 基于文档和关键字的软分区性质的假设，前者假设每个聚类都有一个主题。除了每个主题由多个关键字表征之外，每个文档还可以由多个主题组成，而每个关键字与每个文档中的单个主题相关联[38]。

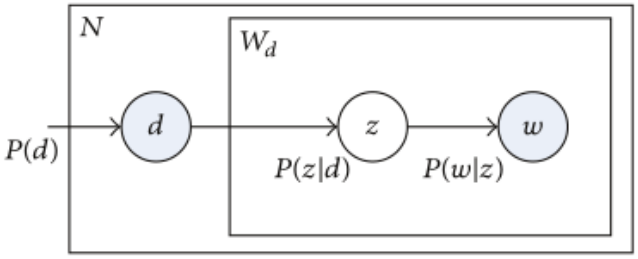

图 2. 3pLSA 基本思想

文献[39]采用大数据分析和语义模型分析，通过 PLSA 模型方法计算，构建语义分析模型，从而揭示无线传感器网络环境下在线汉语语义行为表达的基本规律和发展趋势。通过抽取百度贴吧、知网上 1103 篇文献的 105 万字数据集，并用该数据集验证 PLSA 模型。通过构建无线传感器网络，得到汉语行为表达中的语义分析结果。其次利用 PLSA 模型对数据集进行语义分析后，提高了数据集的准确性。

文献[40]提出了一种自学习 pLSA 模型，旨在充分利用高级异常信息来解决拥挤场景下的异常行为检测。选择信息性观察来构建训练集中的“参考事件”作为高级指导线索。具体而言，训练集被随机分成两个独立的子集。一个用于学习该模型，该模型定义为“参考事件”的初始化顺序。另一个目的是更新此模型，并将不常见的样本选择为“参考事件”。最后使用与“参考事件”最不相似的事件定义异常。实验结果表明，该模型可以在现实世界的人群环境中准确，稳健地检测异常行为。

2.3.3 LSI

LSI（Latent Semantic Index，潜语义标号）可以测量单词出现的上下文的相似性，并创建

中国知网 https://www.cnki.net

降维特征空间表示。LSI 算法的使用具有双重优势：它允许我们进行语义查询，同时也尊重文档中术语的相关性[41]。但是，当用户的查询与文档中的术语字面上匹配时，LSI 会给出不恰当的结果，因为不同的单词可能具有相似的含义（同义词），而单词可能具有多种含义。LSI 通过数学推导的抽象索引而不是使用单个单词进行检索，通过词汇匹配克服信息检索的这些缺点[42]。

文献[43]基于 LSI 设计了一套主题建模技术，通过分析社交媒体数据，帮助决策者和环境社区了解公众对塑料污染相关问题的看法。考虑到话题连贯性、话题流行性和话题相关性，将其应用于数据以识别在线对话的热门话题。实验结果表明，这些主题建模技术中的一些在检测和识别塑料污染的重要主题方面是有效的，并且可以结合潜在的不同技术来开发一个高效的系统，用于大规模地从社交媒体数据中挖掘与环境相关的重要主题。

文献[44]使用文本挖掘技术来准确地找到社交媒体上的广告受众。通过根据推荐分数对目标帖子进行排序来分析 Facebook 帖子，包括六个阶段，如数据预处理、中文分词、词细化、TF-IDF 词向量转换、通过潜在语义索引创建模型以及计算推荐分数。基于推荐结果，验证了与传统推荐方法相比可以提高精准率。

文献[45]基于 LSI 提出了一种端到端模型 SSi-LSi，它融合了句法结构信息和词汇语义信息，以解决现有端到端方法不能充分利用文本信息的局限性。该模型通过集成了词性、义素和上下文。然后在注意机制的基础上进一步实现了句法结构信息和词汇语义信息的融合，从而充分利用了文本信息。随后的实验表明，SSi-LSi 模型在使用不同的文本信息方面具有一定的优势。

2.3.4 LDA

LDA （Latent Dirichlet Allocation，隐式狄利克雷分布）是语料库的生成概率模型。基本思想是将文档表示为潜在主题上的随机混合，其中主题的特征是在单词上的分布[46]。LDA 以单词概率表示主题。每个主题中概率最高的单词通常可以很好地了解主题是什么。LDA 是大型语料库中潜在主题分布的一种杰出工具[47]。因此，它能够识别由许多专利组成的技术领域的子主题，并在一系列主题分布中表示每个专利。使用 LDA（文档集合中的术语）生成词汇表，然后应用该词汇表来发现隐藏的主题。文档被视为主题的混合体，其中主题是这组术语的概率分布。然后将每个文档视为一组主题的概率分布。我们可以认为数据来自一个生成过程，该过程由观察到的和隐藏的联合概率分布定义。

中国知网 https://www.cnki.net

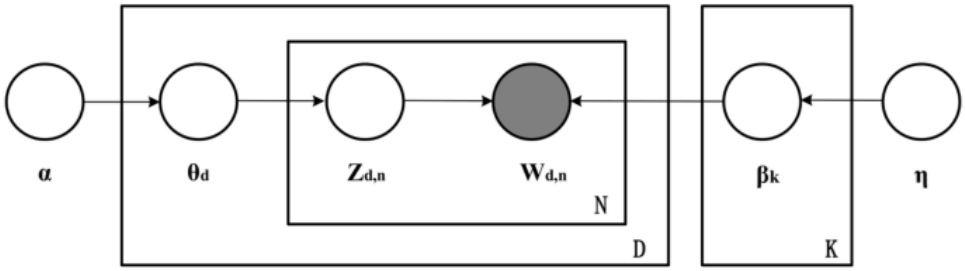

图 2. 4LDA 基本思想

LDA 是一种用于语料库建模的无监督生成概率方法，是最常用的主题建模方法[48]。LDA 假设每个文档都可以表示为潜在主题的概率分布，并且所有文档中的主题分布共享一个公共的 Dirichlet 先验。LDA 模型中的每个潜在主题也表示为单词上的概率分布，主题的单词分布也共享一个共同的 Dirichlet 先验。给定由 M 个文档组成的语料库 D，文档 D 具有 N_d 个单词（D∈1，…，M），LDA 根据以下生成过程对 D 进行建模：

从参数为 β 的 Dirichlet 分布中为主题 t（t∈｛1，…，t｝）选择一个多项式分布。从参数为 α 的 Dirichet 分布中为文档 d（d∈{1，…，M}）选一个多项式分配 θ_d。对于文档 d 中的单词 w_n（n∈{1，…，n d}），从 θ_d 中选择主题 Z_n。

在上述生成过程中，文档中的单词仅是观察变量，而其他单词是潜在变量。为了推断潜在变量和超参数，观测数据 D 的概率被计算并最大化如下：

$$p(D|\alpha,\beta) = \prod_{d=1}^{M} \int p(\theta_d|\alpha)(\prod_{n=1}^{N_d} \sum_{Z_{dn}} p(Z_{dn}|\theta_d)p(w_{dn}|Z_{dn},\beta))d\theta_d \tag{2.1}$$

其中 Dirichlet 的超参数 α 和 β 定义了主题上的单词分布，Z 是数字主题数量，M 为文档数量；N 是词汇数量。变量 θ_d 是文档级变量，对每个文档采样。z_{dn}、w_{dn} 变量是单词级变量，对每个文本文档中的每个单词时进行采样。

文献[49]使用 LDA 方法提取个人在社交网络平台上对事件看法的数据集的主题，来分析公众对气候变化的意见，同时通过双向编码器将数据进行支持、中立和反对的情绪态度分类，构建了主题建模和分类模型，从多个方面验证其方法的优势。

文献[50]针对短文本分类内容稀疏和特征不明显的局限性，提出一种融合 Lda 和双时长短时记忆的短视频分类模型 LDA-Bi LSTM，来对热点视频评论数据进行分类研究，从而了解消费者关注点，提高视频营销效果。

文献[51]收集了往年新闻简报中的科学语料库，采用 LDA、相关性分析等对科学主题和社会环境特征进行了分析，结果表明 LDA 在科学议题主题提取方面有很好的应用效果。

中国知网 https://www.cnki.net

2.4 推荐系统中的特征融合方法

在推荐系统中，为了更好地利用不同特性的优点，可以通过联合建模的形式对特征进行融合。本质上，特征融合是指不同性质的特征进行互补以提高模型性能。目前国内外研究中，主要的特征融合方法，从技术上分类主要有特征求和[52]、注意力机制[53]、特征拼接[54]、反卷积[55]、图神经网络[56]等；从融合时间上分类主要有前融合[57]、中间层融合[58]、后融合[59]。

文献[60]将显式输入特征与嵌入向量连接起来，有效地挖掘选定土地和养分之间潜在的线性和非线性相互作用，以确定与营养价值对应的推荐历史施肥量的重要性。最后，将宽矩阵分解和全链路网络——多层感知机两种不同的预测结果结合在一个融合层中进行最终的肥料预测。

文献[61]同时考虑与用户和项目相关的上下文信息，提出了两种类型的 GRU（Gated Recurrent Units, 门控循环单元）模型,即多特征线性融合 GRU 和多特征用户融合 GRU,以解决上述缺陷,从而帮助用户推荐更个性化的下一个项目。提出的模型采用多特征融合技术,包括特征级联和一维卷积神经网络来生成 GRU 的输入,以学习更多的特征交互信息。通过实验证明了所提模型性能增益，进一步消融实验验证了不同特征对于两种模型的影响。

文献[62]考虑了音乐音频的多个声源，提出融合和弦、旋律和节奏特征以有意义地表征音乐,从而改进音乐推荐。特别地使用两个基于用户的注意力机制来区分音频特征和和弦特征的不同部分的重要性。此外,使用长短期记忆层来捕获序列特征。最后通过多层感知器进行特征融合,分析结果提出建议。

2.5 本章小结

本章内容是对相关理论和技术的研究。第一，研究目前几种主流的推荐模型，包括模型的应用领域、国内外学者的研究内容和各个模型实践中的优缺点；第二，研究了基于推荐系统中，基于机器学习的几种主流的特征表示模型；最后研究了推荐系统中的特征融合方式

通过对国内外学者的研究分析发现，现有推荐过程中有以下问题：

（1）数据稀疏性问题和冷启动问题，在推荐过程中，推荐系统以用户和项目之间的交互矩阵大量数据为基础。在现实中，用户不太可能与所有项目进行交互，而是与一小部分进行交互。这将导致交互矩阵包含空值，引用从未交互过的用户和项目，存在大部分值为空的数据。

（2）特征间的互补性和差异性问题，不同特征对推荐的重要性；如何利用不同属性的特

中国知网 https://www.cnki.net

征间的共性和差异性进行特征融合和互补；不同特征融合到一起可能会产生负影响。

综上所述，本文基于目前广告推荐过程中存在的问题展开研究。本文将在第四章详述通过改进概率主题模型 LDA 进行文本的特征提取，在第五章通过特征融合的方法构建基于内容和协同过滤的混合推荐模型。

中国知网 https://www.cnki.net

第三章 广告推荐系统的总体设计

在第二章充分研究了用于特征提取的主题概率模型和推荐模型相关的有关理论和技术，并调研了相关内容的国内外学者的研究方向的基础上。本章将构建出本研究信息流广告推荐系统的总体架构图，分别设计总体架构和各个功能模块。最后构建数据库的关系模型图，进行系统的数据库设计，并完成系统的实体关系图。

3.1 需求设计

本节详细阐述了信息流广告推荐系统的设计目标和功能需求点，列举了系统实现用例并细化各功能模块，描述了最终实现效果。

3.1.1 设计目标

本研究中开发了信息流广告推荐系统。通过分析平台数据提取图文广告主题特征和用户兴趣行为特征，融合用户的平台底层信息和兴趣行为信息构建用户群体画像，从而计算广告和用户的相似度，基于此构建一个信息流广告推荐系统，实现千人千面，提高用户使用平台满意度和广告推荐效益。如下图 3.1 所示是整体系统的 uml 用例图。

中国知网 https://www.cnki.net

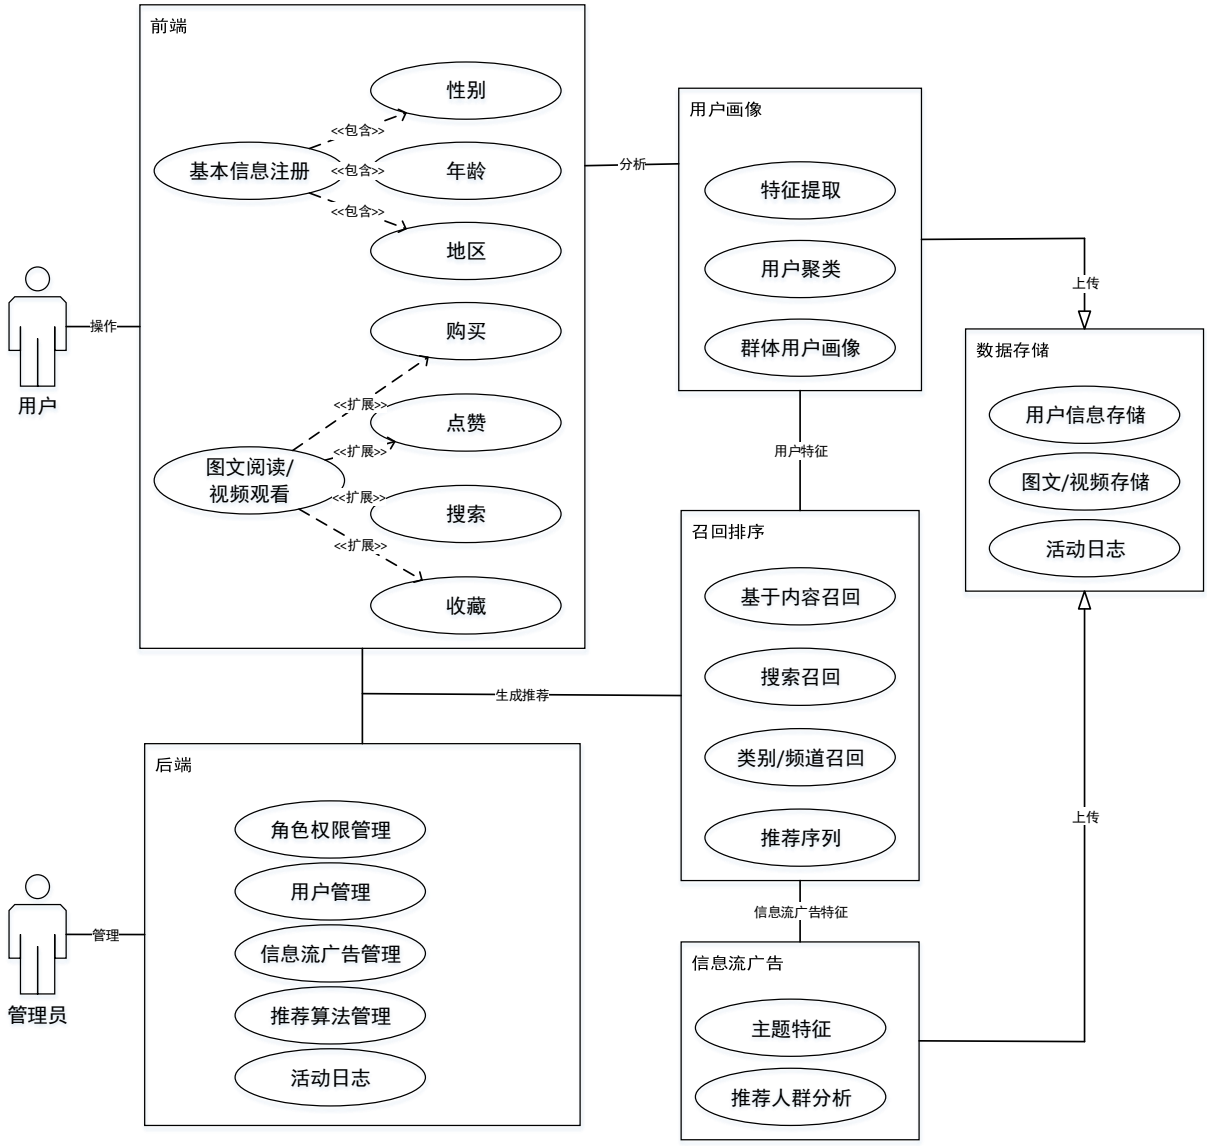

图 3. 1uml 用例图

3.1.2 功能性需求分析

本系统有五个主要功能，包括数据存储与管理功能、文本特征提取和分类功能、用户画像功能、候选集召回功能和找回排序功能。

（1）数据存储与管理功能

一是聚合平台上的图文信息，需要对文章数据结构统一化处理后存储到数据库中；二是存储用户基本数据和在平台上交互留下的历史行为信息，需要不断实时更新来为推荐功能提供数据基础。

（2）文本特征提取功能

针对文本信息的特点，对用户历史行为数据和平台信息数据进行文本特征提取和分类，对文本进行便签化处理，为推荐召回阶段奠定基础，以此匹配用户和广告数据。

中国知网 https://www.cnki.net

（3）用户画像功能

结合平台底层数据和用户历史交互数据，提取用户的特征信息，以此实现精准个性化推荐，聚类相似用户群体，为用户匹配合适的内容，提高召回效率。

（4）候选集召回功能

推荐系统的核心功能之一，在不同的召回阶段设定召回策略，对于不同的召回策略，其数据匹配方法和评估衡量标准不同，各有优劣。需结合和权衡多个召回策略，以实现推荐结果的精准和多样化。

（5）召回排序功能

为了对多种召回策略进行更统一地评估，需要进一步地过滤去重。多种召回策略下获取的候选集数量可能过多，需要评估候选集并进行排序，生成最终推荐列表。

3.1.3 非功能性需求分析

本系统的非功能性需求包括系统易用性、可靠性、可维护性、可扩展性和安全性等方面。

（1）系统的易用性

要求 UI 界面美观、交互式设计符合用户行为模式，界面简洁明了、交互简单直接、功能便捷高效，以用户为中心，

（2）系统的可靠性

要求系统能够不间断地连续运转，减少宕机时间，要求系统能够进行快速部署，意外发生时能够快速切换到备用。

（3）系统的可维护性

可以支持开发人员和用户方便升级。

（4）系统的可扩展性

随着用户量和存储数据量的增长，系统可以支持扩容。

（5）系统的安全性

首要保障数据库安全性，用户数据传输和存储过程中的隐私保护，避免数据泄露。

3.2 总体框架构建

基于上一小节推荐系统的需求分析，本小节将构建推荐系统的总体架构。本系统架构自底向上依次包括数据存储层、特征提取融合与用户画像层、推荐召回层、排序与过滤层、显示层。如下图展示了本系统的总体框架。

中国知网 https://www.cnki.net

图 3.2 系统总体框架图

（1）数据存储层

用于存储平台上的用户信息和图文数据等相关数据，负责数据的统一化整合便于读取和计算。

（2）特征提取和用户画像层

用于图文主题特征和用户兴趣行为特征的提取，用户特征融合和用户画像构建以及相似度匹配，为推荐做准备。基于图文主题特征那和用户兴趣行为特征的提取具体方案将在第四章详述；用户特征融合、用户画像构建以及相似度匹配将在第五章详述。

（3）推荐召回层

布置推荐召回策略，本文主要有基于内容相似度的推荐、基于用户间相似度的协同过滤推荐和搜索召回。

（4）排序过滤层

获取推荐候选集并进行排序和去重过滤。

（5）显示层

结果可视化，展示平台对用户的个性化推荐内容，做到千人千面。

中国知网 https://www.cnki.net

3.3 系统功能设计

基于上述对系统的需求分析，本节对推荐系统进行 uml 面向对象建模具体设计，如下图所示是推荐系统的流程时序图。

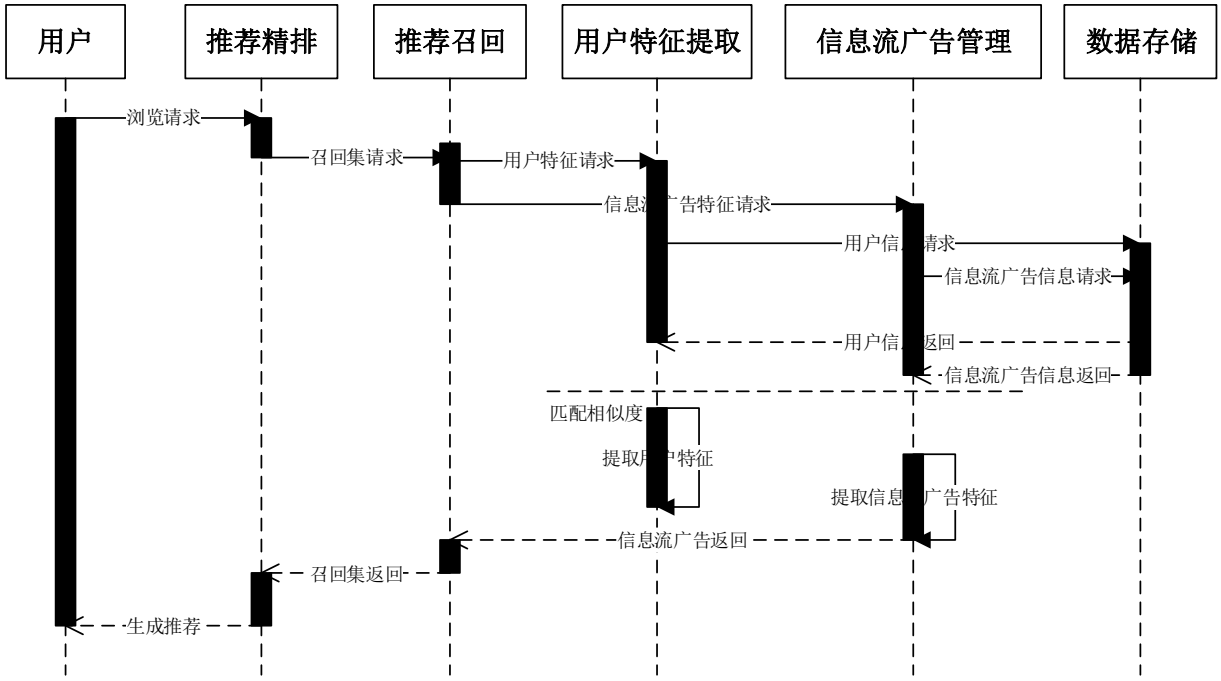

图 3. 3 系统时序图

3.3.1 功能模块设计

本节将推荐系统解耦为以下各子模块并设计其功能。数据存储模块、特征提取模块、用户特征融合和用户画像模块、推荐召回模块和排序过滤模块。数据存储模块包括用户平台底层信息和行为数据、平台图文数据和信息流广告数据的存储和整合。特征提取模块包括广告文本特征提取、用户兴趣行为特征提取及其分类。特征融合和用户画像模块包括用户基本数据和行为数据的特征融合。推荐召回模块主要是基于内容的推荐、基于用户的协同过滤和搜索推荐。排列过滤模块主要是评分排序和去重过滤。如下图是推荐系统组件图。

中国知网 https://www.cnki.net

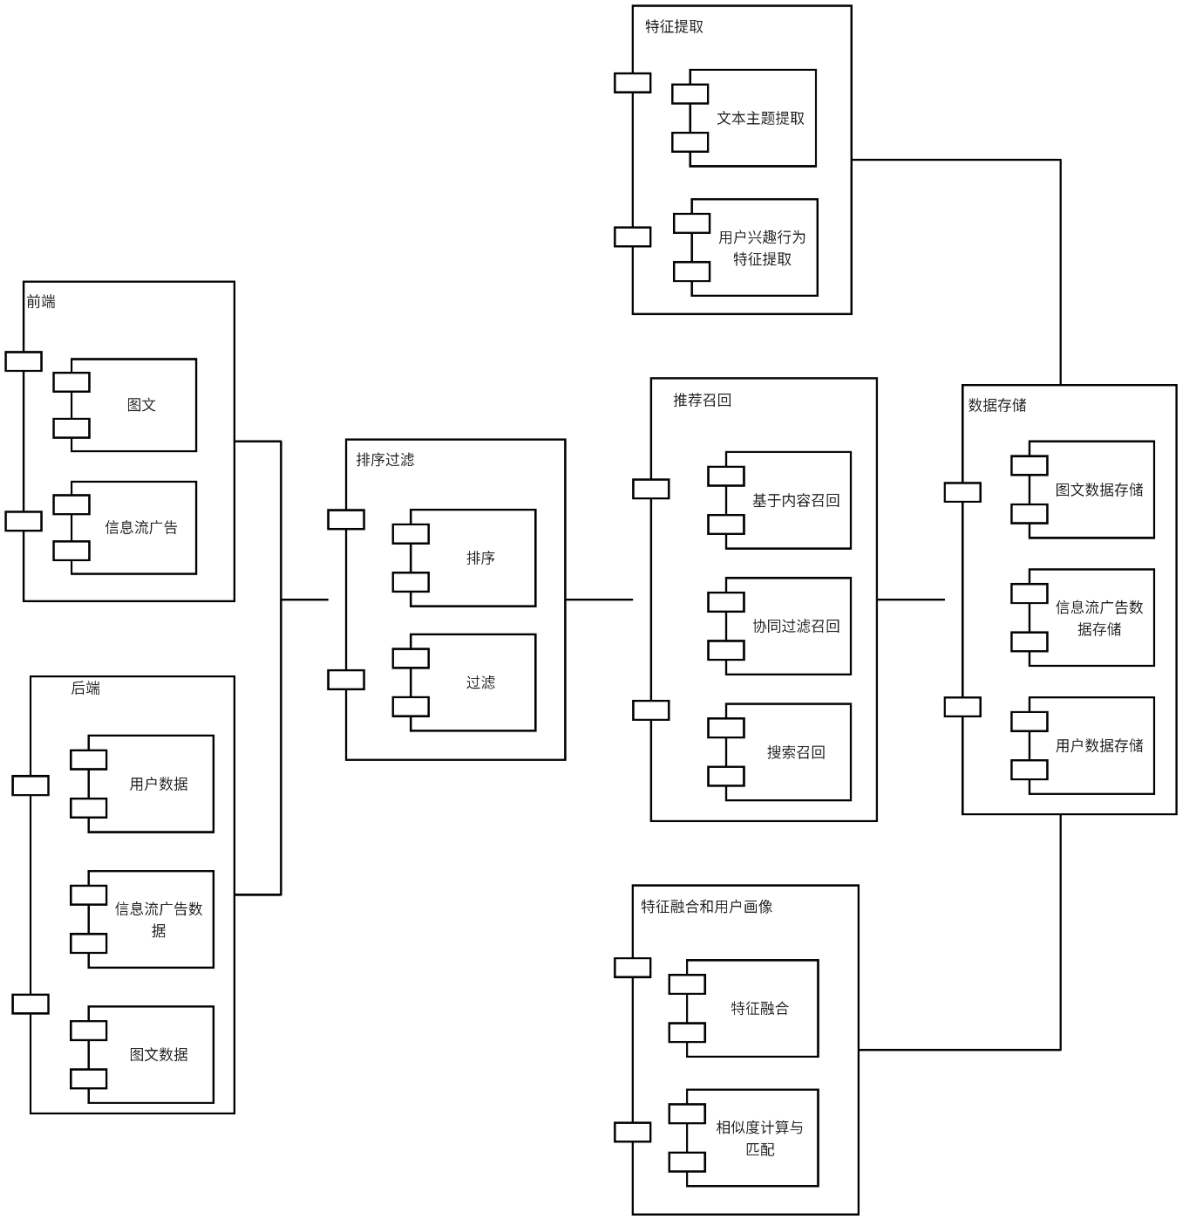

图 3. 4 系统组件图

3.4 数据库设计

在上述需求分析和系统总体架构设计的基础上，本节详细设计了系统中的数据库表和数据库实体关系。如下图是系统的实体关系图。根据分析上述系统实体关系图可以得到本系统需要构建的实体及其实体间对应关系，并根据上述分析来设计系统的数据库。本系统的数据库表主要包括用户数据表、图文/信息流广告表、用户行为记录表。本系统面向对象程序设计，采用 uml 建模法描述数据库表的结构及其关系。如下图具体描述了数据库表的物理关系。

中国知网 https://www.cnki.net

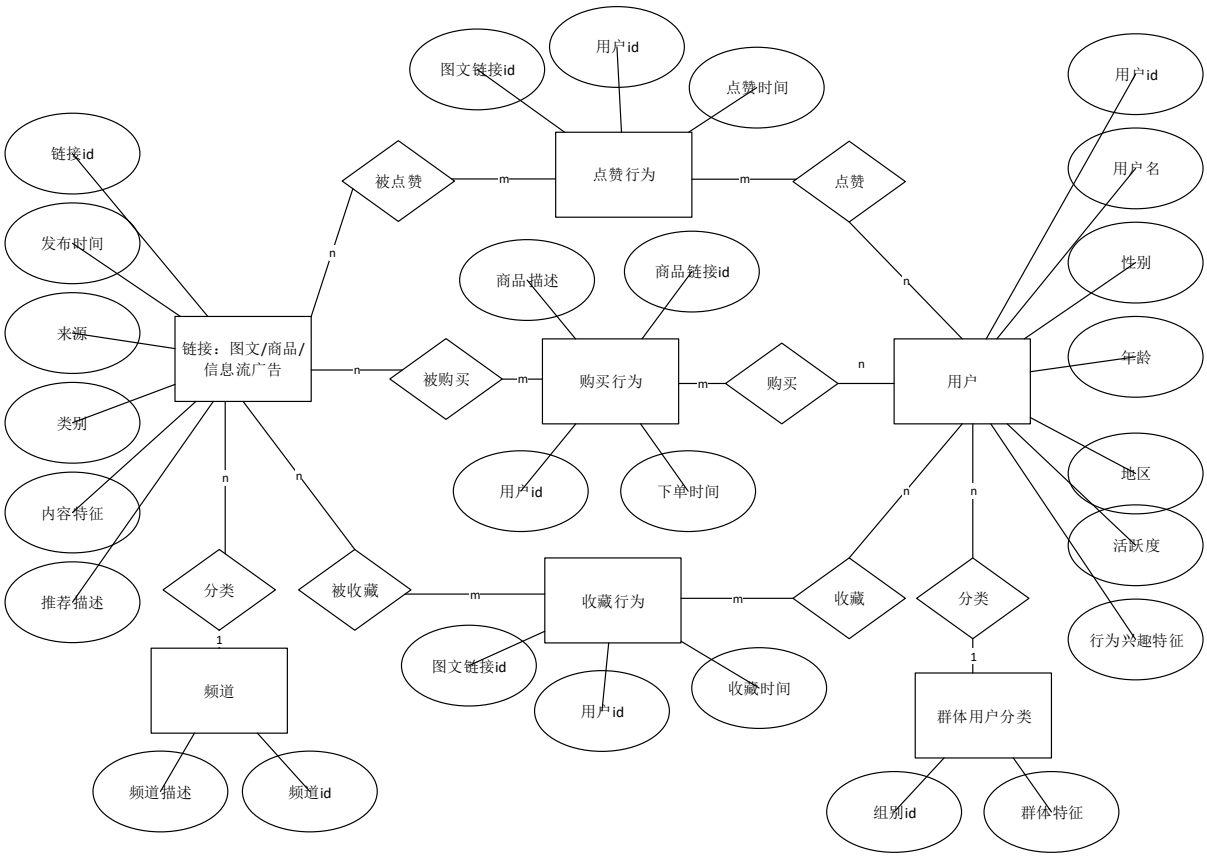

图 3.5 系统实体关系图

根据分析上述系统实体关系图可以得到本系统需要构建的实体及其实体间对应关系，并根据上述分析来设计系统的数据库。本系统的数据库表主要包括用户数据表、图文/信息流广告表、用户行为记录表。本系统面向对象程序设计，采用 uml 建模法描述数据库表的结构及其关系。如下图具体描述了数据库表的物理关系。根据分析上述系统实体关系图可以得到本系统需要构建的实体及其实体间对应关系，并根据上述分析来设计系统的数据库。本系统的数据库表主要包括用户数据表、图文/信息流广告表、用户行为记录表。本系统面向对象程序设计，采用 uml 建模法描述数据库表的结构及其关系。如下图具体描述了数据库表的物理关系。

中国知网 https://www.cnki.net

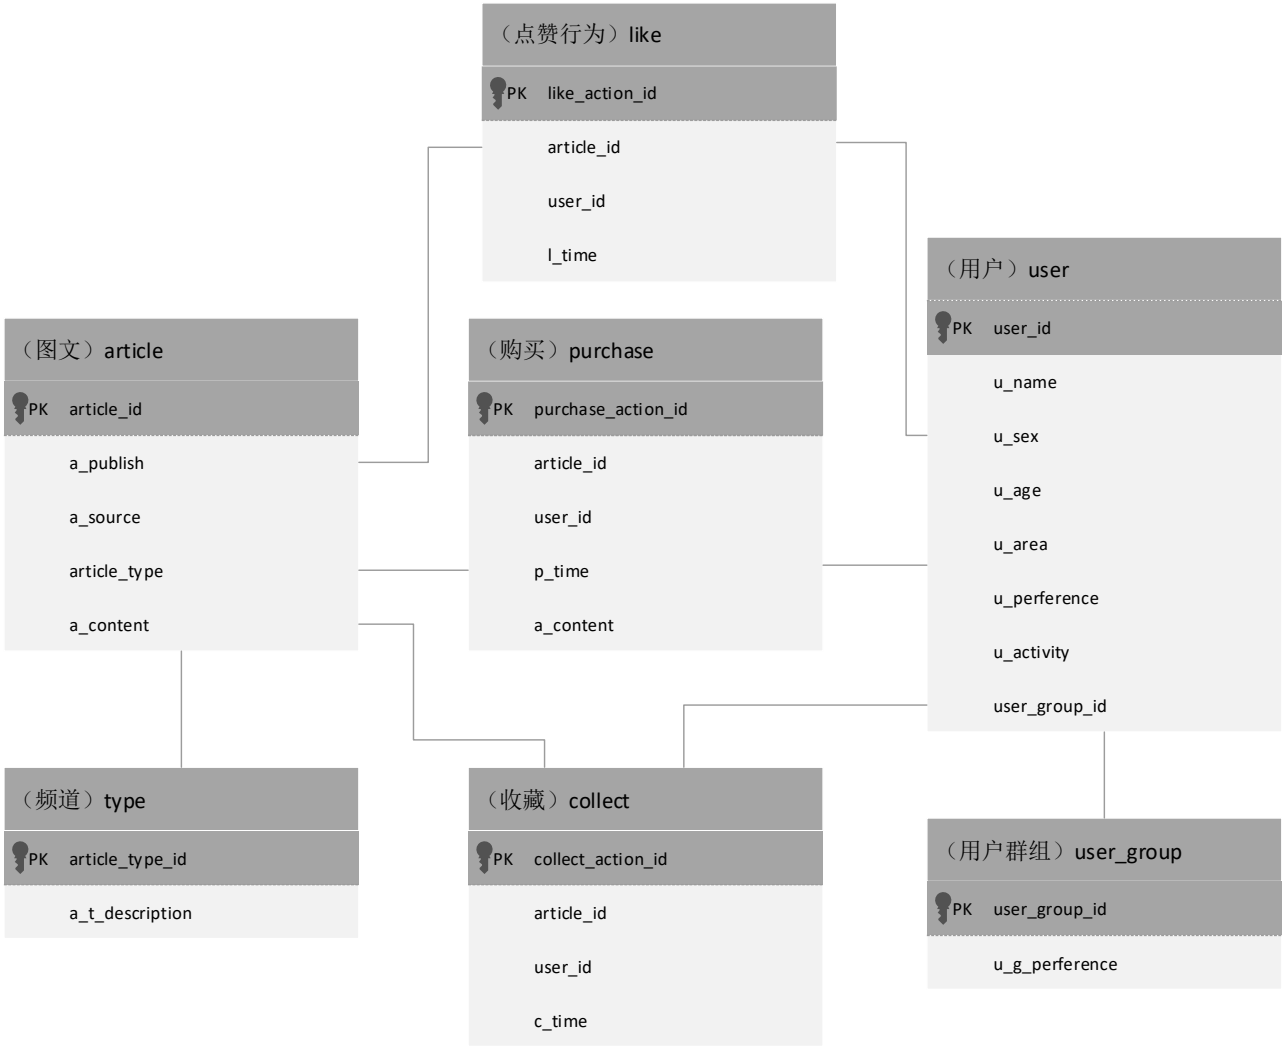

图 3. 6 数据库物理关系图

用户表存储用户的基本信息，包括昵称、性别、地区、活跃度等，通过用户 id 关联其他数据表。用户组别表存储通过分析用户数据来提取的用户组别特征，通过组别 id 关联用户表。图文表存储平台发布图文和穿插信息流广告的基本信息，包括发布时间、发布者、正文等，通过图文 id 关联其他数据表。图文类别存储文章的特征和类别，通过类别 id 关联图文表。用户行为记录表存储用户在平台上的图文操作行为，主要包括点赞行为、收藏行为等。

3.5 本章小结

本章首先编写了信息流广告推荐系统的需求分析和总体设计。其次使用 UML 建模方法进行了数据库设计和数据库表的构建。最后分别详细设计了各子模块的功能，并给出了时序图。

中国知网 https://www.cnki.net

第四章　基于 TI-LDA 的文本特征提取及分类

在上一章对融合多源数据的广告推荐系统的整体设计的基础上，本章就系统推荐模型中包含的用户兴趣特征提取方法进行研究。为了实现用户的精准识别，本文提出了一种研究用户兴趣特征分类系统，可以将平台用户聚类到极有可能具有相似主题的有意义的人群中。该方法通过隐式狄利克雷分配方案，从用户的在线互动数据，包括评论转发行为信息、浏览信息等中提取具有代表性的关键词。然后，基于用户的 TF - IDF 值，应用 K - means 聚类算法将用户划分为主题相似的人群，实现了用户兴趣的有效提取和文本分类。

4.1 问题分析

随着电子商务的蓬勃发展，信息流广告成为企业传播品牌知名度和寻找目标客户实现收益的主要方式，如何通过用户线上互动信息识别到目标客户成为电子商务领域的重要研究问问题。因此本章研究如何将平台上的海量用户与相似的主题进行分类，以便识别目标群体用户。随着海量用户在线上平台的频繁互动，对于用户的分类来说，难以有效管理数量不断增加的用户数据。由于要分析和分类的用户在各个不同维度产生的数据之间关系复杂且冗杂，因此很难快速识别用户兴趣。

当前有一些学者在这方面进行了研究。文献[63]提出了一种 lda 改进后的模型 BS- LDA（Biterm Sentiment Latent Dirichlet Allocation，无监督可信度判断方法）模型，首先推导分布并计算评论数据可信度，从而从用户评论数据中提取对商品质量判断的主题。文献[64]设计了一种改进算法 I-Lda（Linear Discriminant Analysis Algorithm，线性判别分析算法）来降低数据维度，结合逻辑回归算法学习行为，从人类活动与信息物理系统交互数据中提取人类行为特征。文献[65]针对多单词短语方面改进了 LDA 模型，在构建主题模型前进行了词性分类，主题模型构建完成后融合 TextRank 算法得到关键词组来替换 LDA 的识别结果，进一步丰富了主题语义。

在本文中，我们以研究用户的平台互动行为数据为基础，高效精准对相似用户进行分类。互动行为数据是研究用户的重要组成部分之一，它表示了用户的历史消费水平和意图，浏览兴趣和关注内容等，是表示用户转化效益和方向的非常重要的数据。

这是一个根据特定的标准或内容将用户分类的问题。为了将平台上的海量用户分类为具有相似特征的人群，本研究提出了一种基于 LDA 和 TF-IDF 方案的用户分类方法。该方法不

中国知网　https://www.cnki.net

仅实现了用户的有效分类，而且对各类别下的用户特征进行了权重衡量。该方法利用 LDA 从搜索数据中提取主题构建具有代表性的关键词集，引入 TF-IDF 基于关键词集从行为数据中抽取主题词。然后根据用户数据 TF-IDF 值，采用 K-means 聚类算法对主题相似的用户进行分类。最后为了证明所提方法的有效性和适用性，对系统的性能进行评估。

4.2 基于改进 LDA 的文本特征提取和分类方案

4.2.1 系统算法流程

本文提出的文本特征提取和分类方案具体流程如下：

步骤 1：获取一段时间内平台上用户数据。对数据进行预处理操作，进行中文分析，包括数据清洗、去停用词、词性过滤提取名词等。

步骤 2：抓取关键词构建词典。由于用户互动数据的冗杂，本文使用关键词集合中词频较高的关键词。

步骤 3：通过 LDA 主题建模从预处理后的数据集中提取主题。

步骤 4：为步骤 2 获得的关键字和步骤 3 获得的关键词计算 TF 值和 IDF 值。

步骤 5：利用改进后的模型 TI-LDA 进行文本主题特征提取。

步骤 6：通过 K-means 算法进行主题并输出人群特征。

4.2.2 特征提取和分类

（1）数据预处理

中文分词，将一段文本分割成单词或短语。词性过滤，去掉冠词、介词等对文章意义没有太大增加价值的词。去停用词，识别文本中单词的词干。去停用词，去除文本中没有意义的词。

为了简单高效地处理大量的关键词，本文将几个意义相近的关键词归类为一个具有代表性的关键词。本文从所有行为数据的关键词总数中构造出个具有代表性的关键词，并将这些代表性的关键词编成关键词词典。然而，即使是这些具有代表性的关键词，如果在没有减少计算量的情况下用于用户分类，也会造成大量的计算时间。我们在这些代表性关键字中使用最高频率前 10 的关键字集，如表所示。

中国知网 https://www.cnki.net

表 4. 1 高频关键词集

彩妆	护肤	美食教程	摄影技巧	穿搭	发型	减肥秘籍	健身	美甲	正餐
5.45%	4.50%	4.18%	4.08%	2.91%	2.55%	2.44%	2.30%	2.14%	1.86%

（2）TI-LDA

LDA 是一种概率模型，可以从文本集合中提取潜在主题。其基本思想是将文本表示为潜在主题的随机混合，其中每个主题都由单词的分布来表征。

TF-IDF 被广泛应用于信息检索和文本挖掘领域，用于评估文档集合中每个单词之间的关系。特别是，它们用于从文档中提取核心词（即关键字）、计算文档之间的相似度、决定搜索排名等。TF- idf 中的 TF 是指文档中特定单词的出现。另一方面，DF 表示特定单词在文档集合中出现的次数。它计算单词在多个文档中的出现次数，而不仅仅是在一个文档中。DF 值高的单词不重要，因为它们通常出现在所有文档中。因此，IDF 是 DF 的逆，用于衡量所有文档中单词的重要性。TF-IDF 倾向于过滤掉常见的词语，保留重要的词语。

对整个数据集 N_m：Poisson（δ）；

对单个文本 θ_m：Dirichlet（α）；

对主题 z，Φ_k：Dirichlet（β）；

第 m 篇文本中词 w 的生成：依据文本 θ 生成 m 词项 w 主题：$Z_{m,n}$：Multinomial（θ_m）；

根据Φ生成：$w_{m,n}$：Multinomial（Φ_k）。

对语料集中的文本，重复执行以上过程。

根据所使用的模型，变量可以得出联合分布：

$$P(w_m, z_m, v_m, \varphi|\alpha\gamma\beta) = \prod_{n=1}^{N} p\left(w_{m,n}\middle|\varphi z_{m,n}\right) p(z_{m,n}|v_m)\gamma p(v_m|\alpha)\gamma p(\varphi|\beta) \tag{4.1}$$

由此求得主题类别分布：

$$p(w_m|\alpha\gamma\beta) = \iint p(v_m|\alpha)\gamma p(\varphi|\beta)\gamma \prod_{n=1}^{N} \sum_{z_{m,n}} \prod_{n=1}^{N} p\left(w_{m,n}\middle|\varphi z_{m,n}\right) p(z_{m,n}|v_m) d\varphi\beta v_m \tag{4.2}$$

单个词 w 在整个语料集中的分布为：

$$p(w|\alpha\gamma\beta) = \prod_{m=1}^{M} P(w_m|\alpha\gamma\beta) \tag{4.3}$$

其中，固定值 M，表示数据集中的文本总数；m 表示单个文本；N 表示文本中的词语总数；z 表示主题，w 表示文本的词向量；θ 表示主题分布，α 为 θ 的狄利克雷分布的超参数；Φ表示词分布，β 为Φ的狄利克雷分布的超参数。

$$TF_{ij} = {n_{i,j}}\Big/{\sum_k n_{k,j}} \tag{4.4}$$

中国知网 https://www.cnki.net

$$iDF_i = \log {|D|}/{|\{j: t_j \in d_j\}|} \tag{4.5}$$

TF-IDF 值表示决定用户特征的关键字的重要性。某一特定文件内的高词语频率，以及该词语在整个文件集合中的低文件频率，可以产生出高权重的 TF-IDF，表达为：

$$\mathrm{TF-iDF} = \mathrm{TF} * \mathrm{IDF} \tag{4.6}$$

其中|D|是数据集中的文件总数，|{j:t_j∈d_j}|是词 ti 所出现的文件数目。TF 是指文档中特定单词的出现次数，iDF 是 DF 的逆，DF 表示特定单词在文档集合中出现的次数。具有高 TF 值的单词在文档中具有重要性。IDF 值越高，说明所有文档中出现的单词越少，重要性越高。

（3）K-means 聚类

本文通过 TF-IDF 值对文本数据进行分类，根据关键词的重要性找到一组主题相似的用户，使用了目前最常用的聚类算法之一 K-means 聚类算法对相似主题的用户进行分组。

本研究选择 K-means 聚类算法的优点主要是可以处理不同类型的属性；发现任意形状的星团；确定输入参数对领域知识的最低要求；处理噪声和异常值；尽量减少数据之间的不相似性。

本文使用的 K-means 聚类算法，基于用户的 TF-IDF 值与每个聚类的中心值之间的欧氏距离，计算代表特定主题的一组用户的聚类中心，并将用户分配到相似度高的聚类中。K-means 是将一组数据划分为相似数据的类。到目前为止，它已经应用于许多领域的各种应用，如市场营销、生物学、模式识别、web 挖掘、社交网络分析等。在各种聚类技术中，我们选择了无监督学习算法中的 k-means 聚类算法，因为它的有效性，更具体地说，该算法通过最小化数据项和相应的聚类质心之间的距离来实现是将 N 个项目的数据集根据特征划分为 k 个不相交的子集。k-means 聚类算法可以描述如下:

$$E = \sum_{i=1}^{k} \sum_{j \in C_i} ||x_j - c_i||^2 \tag{4.7}$$

式中，k 为簇的个数，x_j 为第 i 个簇 C_i 中的第 j 个数据点。$(||x_j - c_i||)^2$ 表示 x_j 和 c_i 之间的距离，通常用欧几里德距离作为距离度量。

本章提出的算法伪代码如下图所示。

中国知网 https://www.cnki.net

```
Require:words clusters information Wc
Require:all Web services description documents D
for each topic t ∈[1,T].draw a distribution over words φ~ Dirichlet(β)
for each document d ∈ do
    draw a vector of topic proportions for this document θ|α~Dirichlet(a)
    for each word W,in document d do
    conditional on θ choose a topic Z,|θ~Mult(θ)
        conditional on Z, choose a word W1|Z~Mult(Z)
        locate the words cluster C,.where W1 E C1
        for each word Wj(j≠i)in Ci,draw δ i,j~ψ (Zi,j, λ),
        where Zi,j is the topic probability of word Wj at topic Zi
    end for
    centers = X[:K]
    num_iter = 0
    while num_iter < max_iter:
        num_iter += 1
        center_2_x_dict = default_dict(list)
        for i = 0 to m-1:
            current_x = X[i]
            center_idx = calc_dist_and_fetch_min_dist_center(current_x, centers)
            center_2_x_dict[center_idx].append(i)
                for i = 0 to K-1:
            tmp_x = X[center_2_x_dict[i]]
            centers[i] = np.mean(tmp_x)
    return centers
end for
```

图 4. 1 基于改进 LDA 的文本特征提取分类算法伪代码

4.3 仿真实例

4.3.1 数据集

实验数据集来自线上采集的某电商平台用户在平台上一段时间内产生的行为数据，以

中国知网 https://www.cnki.net

27543 名用户行为数据作为用户兴趣特征提取和文本分类的核心，已做脱敏处理。

4.3.2 仿真实例

基于本文设计的 TI-LDA 方案，从爬取步骤中抓取的抽象数据中提取主题集。提取了两种主题集，每种主题集分别包含 7 个、10 个主题。如下图所示展示了其中一种，包含 7 个主题的主题集以及每个主题的关键字。

表 4.2 主题集

topic1	topic2	topic3	topic4	topic5	topic6	topic7
高效瘦腿	今日妆容	冰淇淋	装修灵感	人类幼崽	小猫咪	辣妹穿搭
减脂餐	口红试色	火锅	客厅装修	幼崽成长记	宠物奇遇记	平价穿搭分享
减肥日常	护肤品	零食测评	置物架	宝宝	小奶猫	约会穿搭
燃脂瘦全身	眼妆	饭菜谱	卧室改造	科学育儿	新手养猫	温柔穿搭
腹肌马甲线	粉底液	棉花糖	装修风格	宝宝穿搭	布偶猫	潮流穿搭
减肥逆袭	唇膏	金针菇	阳台装修	儿童房	哈士奇	卫衣穿搭
卡路里	腮红	西兰花	室内设计	读绘本	救助流浪动物	阔腿裤
运动打卡	精华抗老	凉拌菜	微波炉	益智玩具	可爱狗狗	棒球服
臀腿训练	祛痘	螺蛳粉	衣帽间	亲子游戏	养宠物	阿玛尼
无氧运动	敏感肌精华	大鱼大肉	卧室地毯	教育孩子	萌宠猫咪	百褶裙
斯维诗	兰蔻	亿滋奥利奥	无印良品	小马宝莉	PIDAN	URBANREVIVO
Keep	雅诗兰黛	海底捞	美的	凯蒂猫	BUNNY	安踏
圣农	海蓝之谜	星巴克	戴森	COROKU	可莉丝汀	BrandyMelville
超级猩猩	巴黎欧莱雅	肯德基	小米	JELLYCAT	豆柴	露露柠檬
EVERKEEP	屈臣氏	麦当劳	苏泊尔	爱他美	素力高	李宁
SWEATYBETTY	资生堂	喜茶	青山美宿	嫚熙	速诺	F426
YOTTOY	科颜氏	雪碧	鹿家良品	好奇	希宝	COS
姿美堂	娇兰	旺仔	小熊电器	babycare	海洋之星	47BRAND
MINAYO	修丽可	茶百道	松下	MAEIL	卡比	美职棒
75 派	倩碧	蜜雪冰城	爱格	泰兰尼斯	爱肯拿	viiwen

中国知网 https://www.cnki.net

4.4 实验结果与分析

4.4.1 评价指标

（1）总体准确率

总体准确率衡量分类的优度，通过正确预测的实例与分类案例总数的比率来评价。分类的整体精度计算方式如下：

$$\text{Overall accuracy}(x, \hat{x}) = \frac{1}{Cinstances}\sum_{i=0}^{Cinstances-1}(\hat{x}_i = x_i) \tag{4.8}$$

其中 Cinstances 为预测案例总数，x_i 为正确预测的实例数量。

（2）召回率

召回率用来衡量分类的契合度，通过分类器返回的正确结果的百分比来评价。召回率计算方式如下：

$$\text{recall} = {TP}/{(TP + FN)} \tag{4.9}$$

其中 TP 表示通过分类器正确分类的实例数，FN 表示未得到分类的实例数。

（3）精度

精度衡量分类的细度，通过正确预测的实例数与总预测实例数的比率来评价。精度的计算方式如下：

$$\text{precision} = {TP}/{(TP + FP)} \tag{4.10}$$

其中 TP 表示通过分类器正确分类的实例数，FP 表示错误分类的实例数。

4.4.2 实验结果

本节结合不同的评价指标，对本章改进的模型进行了综合分析，通过与传统方法的比较来对比验证本改进模型的优越能力。由以下实验结果图可以看出本章改进的模型在总体准确率、召回率和精度上都有显著提升。

中国知网 https://www.cnki.net

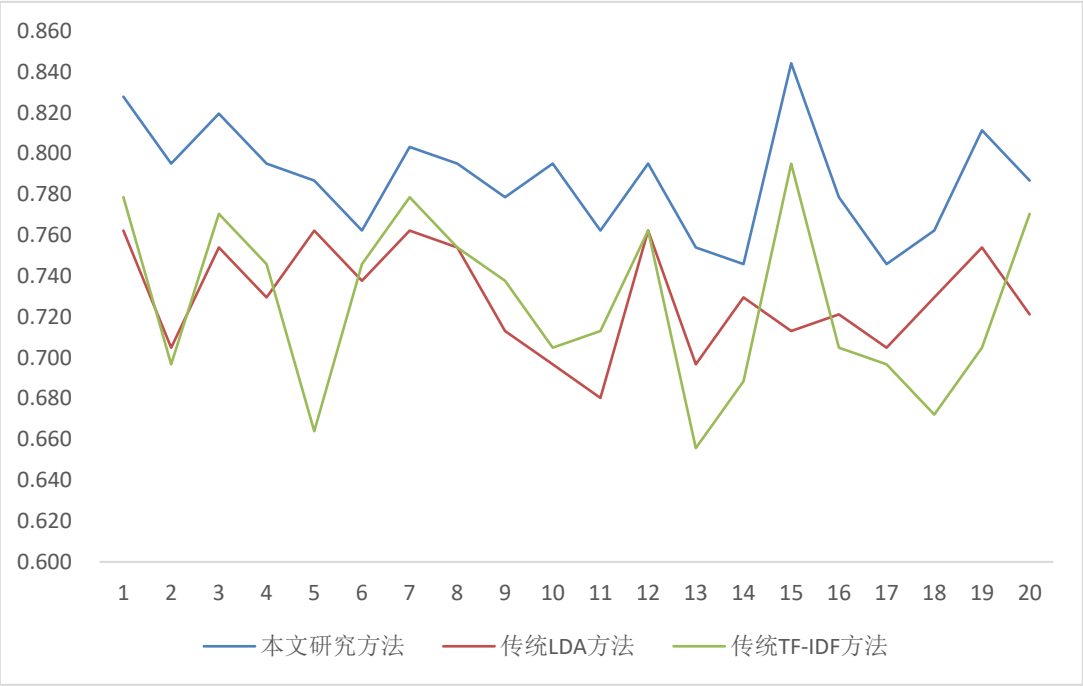

图 4. 2 总体准确率评价指标结果对比图

由上图结果可以看出，本文改进的方法相比于传统方法，在总体准确率上有显著提升。

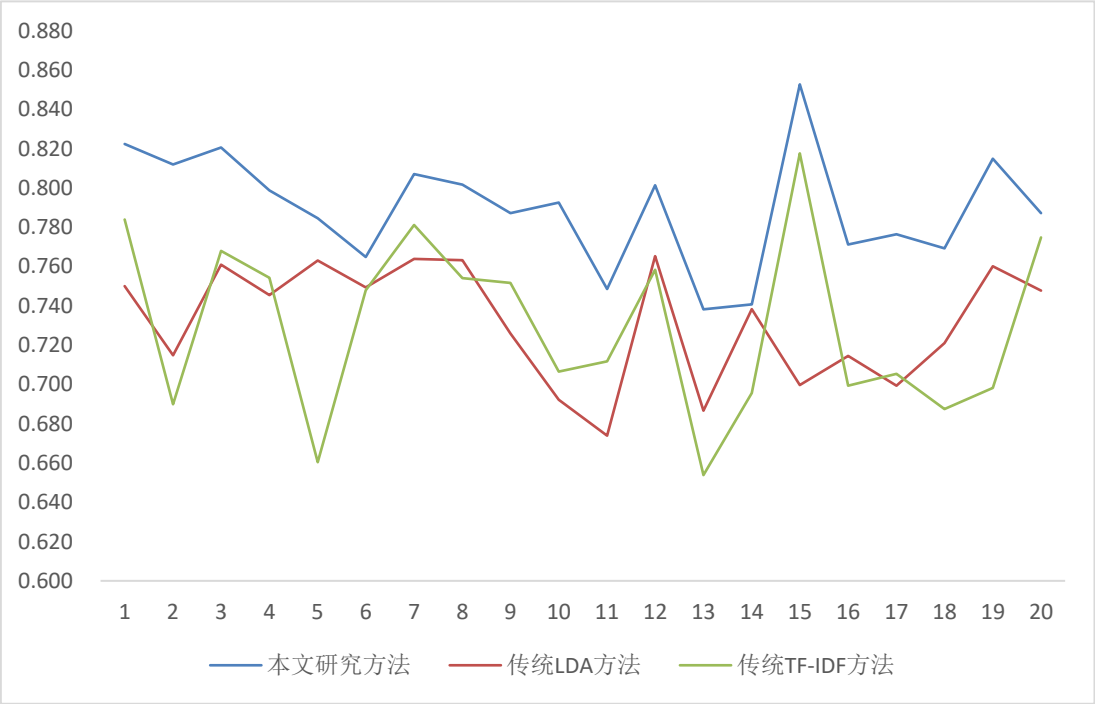

图 4. 3 召回率评价指标结果对比图

由上图结果可以看出，本文改进的方法相比于传统方法，在召回率上有显著提升。

中国知网 https://www.cnki.net

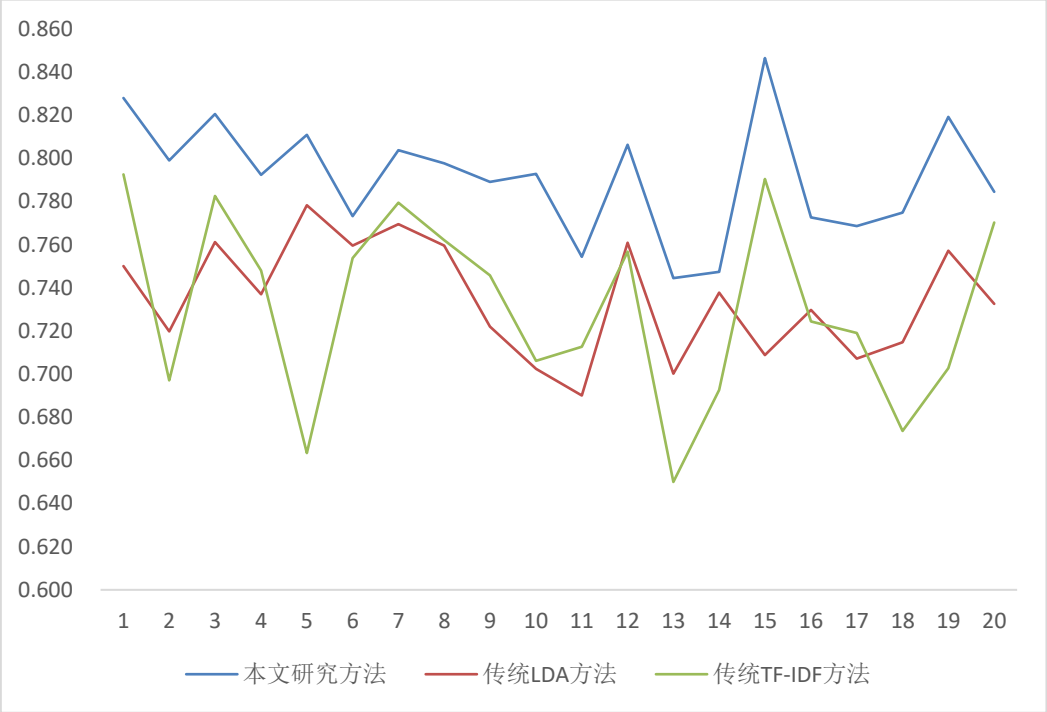

图 4. 4 精度评价指标结果对比图

由上图结果可以看出，本文改进的方法相比于传统方法，在精度上有显著提升。

4.5 本章小结

本章改进了 LDA 模型，引入 TF-IDF 计算用户数据的重要性，进行了用户特征提取，并通过 K-means 聚类算法对主题相似的用户进行人群分组。为了证明所提出系统的性能，采集了小红书电商平台的用户数据进行实验。实验结果表明，该系统能够根据用户的互动数据实现用户特征特征提取对用户进行分类。尤其改进 LDA 模型提取主题构建关键词字典时，我们的分类系统具有更好的聚类性能和更高的分类性能。本章的分类系统可以在高性能计算技术的支持下，对用户进行了特征画像和人群分类，为下一章用户推荐做基础。

中国知网 https://www.cnki.net

第五章 融合多源数据的广告推荐方法

在第四章对非结构文本数据进行特征提取的基础上，本章将结合结构性数据构建来用户画像模型和广告的特征向量，深度挖掘用户与项目之间的关联，从而提出一种融合多源异构数据的信息流广告推荐算法。本章对最后进行了实例，并在在数据集上进行实验，实验结果表明该方法优于传统方法。本章提出一种融合用户兴趣行为特征和基本人口属性特征的信息流广告推荐模型，在广度上剔除冗余特征，同时深度挖掘候选集与用户间的关联，以缓解冷启动问题。

5.1 问题分析

目前推荐系统的普遍存在数据稀疏性和冷启动问题，在实际应用往往采用混合推荐从而避免单一数据或模型带来的局限。但国内外学者目前推荐系统中的数据融合还存在以下问题：一是融合数据的类型，多源数据能提供更大的数据训练，在进行推荐时综合考虑多源数据会得到更加丰富的预测结果，但同时可能会引入与推荐无关的冗余数据，造成不必要的噪声。二是多源异构数据融合问题，来源于多个数据中的数据经常存在不同结构，对于结构类数据和非结构类数据融合有一定难度。

文献[66]提出了一种融合多源异构数据的社区商家推荐模型，为了全面反映用户喜好，综合考虑了用户对商家评分数据和用户社交关系，但是这种方式没有考虑到新用户进入时的冷启动问题。文献[67]提出了一种融合便签偏好和用户信任关系的个性化景区推荐方法通过挖掘用户的隐式信任关系,解决了现有研究在直接信任难以获得时无法进行推荐的问题,有效缓解了数据稀疏性和冷启动问题，但是该方法主要适用于社交网络关系的获取。文献[68]提出了一种加权融合用户兴趣相似度和用户评分差异值的推荐算法，用 TF-IDF 提取用户兴趣特征，根据历史评分矩阵构建用户评分矩阵来提高推荐精度，但是该方法仍未考虑到冷启动问题，同时忽略了用户和候选集本身的相关关系。

本章针对上述问题提出一种融合用户兴趣行为特征和基本人口属性特征的信息流广告推荐模型，在广度上剔除冗余特征，同时深度挖掘候选集与用户间的关联，以缓解冷启动问题。

中国知网 https://www.cnki.net

5.2 融合多源数据的广告推荐系统

5.2.1 算法设计

本算法流程如下。

步骤 1 对结构化数据处理，设定阈值，量化并分级结构化数据，剔除冗余特征。

步骤 2 使用第四章的方法提取非结构特征。

步骤 3 定义用户特征表示 U={B,A,t}。

步骤 4 对于广告的特征表示同上 1、2、3。

步骤 5 定义各类数据特征间相似度计算方式。

步骤 6 计算相似值进行推荐。用户特征与信息流广告特征匹配如下图所示。

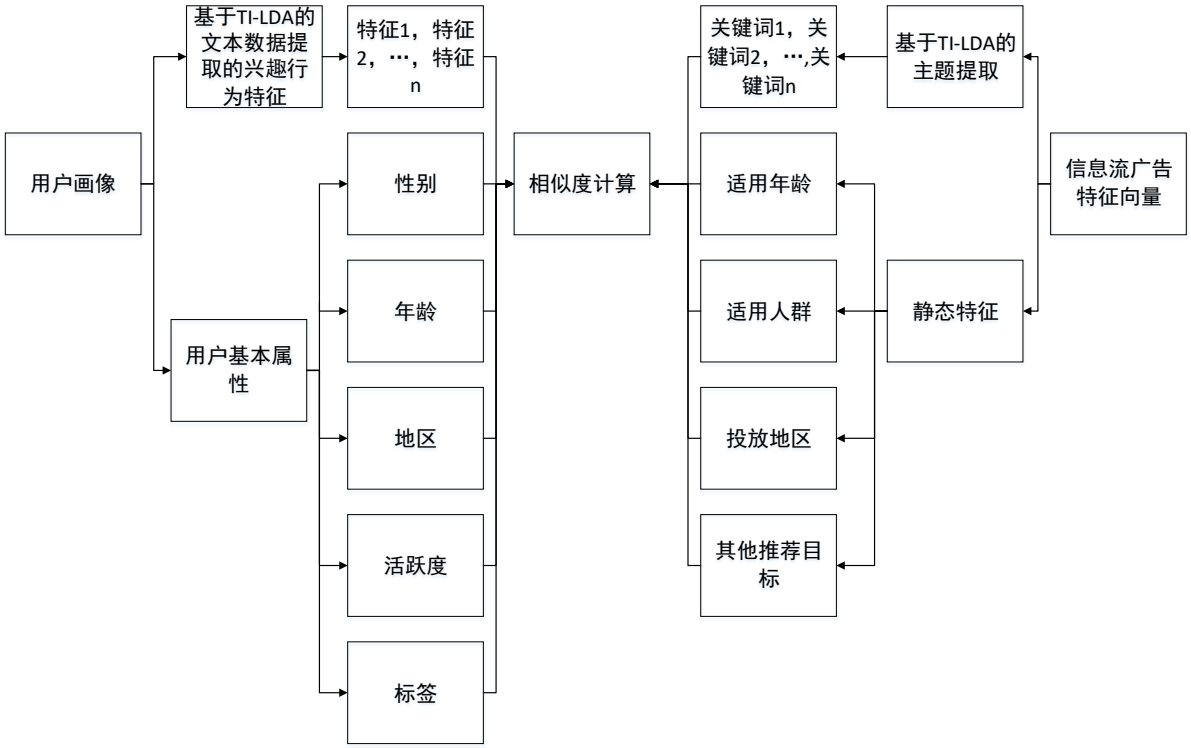

图 5. 1 用户与信息流广告特征相似度匹配图

对于是非型数据，例如定义性别相似度：

$$\mathrm{Sim}_{gender}(\mathrm{u,v}) = \begin{cases} 0\ ,\ Genderu \neq Genderv \\ 1\ ,\ Genderu = Genderv \end{cases} \tag{6.1}$$

对于区间型数据，例如年龄相似度：年龄差在 5 岁内，相似度为 1，年龄差大于 20 岁，相似度为 0。

$$\mathrm{Sim}_{age}(\mathrm{u,v}) = \begin{cases} 0\ ,\ |Age_u - Age_v| > 25 \\ \frac{(20-|Age_u-Age_v|)}{10}\ ,\quad 10 \le |Age_u - Age_v| \le 20 \\ 1\ ,\quad 0 < |Age_u - Age_v| < 5 \end{cases} \tag{6.2}$$

中国知网 https://www.cnki.net

对于文本数据数据，使用第四章构建的词典，基于词向量计算文本相似度。

表 5. 1 基于词向量的语义相似度

	基于词的语义相似度					
t_x	advise	project	scientific	reinforcement	study	sources
field	0.0019	0.0074	0.0091	0.0054	0.0011	0.016
think	0.0531	0.0004	0.0031	0.0043	0.0029	0.0037
resolve	0.0011	0.0029	0.0032	0.004	0.0015	0.0038
fulcrum	0.0028	0.0155	0.0191	0.0058	0.0012	0.0120

具体来说，对于词语 t_x 出现次数记录为 f_x。定义 t_x 与 p_a 中语义相似度最高的词语 d_y 的相似度为 s（t_x，k_y）∈（0，1）。将 k_i 中的 t_x 替换为 d_y，其权重更新为 $h_xy=f_xs$（t_x，d_y）。

假设用 d_1 来替换的 k_i 中的词语 n_1，替换后权重的权重为{h_{11}，h_{21}，…，h_{n1}}，同时 k 中词语 n_0 不被替换。

ki 表示为{d_1，d_2，…,d_t，d_{t+1},…,d_{t+n}}，对应的权重为{$\sum w_{j1}$，$\sum w_{j2}$，…,$\sum w_{jk}$，0，…，0}

通过 p_a 与 k_i 之间的相似值来计算 l_a 和 k_i 之间的相似度。权重 d_{t+1}，d_{t+2}，…,d_{t+n}=0，在 k_i 中去掉它们,d_i 与 p_a 成为同一空间向量。最后计算 p_a 和 k_i 中词语的 tf-idf 值来得出相似度。

如下图所示是本章融合多源数据的相似度计算的推荐系统伪代码

中国知网 https://www.cnki.net

```
def usersimilarity(user_items):
    item_users=defaultdict(set)
    for u, items in user_items.items():
        for i in items:
            if i not in item_users:
                item_users[i]=[]
            item_users[i].append(u)
    C=dict()
    N=dict()
    for i, users in item_users.items():
        for u in users:
            N.setdefault(u, 0)
            N[u]=N[u]+1
            C.setdefault(u, {})
            for v in users:
                if u==v:
                    continue
                C[u].setdefault(v,0)
                C[u][v]+=1
    w=dict()
    for u, related_users in C.items():
        w.setdefault(u,{})
        for v, cuv in related_users.items():
            w[u][v]=cuv/math.sqrt(N[u]*N[v])
    return w
def recommend(u, user_items, w, N):
    rank=dict()
    interacted_items=user_items[u]
    for v, wuv in sorted(w[u].items(), key=lambda x:x[1], reverse=True)[:N]:
        for i, rvi in user_items[v].items():
            if i in interacted_items:
                continue
            rank[i]=+wuv*rvi
    return rank
```

图 5. 2 融合多源数据的推荐算法代码

中国知网 https://www.cnki.net

5.3 仿真与实验

5.3.1 仿真实例

本文数据通过爬取网上采集的小红书平台用户数据作为实例分析的基础，爬取 27543 条用户数据，已做脱敏处理。

（1）数据预处理

量化分级结构化数据，最终保留性别、年龄 2 个指标。通过第四章的方法进行用户兴趣特征提取，最终保留 4 个特征词，这里以其中四类用户为例。

表 5. 2 数据量化分级

结构化数据	性别	男	0
		女	1
	年龄	19-24	0
		25-30	1
		31-39	2
		40+	3
	地区	一线城市	0
		二线城市	1
		三线城市	2
		四线城市	3
	活跃度	低	0
		中	1
		高	2
非结构化数据	特征 1、特征 2、特征 3、特征 n		

（2）用户画像构建

（ a）

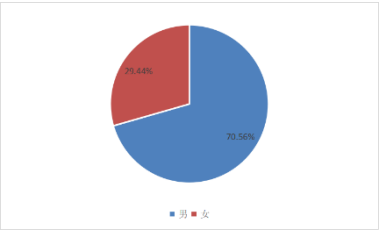

（ b）

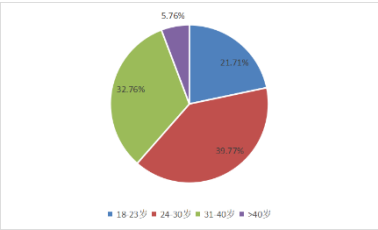

（ c）

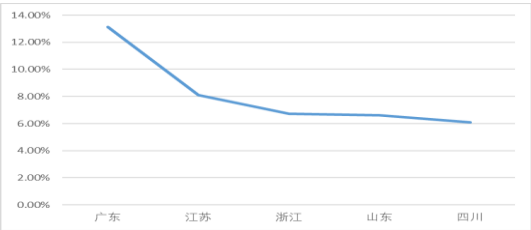

（ d）

图 5. 3 第一类用户

第一类用户，以男性为主，25-30 岁年龄为主要区间，以“装修灵感”、“客厅装修”“置

中国知网 https://www.cnki.net

物架”“卧室改造”为主要兴趣标签。

（ e）

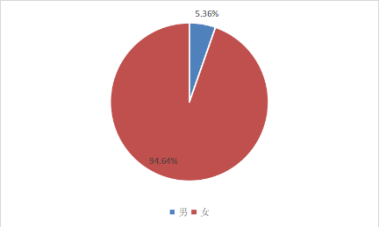

（ f）

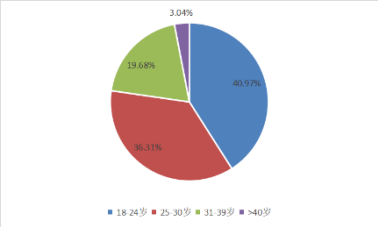

（ g）

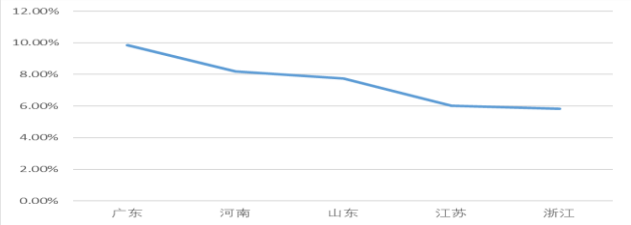

（ h）

图 5. 4 第二类用户

第二类用户，以女性为主，年龄以 18-24 为主要区间，以“今日妆容”、“口红试色”“护肤品”“眼妆”等为主要兴趣标签。

（ i）

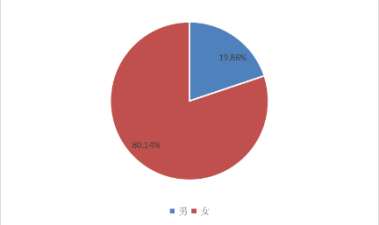

（ j）

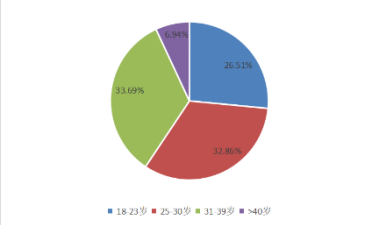

（ k）

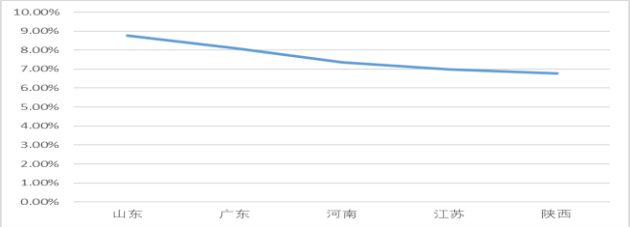

（ l）

图 5. 5 第三类用户

第三类用户，以女性为主，年龄区间在 25-30 岁为主要区间，以“冰淇淋”“火锅”“零食测评”“饭菜谱”为主要兴趣标签。

中国知网　https://www.cnki.net

（ m）

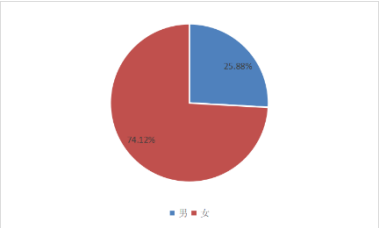

（ n）

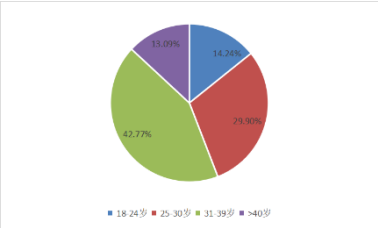

（ o）

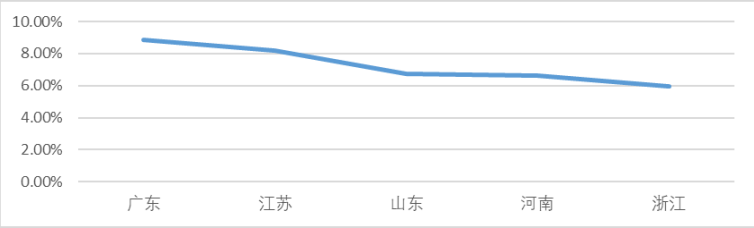

（ p）

图 5. 6 第四类用户

第四类用户，以 31-39 之间的女性用户为主，以“高效瘦腿”、“减脂餐”、“减肥日常”“燃脂瘦全身”等为主要兴趣特征。

（3）用户特征表示及兴趣特征向量矩阵

以上述四类用户作为实例分析。将用户特征表示为 U，向量矩阵为 V。

U1 = {0, 1, [装修灵感 客厅装置 置物架 卧室改造]}

U2 = {1, 0, [今日妆容 口红试色 护肤品 眼妆]}

U3 = {1, 0, [冰淇淋 火锅 零食测评 饭菜谱]}

U4 = {0, 1, [高效瘦腿 减脂餐 减肥日常 燃脂]}

$$V = \begin{pmatrix} 0.2593 & 0.1250 & 0.0913 & 0.0726 \\ 0.1519 & 0.1450 & 0.1287 & 0.1120 \\ 0.1973 & 0.0857 & 0.0688 & 0.0650 \\ 0.2255 & 0.1966 & 0.1326 & 0.1236 \end{pmatrix}$$

（4）用户特征与广告推荐匹配度计算

随机选取了三条广告与上述四类用户进行了相似度计算，匹配值计算结果如下表所示。

表 5. 3 用户与广告推荐度

	第一类用户	第二类用户	第三类用户	第四类用户
广告 1	0.168	0.931	0.735	0.621
广告 2	0.872	0.139	0.265	0.310
广告 3	0.455	0.586	0.389	0.522

由上表可以看出：

广告 1 与第二类用户契合度最高，优先推荐给第二类用户，其次是第三类和第四类用户。

广告 2 与第一类用户契合度最高，优先推荐给第一类用户。

中国知网 https://www.cnki.net

广告 3 与第二类用户契合度最高，优先推荐给第二类用户，其次是第四类用户。

5.4 本章小结

本章融合结构性数据和用户兴趣行为特征来构建用户画像模型和广告的特征向量，深度挖掘用户与项目之间的关联，从而提出一种融合多源异构数据的信息流广告推荐方法。本章最后进行了实例，并在在数据集上进行实验，实验结果表明该方法优于传统方法。本章针对提出一种融合用户兴趣行为特征和基本人口属性特征的信息流广告推荐模型，在广度上剔除冗余特征，同时深度挖掘候选集与用户间的关联，以缓解广告推荐中的冷启动问题。

中国知网 https://www.cnki.net

第六章 系统实现与测试

本文第三章对广告推荐系统进行整体设计，第四章、第五章详细设计了广告推荐系统中的关键技术和推荐方案。基于上述基础，本章对推荐系统进行原型搭建与实现以及各个功能模块的实现与测试。本章首先描述搭建系统的软硬件环境，其次进行系统内各部分的原型实现，最后测试各模块的业务功能。

6.1 环境搭建

6.1.1 硬件环境

本小节来说明系统开发和部署需要搭建的软件环境和硬件环境。

推荐系统的硬件环境包括开发环境、数据库数据库和应用服务器。其中开发环境中进行代码编写；数据库中进行系统中的数据存储与访问；应用服务器中部署前后端代码。如下表具体详述了硬件环境各参数。

表 6.1 系统开发硬件环境

开发环境	
属性	参数
设备型号	MECHREVO Z2 Series GK5CN6Z
操作系统	Windows 10 企业版
CPU	Intel(R) Core(TM) i7-8750H CPU 2.20 GHz
内存	16GB DDR4 2666MHz
数据库服务器	
属性	参数
设备型号	腾讯云轻量应用服务器
操作系统	CentOS7.6 64 位
CPU	Intel(R) Xeon(R) Gold 6148 CPU 2.40GHz
内存	4GB DDR4
应用服务器	
属性	参数
设备型号	腾讯云轻量应用服务器
操作系统	CentOS7.6 64 位
CPU	Intel(R) Xeon(R) Gold 6148 CPU 2.40GHz
内存	4GB DDR4

中国知网 https://www.cnki.net

6.1.2 软件环境

本文的推荐系统的开发需要搭建相应的软件环境。包括后端开发语言和框架、前端开发框架和环境、数据库服务工具和应用服务器工具。如下表具体详述了软件环境各参数。

表 6.2 系统开发软件环境

软件服务	软件名称	版本
后端开发语言	JAVA	jdk1.8.0_231
后端框架	SpringBoot	2.2.1.RELEASE
推荐算法开发语言	Python	3.8.3
前端框架	Vue	2.6.11
开发环境	Intellij IDEA	2022.1
数据库服务	Mysql	5.7.27
应用服务器	tomcat	8.5.87
版本控制	subversion	1.11.1

6.2 系统实现

在第三章系统总体设计和第四、五章构建系统核心技术方案的基础上，本节实现了内部子系统的原型。接下来将分小节详细介绍各子系统功能，介绍各子系统的运行流程图和 UML 类图建模。

6.2.1 数据存储与管理子模块

数据存储子模块主要负责平台文章、用户信息、信息流广告数据的收集存储与统一管理。对于用户信息，能够实现用户基本信息的新增、编辑和删除；能够实现用户行为信息的日志记录工作。该模块能够对数据信息进行收集，并进行结构的统一化处理，持久化本地数据库。数据存储模块的主要流程图如下图所示。

中国知网 https://www.cnki.net

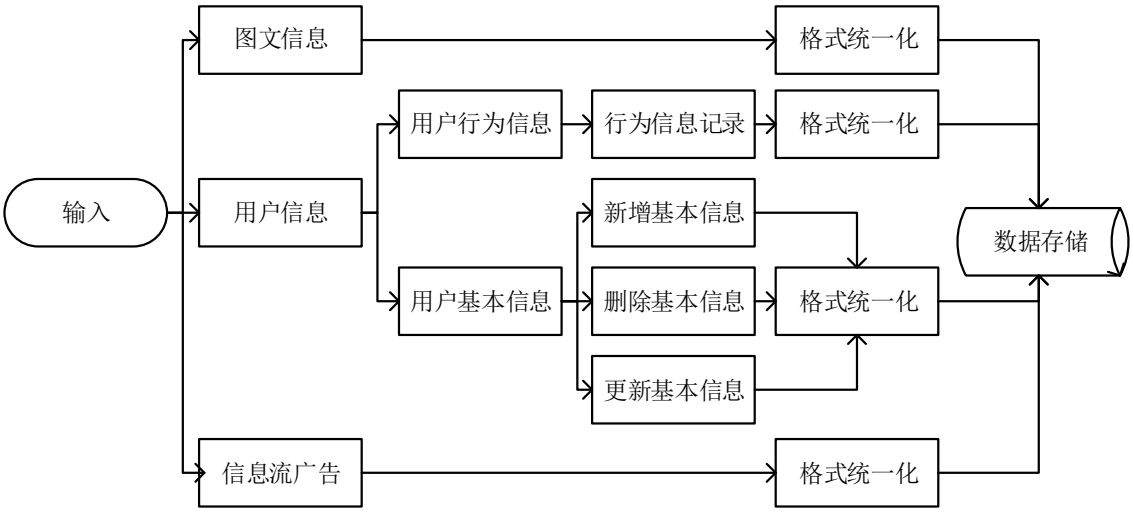

图 6. 1 数据存储与管理子模块

6.2.2 特征提取子模块

特征提取子模块从数据存储子模块中获取数据后，主要负责基于文本数据的特征提取及分类，主要涉及文本处理的相关算法，生成文本的特征表示向量，为后续个性化推荐奠定基础。首先获取文本信息，将其进行文本预处理操作，包括去停用词、分词等；其次使用第四章基于改进的文本处理算法进行特征提取，将其进行训练分类生成文本特征表示向量，将获取特征的文本集合输入分类模型；最后得到文本类别及主题特征。具体流程如下图所示。

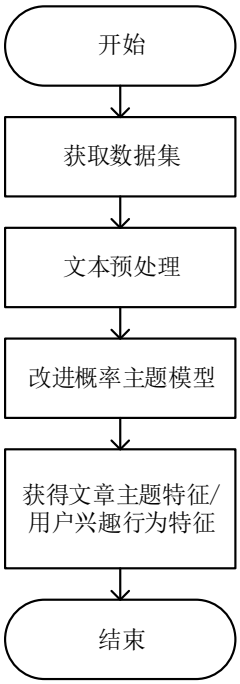

图 6. 2 特征提取子模块

中国知网 https://www.cnki.net

6.2.3 用户画像与特征融合子模块

特征融合和用户画像子模块包括个人用户画像和群体用户画像，主要负责融合用户的基本信息和行为数据来提取用户特征，生成最终用户特征向量表示，是本文实现推荐的重要基础。个人用户画像根据设计的便签体系来表示用户特征，一方面调取用户兴趣集到改进的 TI-LDA 模型中得到用户兴趣特征向量，同时融合用户基本信息来得到最终得用户特征向量表示。群体用户画像通过聚类算法来用户聚类，从其中提取群体用户特征。具体流程如图所示。

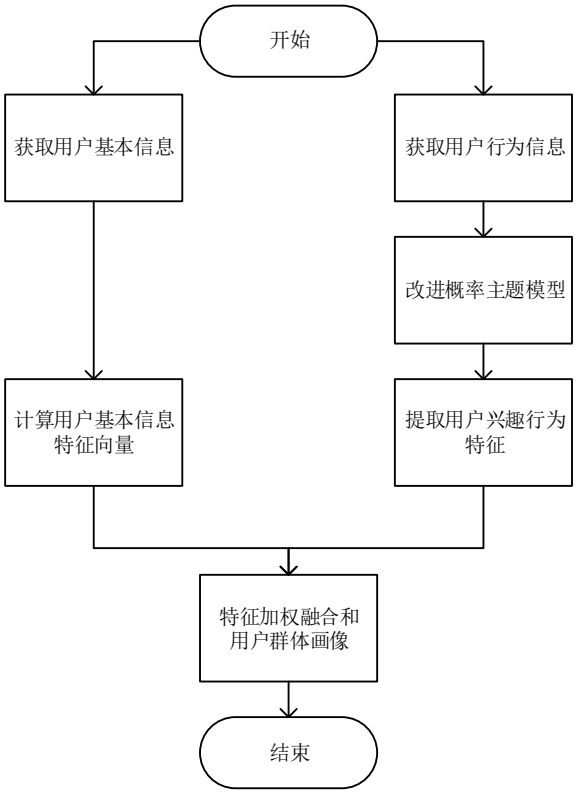

图 6. 3 用户画像和特征融合

6.2.4 推荐召回子模块

推荐召回子模块主要包括基于内容的召回、协同过滤召回、热点召回和搜索召回这四种召回方式，在不同阶段使用不同召回方式，充分发挥不同召回策略的优势，来实现推荐内容的多样性和精准性。

（1）基于内容的推荐召回

基于内容的召回策略是本文主要研究和详细设计的推荐方式，依靠文本处理模块提取文本特征和用户特征进行匹配来实现召回。首先使用特征提取子模块中训练的分类器得到文本主题特征分布；其次调取用户兴趣偏好集合并输入到训练好的用户画像模型中进行设计，提

中国知网 https://www.cnki.net

取用户的特征表示；最后将候选集中文本特征向量与用户特征向量进行匹配，获取相似度高的 N 个信息流广告内容进行召回。具体流程如图所示。

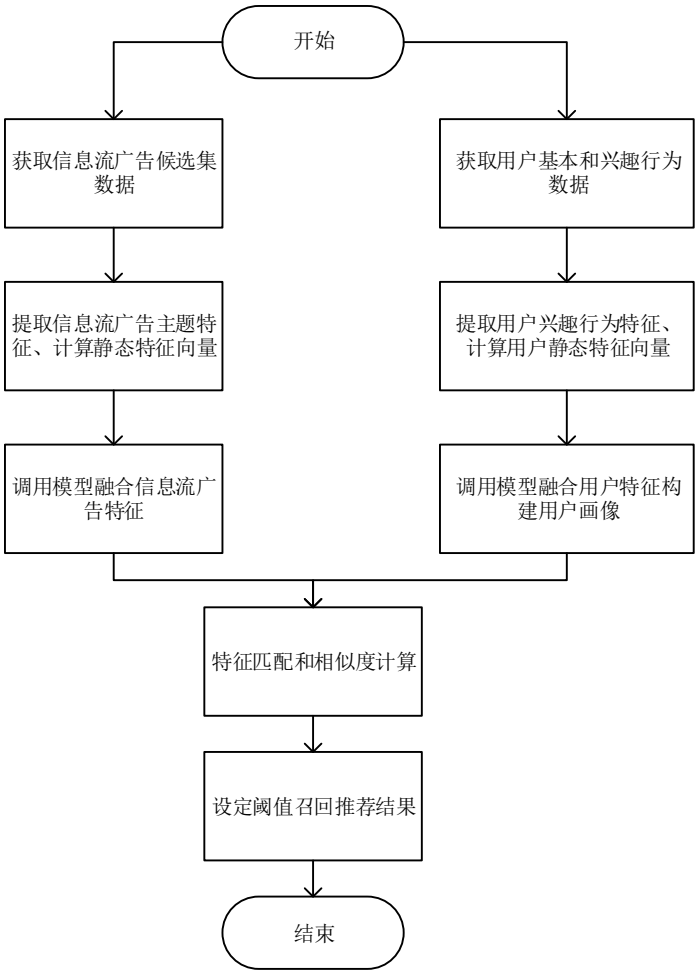

图 6. 4 基于内容的召回

（2）协同过滤召回

协同过滤召回，主要基于用户画像子模块提取到的用户特征来得到召回集。首先调取用户特征数据，并进行用户画像的相似度计算；其次根据相似度矩阵进行用户聚类；最后设定最邻近个数获取其他用户偏好集合来实现协同过滤召回。具体流程如图所示。

中国知网 https://www.cnki.net

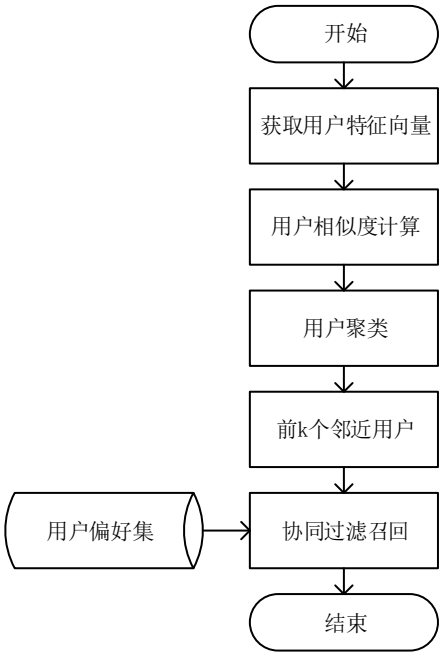

图 6. 5 协同过滤召回

（3）热点召回

根据设定的信息流广告热度计算规则，计算所有广告文本的热度，排序出热度较高的 N 个广告列表，将其加入到召回集中。

（4）搜索召回

基于搜索的召回，通过分析用户的搜索内容，匹配信息流广告特征，以此获取较精准的推荐结果。

6.2.5 排序过滤子模块

排序过滤子系统主要负责对召回候选集数据的去重过滤、排序生成最终推荐列表。首先，读取用户行为数据，通过文本处理特征提取获取文章主题向量和用户兴趣行为特征向量，结合用户基本信息得到特征样本。其次将召回集合输入到训练号的模型中，根据点击率 CTR 进行排序。最后基于推荐数目、历史浏览记录、黑白名单等进一步过滤，混合热点内容到推荐结果中，得到最终的推荐列表。具体流程如图所示。

中国知网 https://www.cnki.net

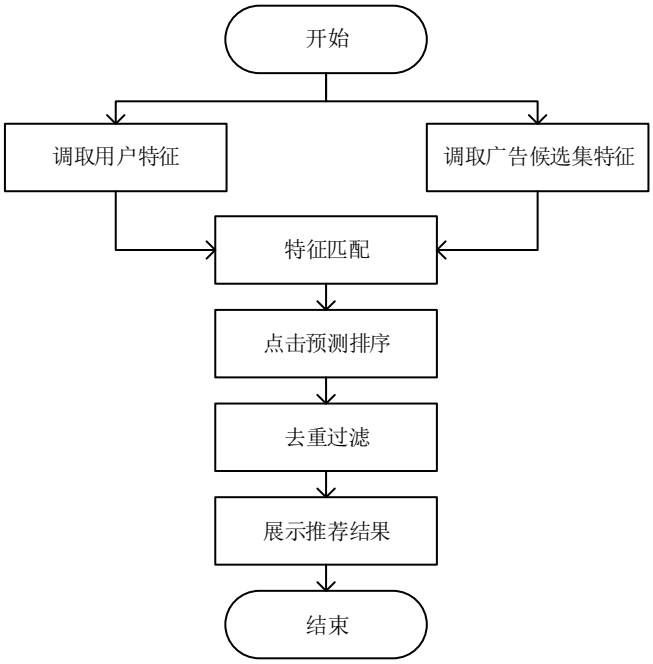

图 6. 6 排序过滤子模块

6.3 功能测试

基于上节环境搭建和系统构建，本节将进行系统的功能测试和界面展示。

6.3.1 前台个人用户端

前台用户端包括用户注册和登录功能、用户个人中心模块、用户访问平台文章模块。如下图展示了用户注册登录界面。

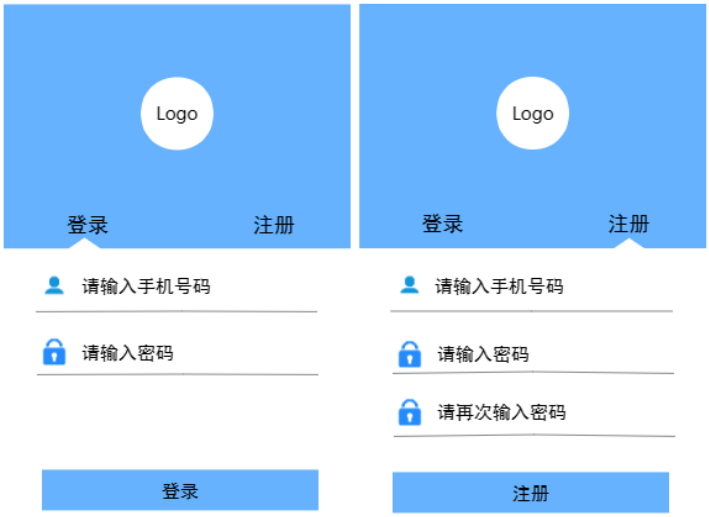

图 6. 7 用户注册登录界面

中国知网 https://www.cnki.net

个人中心板块主要包括个人基本信息的修改和完善、历史行为的记录功能。如下图展示了用户个人中心界面。

图 6. 8 个人中心界面

主页板块主要包括图文频道列表和穿插个性化信息流广告。如下图展示了用户主页浏览和个性化推荐模块界面。

图 6. 9 主页推荐界面

前台用户端的具体功能操作和测试结果如下表所示。

中国知网 https://www.cnki.net

表 6.3 前台用户端测试操作

测试功能	测试步骤	预期结果	测试结果	是否符合预期
用户注册	注册新用户	输入合法且唯一的信息则注册成功，否则失败	输入合法且未注册过的信息提示注册成功；输入非法或已存在的信息则提示注册失败	是
用户登录	登录账号	输入已注册的账号密码则成功登录，否则失败	账号密码正确则登录成功；否则提示错误	是
编辑资料	编辑或修改个人信息	可以编辑并保存个人信息	可修改个人信息并保存	是
历史记录	记录用户行为	记录用户在平台上的浏览、点赞、转发等行为数据	可记录用户历史行为	是
文章分类	点击不同频道	获取指定类别文献并穿插信息流广告	筛选出相应类别的文章	是
行为交互	点赞、收藏等行为动作按钮	完成指定动作并记录	完成指定动作	是

6.3.2 后台管理员端

后台管理员端主要功能包括管理员注册登录及角色管理、用户管理和平台数据管理等。如下图所示是后台管理员端的注册登录界面。

中国知网 https://www.cnki.net

图 6. 10 后台管理端注册登录界面

管理员端数据管理界面如下图所示。

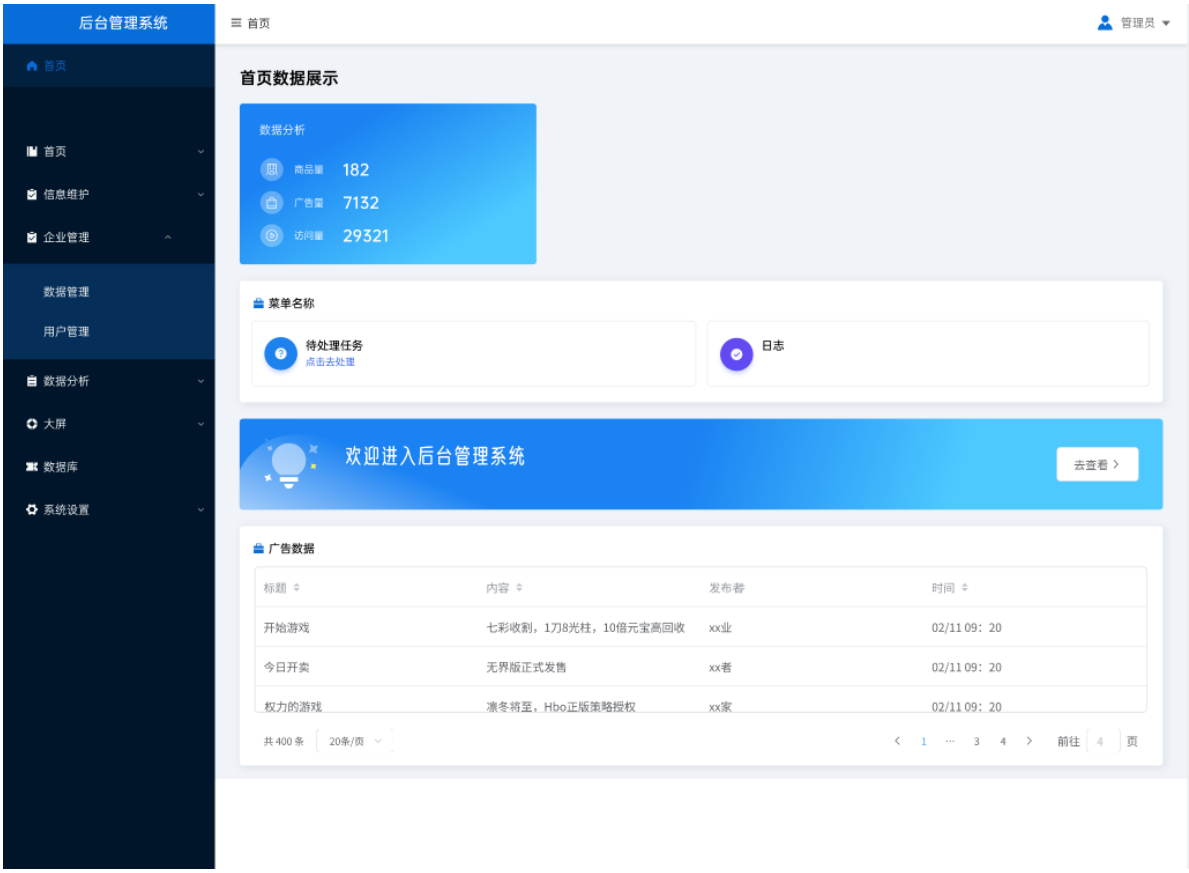

图 6. 11 数据管理界面

基本功能包括管理员角色权限管理、用户管理、平台数据维护、平台监控等功能。具体操作和测试结果如下表所示。

中国知网 https://www.cnki.net

表 6.4 后台管理员端功能测试操作

测试功能	测试步骤	预期结果	实际结果	是否符合预期
管理员登录	登录	输入正确账号密码则跳转页面；否则显示用户信息错误	输入正确信息则登录主页；输入错误则提示信息错误	是
角色管理	对管理员角色信息进行增删改查	正确操作则写入数据库中否则提示错误信息	正确操作时可以进行管理员角色的增删改查；否则提示错误	是
用户管理	查看用户信息和删除不合规信息	合规操作则写入数据库中；否则显示错误提示	可以查看用户基本信息和行为日志；可以删除用户不合规发布	是
发布管理	查看发布内容并维护	合规操作则写入数据库中；否则显示错误提示	可以查看发布内容；可以删除不合规发布	是

6.4 本章小结

本章对本文设计的信息流广告推荐系统进行了原型实现和系统仿真。首先阐述了系统搭建的硬件和软件环境，其次对主要模块进行了原型实现，包括数据存储子模块、特征提取子模块、特征融合与用户画像子模块、推荐召回子模块和排序过滤子模块。最后从前台用户端和后台管理员端两方面角度进行了具体的功能测试，测试结果表明本文实现了信息流广告推荐系统。

中国知网 https://www.cnki.net

第七章 总结与展望

7.1 总结

互联网的迅速发展带动了电子商务的蓬勃发展，促进了广告的新一轮竞争。在移动互联网的高速发展下，信息流广告由于其效益转化优势成为各主流电商及社交媒体平台流量变现的主要广告模式。个性化推荐系统作为一种有效的信息过滤工具，可以帮助用户在需求不明确的情况下高效地获取满足自己需求的信息。本文设计了一种融合多源数据和改进特征提取方法的信息流广告推荐系统。

本文研究的贡献主要在以下几个方面：

（1）研究了国内外研究学者在推荐系统主流的算法模型和应用领域，包括基于内容的推荐、协同过滤、混合推荐和基于知识的推荐等。研究了文本数据处理中特征表示和提取的主流主题模型。研究了推荐模型中特征融合的主要方式。

（2）编写了信息流广告推荐系统的需求分析。层层详细设计了推荐系统的主要功能，自底向上依次包括数据存储层、特征提取融合与用户画像层、推荐召回层、排序与过滤层、显示层。完成了主要核心功能的详细设计，包括数据存储与管理功能、文本特征提取和分类功能、用户画像功能、候选集召回功能和找回排序功能。构建了数据库。最后实现了推荐系统。

（3）本研究对主题模型 Lda 进行改进，提出了一种 TI-Lda 模型。在第四章中首先对文本数据进行中文分词、去停用词的预处理操作，其次基于 TI-lda 对文本数据进行特征表示和提取，然后利用聚类算法实现文本数据的分类，从而实现了用户兴趣行为特征和广告主题的分类，为后续推荐系统奠定了基础。实验结果表明，改进后的模型对文本数据的处理，相对于传统方法，在整体精度、召回率和精度等方面具有优越性。

（4）本研究融合多源数据，主要是用户平台属性数据和用户行为数据，构建了用户画像，同时进行了用户和广告的特征向量表示。第五章中首先融合多源异构数据构建了用户画像和广告特征向量表示，其次进行用户和广告的相似度匹配，根据契合度值选择得分较高的进行排序推荐，实现了本文主要研究的基于内容的推荐方式。在构建用户画像的同时进行了群体相似度计算，实现了协同推荐方式。本文提出的推荐方法缓解了传统推荐系统中的冷启动问题，丰富了推荐结果的多样性，提高了推荐结果的精准度。

（5）对信息流广告推荐系统进行了系统仿真和功能测试，用户端功能包括用户注册和登录功能、用户个人中心模块、用户访问平台文章模块。管理员端功能包括管理员角色权限管

中国知网 https://www.cnki.net

理、用户管理、平台数据维护、平台监控等，在第六章中从前台个人用户端和后台管理员端两个方面搭建了界面进行展示，并测试了核心功能。

7.2 展望

信息流广告推荐是互联网大时代的趋势，本文提出的基于 TI-LDA 和融合多源数据的信息流广告推荐系统，为后续学者在推荐系统的特征提取改进方法和数据融合等方面提供了研究思路。但本文研究还存在一些不足。

（1）一方面是信息安全的问题，推荐系统的数据基础是用户历史行为数据和用户在平台留下的个人信息，这些都可能涉及到用户个人隐私问题，因此数据保护是本文后续推荐系统研究中需要关注的地方。

（2）一方面是系统性能问题，本文设计的推荐系统时间复杂度高，在后续的研究中需要改善模型计算量，提高效率。

中国知网 https://www.cnki.net

参考文献

[1] 王铮. 互联网广告服务器集群的设计实现与性能优化[D].山东大学,2019.

[2] 温进浪. 腾讯计算广告的运营模式研究[D].广西大学,2021.DOI:10.27034/d.cnki.ggxiu.2021.000816.

[3] Science - Library Science; Findings from Humboldt University Broaden Understanding of Library Science (Selecting a Text Similarity Measure for a Content-based Recommender System a Comparison In Two Corpora)[J]. Computer Technology Journal,2019.

[4] Garanayak Mamata,Nayak Kumar Suvendu,Sangeetha K.,Choudhury Tanupriya,Shitharth S.. Content and Popularity-Based Music Recommendation System[J]. International Journal of Information System Modeling and Design (IJISMD),2022,13(7).

[5] Chaudhuri Arpita,Sarma Monalisa,Samanta Debasis. SHARE: Designing multiple criteria-based personalized research paper recommendation system[J]. Information Sciences,2022,617.

[6] Bagwari Ashish,Sinha Anurag,Singh N. K.,Garg Namit,Kanti Jyotshana. CBIR-DSS: Business Decision Oriented Content-Based Recommendation Model for E-Commerce[J]. Information,2022,13(10).

[7] S. Sridhar,D. Dhanasekaran,G. Charlyn Pushpa Latha. Content-Based Movie Recommendation System Using MBO with DBN[J]. Intelligent Automation & Soft Computing,2023,35(3).

[8] Albatayneh Naji Ahmad,Ghauth Khairil Imran,Chua Fang-Fang. Discriminate2Rec: Negation-based dynamic discriminative interest-based preference learning for semantics-aware content-based recommendation[J]. Expert Systems With Applications,2022,199.

[9] Panpan Yang,Guangming Li,Xin Xue. Design of collaborative filtering recommendation algorithm combining time weight and reward and punishment factors[J]. Academic Journal of Computing & Information Science,2022,5(14).

[10] Karn Arodh Lal,Karna Rakshha Kumari,Kondamudi Bhavana Raj,Bagale Girish,Pustokhin Denis A.,Pustokhina Irina V.,Sengan Sudhakar. Customer centric hybrid recommendation system for E-Commerce applications by integrating hybrid sentiment analysis[J]. Electronic Commerce Research,2022,23(1).

[11] Stefanidis Kiriakos,Tsatsou Dorothea,Konstantinidis Dimitrios,Gymnopoulos Lazaros,Daras Petros,WilsonBarnes Saskia,Hart Kathryn,Cornelissen Véronique,Decorte Elise,Lalama Elena,Pfeiffer Andreas,Hassapidou Maria,Pagkalos Ioannis,Argiriou Anagnostis,Rouskas Konstantinos,Hadjidimitriou Stelios,Charisis Vasileios,Dias Sofia Balula,Diniz José Alves,Telo Gonçalo,Silva Hugo,Bensenousi Alex,Dimitropoulos Kosmas. PROTEIN AI Advisor: A Knowledge-Based Recommendation Framework Using Expert-Validated Meals for Healthy Diets[J]. Nutrients,2022,14(20).

[12] Colace Francesco,Conte Dajana,De Santo Massimo,Lombardi Marco,Santaniello Domenico,Valentino Carmine. A content-based recommendation approach based on singular value decomposition[J]. Connection Science,2022,34(1).

[13] Pujahari Abinash,Sisodia Dilip Singh.Item feature refinement using matrix factorization and boosted learning based user profile generation for content-based recommender systems[J].Expert Systems With Applications,2022,206(206).

[14] Nguyen Van Dat,Pham Van Toan,Ta Minh Thanh.Solving distribution problems in content-based recommendation system with gaussian mixture model[J].Applied Intelligence,2021,(prepublish).

[15] Albatayneh Naji Ahmad,Ghauth Khairil Imran,Chua Fang-Fang.Discriminate2Rec: Negation-based dynamic discriminative interest-based preference learning for semantics-aware content-based recommendation[J].Expert Systems With Applications,2022,199(199).

中国知网 https://www.cnki.net

[16] Colace Francesco,Conte Dajana,De Santo Massimo,Lombardi Marco,Santaniello Domenico,Valentino Carmine. A content-based recommendation approach based on singular value decomposition[J]. Connection Science,2022,34(1).

[17] Nikita Taneja,Hardeo Kumar Thakur. Evaluating the Scalability of Matrix Factorization and Neighborhood Based Recommender Systems[J]. International Journal of Information Technology and Computer Science(IJITCS),2023,15(1).

[18] Akbar Shahid,Hayat Maqsood,Tahir Muhammad,Khan Salman,Alarfaj Fawaz Khaled. cACP-DeepGram: Classification of anticancer peptides via deep neural network and skip-gram-based word embedding model[J]. Artificial Intelligence In Medicine,2022,131.

[19] William Giovinno Bryan ,Gunawan Alexander Agung Santoso. Bilateral Variational Autoencoder Optimization with Learning-to-Rank Metric on Collaborative Filtering Recommendation[J]. 2023,17(02).

[20] Aljunid Mohammed Fadhel,Doddaghatta Huchaiah Manjaiah. Multi-model deep learning approach for collaborative filtering recommendation system[J]. CAAI Transactions on Intelligence Technology,2020,5(4).

[21] Thavavel Vaiyapuri. Deep Learning Enabled Autoencoder Architecture for Collaborative Filtering Recommendation in IoT Environment[J]. Computers, Materials & Continua,2021,68(1).

[22] Sejwal Vineet K.,Abulaish Muhammad. A hybrid recommendation technique using topic embedding for rating prediction and to handle cold-start problem[J]. Expert Systems With Applications,2022,209.

[23] Cao Yixiao,Liu Peng. Personalized Music Hybrid Recommendation Algorithms Fusing Gene Features[J]. Mathematical Problems in Engineering,2022,2022.

[24] Federica Cena,Luca Console,Fabiana Vernero. Logical foundations of knowledge-based recommender systems: A unifying spectrum of alternatives[J]. Information Sciences,2021,546.

[25] Stefanidis Kiriakos,Tsatsou Dorothea,Konstantinidis Dimitrios,Gymnopoulos Lazaros,Daras Petros,WilsonBarnes Saskia,Hart Kathryn,Cornelissen Véronique,Decorte Elise,Lalama Elena,Pfeiffer Andreas,Hassapidou Maria,Pagkalos Ioannis,Argiriou Anagnostis,Rouskas Konstantinos,Hadjidimitriou Stelios,Charisis Vasileios,Dias Sofia Balula,Diniz José Alves,Telo Gonçalo,Silva Hugo,Bensenousi Alex,Dimitropoulos Kosmas. PROTEIN AI Advisor: A Knowledge-Based Recommendation Framework Using Expert-Validated Meals for Healthy Diets[J]. Nutrients,2022,14(20).

[26] V. Vijayakumar,Subramaniyaswamy Vairavasundaram,R. Logesh,A. Sivapathi. Effective Knowledge Based Recommender System for Tailored Multiple Point of Interest Recommendation[J]. International Journal of Web Portals (IJWP),2019,11(1).

[27] Wang Zheyu,Huang Haoce,Cui Liping,Chen Juan,An Jiye,Duan Huilong,Ge Huiqing,Deng Ning. Using Natural Language Processing Techniques to Provide Personalized Educational Materials for Chronic Disease Patients in China: Development and Assessment of a Knowledge-Based Health Recommender System.[J]. JMIR medical informatics,2020,8(4).

[28] Avasthi Sandhya,Chauhan Ritu,Acharjya Debi Prasanna. Extracting information and inferences from a large text corpus.[J]. International journal of information technology : an official journal of Bharati Vidyapeeth's Institute of Computer Applications and Management,2022,15(1).

[29] Srinivasarao Ulligaddala,Sharaff Aakanksha. Email thread sentiment sequence identification using PLSA clustering algorithm[J]. Expert Systems With Applications,2022,193.

[30] Qi Liangang,Shen Zhenheng,Guo Qiang,Wang Yani,Mykola Kaliuzhnyi. Chirp Rates Estimation for Multiple LFM Signals by DPT–SVD[J]. Circuits, Systems, and Signal Processing,2022,42(5).

[31] Hyperdyne Inc.; Patent Application Titled "Decentralized Latent Semantic Index Using Distributed Average Consensus" Published Online (USPTO 20190228025)[J]. Computer Weekly News,2019.

[32] Li Linhui,Dai Dan,Liu Hongjiu,Yuan Yubo,Ding Lizhong,Xu Yujie. Research on Short Video Hotspot Classification Based on LDA Feature Fusion and Improved BiLSTM[J]. Applied Sciences,2022,12(23).

中国知网 https://www.cnki.net

[33] Osuntoki Seun,Odumuyiwa Victor,Sennaike Oladipupo. Understanding Document Thematic Structure: A Systematic Review of Topic Modeling Algorithms[J]. Journal of Information and Organizational Sciences,2022,46(2).

[34] K. Anuratha,M. Parvathy. Multi-label Emotion Classification of COVID–19 Tweets with Deep Learning and Topic Modelling[J]. Computer Systems Science and Engineering,2022,45(3).

[35] 徐雪珂,邓松,张荣,叶治,徐昊颖.基于个体特征与教学评价的教师学习对象推荐[J].江西师范大学学报(自然科学版),2019,43(04):409-415.DOI:10.16357/j.cnki.issn1000-5862.2019.04.13.

[36] Yao Dunhong,Deng Xiaowu. A Course Teacher Recommendation Algorithm Based on Improved Latent Factor Model and PersonalRank[J]. IEEE ACCESS,2021,9.

[37] Srinivasarao Ulligaddala,Sharaff Aakanksha. Email thread sentiment sequence identification using PLSA clustering algorithm[J]. Expert Systems With Applications,2022,193.

[38] Shuoyan LIU,Enze YANG,Kai FANG. Self-Learning pLSA Model for Abnormal Behavior Detection in Crowded Scenes:Regular Section[J]. IEICE Transactions on Information and Systems,2021,E104.D(3).

[39] Liu, Z. Demand Analysis of Online Chinese Behavior Expression in Wireless Sensor[J]. Clarivate Analytics Web of Science,2021

[40] Liu, SY. Self-Learning pLSA Model for Abnormal Behavior Detection in Crowded Scenes[J]. Clarivate Analytics Web of Science,2021

[41] 马伟彬.TF-IDF模型和LSI模型文本相似度算法的应用[J].电子技术与软件工程,2022(01):130-133.

[42] 桑雪,何静,陈明.基于TF-IDF和LSI模型的网络舆情实时监测建模和应用[J].数学的实践与认识,2022,52(11):56-66.

[43] Teh, PL. Analysis of Popular Social Media Topics Regarding Plastic Pollution[J]. Clarivate Analytics Web of Science.2022

[44] Liao, CH. A Photo Post Recommendation System Based on Topic Model for Improving Facebook Fan Page Engagement[J]. Clarivate Analytics Web of Science.2020

[45] Bie, Y. Fusing Syntactic Structure Information and Lexical Semantic Information for End-to-End Aspect-Based Sentiment Analysis[J]. Clarivate Analytics Web of Science ,2023

[46] 张东鑫,张敏.图情领域LDA主题模型应用研究进展述评[J].图书情报知识,2022,39(06):143-157.DOI:10.13366/j.dik.2022.06.143.

[47] 王一朵,吕卫东,胡陈陈,郑江怀.基于PCA、LDA和LR融合算法的人脸图像识别研究[J].科学技术创新,2022(22):72-75.

[48] 邰悦. 基于社会化标签的主题识别方法研究[D].安徽理工大学,2022.DOI:10.26918/d.cnki.ghngc.2022.000218.

[49] Uthirapathy Samson Ebenezar,Sandanam Domnic. Topic Modelling and Opinion Analysis On Climate Change Twitter Data Using LDA And BERT Model.[J]. Procedia Computer Science,2023,218.

[50] Li Linhui,Dai Dan,Liu Hongjiu,Yuan Yubo,Ding Lizhong,Xu Yujie. Research on Short Video Hotspot Classification Based on LDA Feature Fusion and Improved BiLSTM[J]. Applied Sciences,2022,12(23).

[51] Xie Qihui,Xue Yanan,Zhao Zhuojun. Understanding the Scientific Topics in the Chinese Government's Communication about COVID-19: An LDA Approach[J]. Sustainability,2022,14(15).

[52] Backbone Network for Object Detection with Multiple Dilated Convolutions and Feature Summation[J]. Journal of KIISE,2018,45(8).

[53] 李梅,宁德军,郭佳程.基于注意力机制的CNN-LSTM模型及其应用[J].计算机工程与应用,2019,55(13):20-27.

[54] 张艳,王林茂,程志友,章杨凡,储著增.基于多尺度特征拼接的小样本茶叶病害分类[J].安徽大学学报(自然科学版),2022,46(05):58-63.

[55] 易清明,吕人毅,石敏,骆爱文.融合多尺度空洞卷积与反卷积的轻量化目标检测[J].华南理工大学学报(自然科学版),2022,50(12):41-48.

中国知网 https://www.cnki.net

[56] 吴长旺. 融合注意力机制的图神经网络推荐算法研究[D]. 南京邮电大学,2022.DOI:10.27251/d.cnki.gnjdc.2022.000867.
[57] 王铃,陶宏才.基于LSTM前融合中文情感倾向分类模型的研究[J].成都信息工程大学学报,2020,35(02):139-145.DOI:10.16836/j.cnki.jcuit.2020.02.003.
[58] 范涛. 基于深度学习的图文融合的网民情感识别研究[D]. 南京理工大学,2020.DOI:10.27241/d.cnki.gnjgu.2020.000797.
[59] 刘琦,侯丽,彭章友.基于辨识特征后融合的行人再识别[J].计算机应用研究,2019,36(08):2552-2555.DOI:10.19734/j.issn.1001-3695.2018.02.0186.
[60] Swaminathan Bhuvaneswari,Palani Saravanan,Vairavasundaram Subramaniyaswamy. Feature fusion based deep neural collaborative filtering model for fertilizer prediction[J]. Expert Systems With Applications,2023,216.
[61] Gu Xiao,Zhao Haiping,Jian Ling. Sequence neural network for recommendation with multi-feature fusion[J]. Expert Systems With Applications,2022,210.
[62] Feng Weite,Liu Junrui,Li Tong,Yang Zhen,Wu Di. FAC: A Music Recommendation Model Based on Fusing Audio and Chord Features (115)[J]. International Journal of Software Engineering and Knowledge Engineering,2022,32(11n12).
[63] Fu Xiao,Jing Chen,Zhetao Li,Haiping Huang,Lijuan Sun. Improved LDA Dimension Reduction Based Behavior Learning with Commodity WiFi for Cyber-Physical Systems[J]. ACM Transactions on Cyber-Physical Systems,2019,3(4).
[64] Xuan WANG,Bofeng ZHANG,Mingqing HUANG,Furong CHANG,Zhuocheng ZHOU. Improved LDA Model for Credibility Evaluation of Online Product Reviews[J]. IEICE Transactions on Information and Systems,2019,E102.D(11).
[65] 龙艺璇,安源,王东晋,翟夏普,伊惠芳.基于改进LDA模型的铁路领域主题发现研究[J].数字图书馆论坛,2022(02):26-32.
[66] 冀振燕,皮怀雨,姚伟娜.融合多源异构数据的混合推荐模型[J].北京邮电大学学报,2019,42(01):126-132.DOI:10.13190/j.jbupt.2018-176.
[67] Yun Laiyan and Luo Zhenrong. Multisource Information Fusion Algorithm for Personalized Tourism Destination Recommendation[J]. Mathematical Problems in Engineering, 2022, 2022
[68] 陆航,师智斌,刘忠宝.融合用户兴趣和评分差异的协同过滤推荐算法[J].计算机工程与应用,2020,56(07):24-29.

中国知网 https://www.cnki.net