分　类　号：TP183　　单位代码：10192

研究生学号：202104191　　密　　级：公开

吉林化工学院
硕士学位论文
（专业学位）

基于大模型文本特征增强与融合的短视频广告推荐模型

A Short Video Advertisement Recommendation Model Based on Large Model Text Feature Enhancement and Fusion

作者姓名：蒋昕强

专　　业：电子信息

研究方向：人工智能技术及应用

指导教师：耿英楠 副教授

培养单位：吉林化工学院信息与控制工程学院

2024 年 6 月

中国知网 https://www.cnki.net

基于大模型文本特征增强与融合的短视频推荐模型

A Short Video Advertisement Recommendation Model Based on Large Model Text Feature Enhancement and Fusion

作者姓名：蒋昕强

专业名称：电子信息

指导教师：耿英楠 副教授

学位类别：电子信息硕士专业学位

答辩日期：2024 年 6 月 4 日

中国知网 https://www.cnki.net

摘要

近年来，短视频平台已经成为我国互联网领域中重要支柱性产业。与此同时，短视频广告不仅作为短视频平台商业营收的主要来源，还为广告商提供了高质量的投放渠道。因此，如何将短视频广告推送给感兴趣的用户，从而实现良好的营销效果成为一个重要的问题。短视频平台利用推荐算法技术可以有效改善广告的营销表现。传统推荐算法利用用户个人数据、历史行为数据以及物品交互记录等信息，分析用户兴趣和行为模式，向用户推荐感兴趣的物品。然而，当全新的短视频广告上传到平台中，由于缺乏历史行为数据和广告交互记录会导致传统推荐算法出现性能下降的情况。此外，传统推荐算法过于依赖用户个人数据以及历史行为数据，而使用这两种数据作为推荐算法输入可能会引发用户隐私安全问题。本文主要研究工作如下。

针对推荐算法中普遍存在的冷启动问题，本文以基于内容的推荐算法作为基础，提出了一种基于视听特征融合的短视频广告推荐模型。首先，该模型以短视频广告本身的图像特征序列和音频特征序列作为模型输入。然后，利用特征编码模块学习每种特征中的上下文信息和代表性信息，进一步增加特征向量的语义信息，并输出加权特征向量。接着，利用特征融合模块将两种不同的模态特征进行融合，构成融合加权特征向量，获得更全面、更综合的特征表达。最后，通过最终决策模块将融合加权特征向量转换成短视频广告相关性分数，根据相关性分数的大小构建推荐排序。

针对图像场景信息与文本内容不匹配的问题，本文设计一种基于文本相似度的过滤机制。首先，在本文中采用大模型来描述图像场景信息，并以文本的形式予以呈现。这种做法旨在利用大模型分析并理解图像场景内容的能力，并通过文本内容来丰富对图像内容的理解，进而提升模型对视频内容的整体理解。然而，文本内容却存在与图像场景信息不匹配的问题。因此，提出了上述的文本过滤机制，以过滤掉与图像场景信息不相符的文本内容。随后，将大模型文本信息融入到基于视听特征融合的短视频广告推荐模型中。实验表明，相比基于视听特征融合的短视频广告推荐模型，改进后的模型在推荐能力上有明显提高。

针对多模态特征信息不一致的问题，本文提出了一种基于门控机制的多模态融合方法。在大模型文本信息融入基线模型的过程中发现，采用直接拼接的多模态融合方法无法解决特征信息不一致问题。为了解决这个问题，提出了上述多模态融合方法。该融合方法的核

中国知网 https://www.cnki.net

心思想是将 Sigmoid 函数视作通道闸门，允许模型自主地控制每种模态特征的贡献程度。因此，根据不同模态信息的重要性，动态地调整每种模态特征的权重，以获得更有效、更具代表性的融合结果。实验结果表明，所提出的多模态融合方法可以有效提高模型推荐能力。

关键词：多模态融合，推荐系统，短视频广告，大语言模型，文本特征

中国知网 https://www.cnki.net

Abstract

In recent years, short video platforms have become an important pillar industry in China's Internet sector. At the same time, short video advertisements not only serve as the main source of commercial revenue for short video platforms, but also provide high-quality placement channels for advertisers. Therefore, how to push short video advertisements to interested users so as to realize good marketing effects has become an important issue. Short video platforms can effectively improve the marketing performance of ads by utilizing recommendation algorithm technology. Traditional recommendation algorithms use information such as users' personal data, historical behavioral data, and item interaction records to analyze users' interests and behavioral patterns and recommend items of interest to users. However, when brand-new short video ads are uploaded to the platform, the lack of historical behavioral data and ad interaction records can lead to performance degradation of traditional recommendation algorithms. In addition, traditional recommendation algorithms rely too much on users' personal data as well as historical behavioral data, and the use of these two kinds of data as input to recommendation algorithms may raise the issue of user privacy and security. The main research work of this thesis is as follows.

Aiming at the common cold-start problem in recommendation algorithms, this thesis proposes a short video advertisement recommendation model based on audio-visual feature fusion, using content-based recommendation algorithms as the basis. First, the model takes the image feature sequences and audio feature sequences of the short video advertisement itself as model inputs. Then, the feature encoding module is utilized to learn the contextual and representative information in each feature, further increase the semantic information of the feature vectors, and output the weighted feature vectors. Next, two different modal features are fused using the feature fusion module to form a fusion weighted feature vector to obtain a more comprehensive and integrated feature representation. Finally, the fusion-weighted feature vector is converted into a short video ad relevance score by the final decision module, and a recommendation ranking is constructed based on the size of the relevance score. The above model will be used as a baseline model, and according to experiments, the model has good performance in the short video advertisement recommendation task.

中国知网 https://www.cnki.net

Aiming at the problem of mismatch between image scene information and text content, this thesis designs a filtering mechanism based on text similarity. First, in this thesis, a big model is used to describe the image scene information and present it in the form of text. This approach aims to utilize the ability of the big model to analyze and understand the image scene content, and enrich the understanding of the image content through the text content, which in turn improves the model's overall understanding of the video content. However, the text content suffers from the problem of mismatch with the image scene information. Therefore, the text filtering mechanism described above is proposed to filter out text content that does not match the image scene information. Subsequently, the large model text information is incorporated into a short video advertisement recommendation model based on audiovisual feature fusion. Experiments show that compared with the short video advertisement recommendation model based on audiovisual feature fusion, the improved model has a significant improvement in recommendation capability.

Aiming at the problem of inconsistent multimodal feature information, this thesis proposes a multimodal fusion method based on the gating mechanism. In the process of incorporating large model text information into the baseline model, it is found that the multimodal fusion method using direct splicing cannot solve the problem of inconsistent feature information. To solve this problem, the above multimodal fusion method is proposed. The core idea of this fusion method is to regard the Sigmoid function as a channel gate, allowing the model to autonomously control the degree of contribution of each modal feature. As a result, the weight of each modal feature is dynamically adjusted according to the importance of different modal information to obtain more effective and representative fusion results. Experimental results show that the proposed multimodal fusion method can effectively improve the model recommendation capability.

Key words： Multimodal fusion, Recommender systems, Short video ads, Large language models, Text features

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 本文的研究内容以及创新点.....3
1.2.1 研究内容.....3
1.2.2 创新点.....3
1.3 本文组织结构.....4
1.4 本章小结.....5
第 2 章 相关技术研究.....6
2.1 推荐算法研究.....6
2.1.1 推荐算法概述.....6
2.1.2 推荐算法国内外研究现状.....8
2.2 视频推荐算法研究.....9
2.2.1 视频推荐算法概述.....9
2.2.2 视频推荐算法国内外研究现状.....10
2.3 推荐算法与视频推荐算法共同存在的问题.....11
2.4 本章小结.....12
第 3 章 基于大模型文本特征增强与融合的短视频广告推荐模型设计.....13
3.1 基于视听特征融合的短视频广告推荐模型(SVARM)设计.....13
3.1.1 特征编码模块(Encoder Module).....14
3.1.2 特征融合模块(Fusion Module).....21
3.1.3 最终决策模块(Decision Module).....22
3.2 基于大模型文本特征增强与融合的短视频广告推荐模型(TFE-SVARM)设计.....23
3.2.1 文本特征编码模块.....23
3.2.2 门控机制特征融合模块.....24
3.3 本章总结.....25
第 4 章 数据处理与实验分析.....26
4.1 数据集和评价指标.....26
4.1.1 数据集.....26
4.1.2 评价指标.....27
4.2 多模态特征提取.....31
4.2.1 图像特征提取.....31
4.2.2 音频特征提取.....32

中国知网 https://www.cnki.net

4.2.3 文本特征提取.....33
4.3 实验平台设置.....36
4.4 模型训练——RankNet 算法.....36
4.4.1 排序学习(Learning to rank,LTR).....36
4.4.2 RankNet 算法介绍.....37
4.4.3 具体实现.....41
4.5 实验设置与结果分析.....43
4.5.1 实验参数设置.....43
4.5.2 实验一:模型设置对比实验.....44
4.5.3 实验二:模态消融实验.....45
4.5.4 实验三:多模态融合策略对比实验.....47
4.6 本章小结.....48
第 5 章 研究总结与未来展望.....49
5.1 研究总结.....49
5.2 未来展望.....50
参考文献.....51

中国知网 https://www.cnki.net

第 1 章 绪论

在如今的大数据信息时代背景下，短视频俨然成为大众获取信息来源最主要的方式之一。短视频凭借简洁直观的视频形式、丰富广泛的视频内容以及“短平快”的传播优势，成为主流的信息载体。通过浏览短视频，用户能够迅速获取当下最热门的信息内容、了解最新的网络动态，并作为“碎片化”时间休闲娱乐的主要方式。随着短视频在电商、教育、娱乐等领域不断深入，其应用前景十分广泛，并且为我国数字化信息时代开拓了有利的发展前景。

1.1 研究背景及意义

随着，移动互联网的高速发展以及智能移动设备的普及，短视频平台成为我国网民捕获信息、学习知识和休闲娱乐最主要的途径之一，也是广大互联网用户获取新闻资讯的主要渠道之一[1]。短视频平台是指网络用户拍摄时长在 15 秒~3 分钟以内的视频，并加以美化编辑。通过互联网上传，供平台其他用户观看、评论和分享的互联网在线平台。目前，短视频平台涵盖影视表演、商业推广、潮流时尚、社会热点、在线购物、宠物医疗等领域。这些领域满足了每个人生活的基本需求，因此短视频平台能够吸引海量的平台用户，并且这些用户深度参与短视频内容的创作。根据中国互联网络信息中心发布的第 52 次《中国互联网发展状况统计报告》，截至 2023 年 6 月，网络视频用户规模为 10.44 亿人，相较于 2022 年 12 月增长 1380 万人，占整体网民 96.8%。其中，短视频用户规模为 10.26 亿人，相较于 2022 年 12 月增长 1454 万人，占整体网民 95.2%。并且，整体网民的人均单日使用短视频应用时长超过 2.5 小时，而整体网民的人均单日互联网应用使用时长达 5.5 小时，短视频应用远高于其他互联网应用的使用时长。这表明短视频产业在我国互联网领域成为其他产业难以企及的流量屋脊和时间黑洞，并且在未来几年内，预计短视频内容产业和平台会依旧保持高速增长的势头，持续稳固互联网领域的霸主地位。

目前，我国短视频行业收入来源大致分成四个部分：商业广告、电商佣金、直播分成和网络游戏，其中商业广告是短视频行业的主要收入来源。具体而言，商业广告营收能够细化成三种广告营收，分别是：品牌宣传广告、应用开屏广告和用户互动广告。随着平台用户规模不断扩大和粘性持续增长，商业广告营收作为短视频行业崛起的经济引擎，短视频广告市场规模持续扩大。据不完全统计，从 2019 年至 2022 年我国短视频广告市场规模从 497.5 亿元增长到 2548.7 亿元。并且，在整个移动互联网广告行业中，短视频广告的占

中国知网 https://www.cnki.net

比份额将继续稳步上升。由此可见，短视频广告在我国短视频行业中具有重要的战略意义。具体而言，短视频广告不仅仅是平台营收的主要来源，同时也兼顾品牌宣发、产品销售和用户参与的主要渠道。因此，广告商、品牌商和短视频平台会继续加大广告资金的投入，不断创新广告形式、丰富广告内容，从而最大程度地满足行业和用户需求，共同推进短视频广告行业蓬勃发展。

随着短视频广告行业规模不断扩大，可供用户浏览的广告内容也随之增加。然而，在众多广告内容中，用户更希望能够浏览到符合自己兴趣的营销内容。因此，利用推荐算法来提升短视频广告的推送效率，从而提高用户在浏览过程中的视听体验[2]。传统推荐算法通常根据用户个人的信息数据，例如：性别、年龄、浏览时长、点赞和视频评论等数据来实现个性化推荐[3,4]。尽管上述推荐算法具有个性化的推荐能力，能够为用户提供相对准确的推荐结果。但是，在面对短视频平台中庞大的广告视频数量以及海量的用户个人数据，传统推荐算法的推荐能力却显得十分有限。具体而言，传统推荐算法在处理如此规模的数据量会面临诸多挑战，包括推荐结果准确性下降，推荐系统响应速度变慢等问题。然而，这些问题阻碍了传统推荐算法在短视频广告推荐领域的表现，同样也给短视频广告推荐算法的研究带来了严峻的挑战[5]。

为了解决上述问题，相关学者一直致力于探究适用于短视频行业的推荐算法，这些推荐算法通过深入分析用户以往的行为习惯、短视频自身的特性以及短视频内容的特点等多种方面，为用户提供更为精准的短视频推送服务[6]。尽管这些研究工作在一定程度上提升了用户的视听体验，并且这些推荐算法也在短视频行业得到了充分的利用，但是依然存在一些痛点问题和不足没有解决，主要囊括以下几个部分：

1. 推荐系统冷启动问题：该问题是指当新物品加入或新用户注册加入推荐系统中，由于缺乏物品交互记录和用户历史行为数据，导致推荐算法无法提供精准的推荐结果[7]，并且这一问题在传统推荐算法中普遍存在。
2. 用户个人数据隐私问题：将用户的私人数据作为推荐算法的输入，这个行为本身就会带来严重的风险问题。此风险问题涉及私人数据的所有权、控制权和访问权的归属问题、数据使用方对私人数据的收集范围问题以及如何确保合法使用私人数据的问题等。如果这些问题得不到解决，极有可能导致私人数据隐私泄露和信息滥用的情况[8,9]。
3. 忽略多模态信息问题：传统推荐系统更加强调的是充分利用用户个人数据、历史

中国知网 https://www.cnki.net

行为数据以及物品交互记录数据，而忽视了短视频广告中多模态信息的重要性[10]。

为了解决上述三个问题， 在研究工作中提出了一种短视频广告推荐的多模态框架，即基于大模型文本特征增强与融合的短视频广告推荐模型。该模型仅使用广告自身的特征信息作为输入数据，而不需要用户个人数据和物品交互记录。此外，该模型充分利用短视频广告中多种模态信息，包含图像信息、音频信息和文本信息，使得该模型能够更全面地理解广告内容。提供更加准确的推荐结果。

1.2 本文的研究内容以及创新点

1.2.1 研究内容

本文主要以挖掘图像场景信息和多模态融合方法作为主要研究内容，以短视频广告作为研究对象、基于内容的推荐算法作为研究基础，设计了一种基于大模型文本特征增强与融合的短视频广告推荐系统。本文研究内容归纳为以下几点：

1. 图像场景信息通常是指图像中所展现的场景内容，包括位置关系、背景环境、人物情绪以及运动状态等信息，这些信息能够有效帮助模型提高对图像内容的理解程度。由于视频由一帧帧图像构成，所以充分利用每帧图像场景信息的内容，可以提高模型对整体视频内容的理解。因此，将如何挖掘图像场景信息作为首要研究内容。
2. 单一模态信息描述事物会存在一定的局限性，而多种模态信息的融合能够给出更加丰富和全面的描述。但是，在模型中采用何种多模态融合方法是一个关键的研究内容，对不同的融合方式进行详细分析，包括这些方法的优点和缺点。为了提升模型的推荐效果，提出了一种门控机制的多模态融合方法。
3. 本文对基于内容的推荐系统的发展历程和研究近况进行深入分析，并总结了目前有关研究存在的缺陷问题和技术短板。在这一总结基础上，提出了文本设计的模型框架。

1.2.2 创新点

在本研究工作中，研究创新方面可以总结为以下三点：

1. 为了解决传统图像特征中图像场景特征不足的问题，提出利用大模型生成以描述图像场景为主题的文字。通过添加文字信息，可以更丰富地表达图像信息，从而

中国知网 https://www.cnki.net

弥补传统图像特征的不足。此外，还设计了一种文本过滤机制，以过滤掉与图像场景不相符的文本内容。

2. 为了解决多模态特征不一致的问题，本文提出了一种基于门控机制的多模态融合策略，以体现模型使用多模态信息的优势。
3. 根据目前的了解，本文首次尝试在短视频广告领域中应用大模型文本，本研究工作也为设计短视频广告推荐模型提供了新的思路和方法。

1.3 本文组织结构

本文共有五个章节组成，每个章节的主要内容如下：

第 1 章，绪论。在本章节中，主要阐述短视频行业和短视频广告的研究背景和意义。然而，通过分析短视频广告推荐领域的技术需求和传统推荐系统的技术特点，结合目前的发展现状，发现传统推荐系统并不适用于短视频广告推荐领域。依据这个问题明确了本文的研究内容以及提出了创新点。

第 2 章，相关技术研究。在这一章节中，主要探讨了在本研究工作中涉及的相关技术研究，分成两个方面：推荐系统研究以及视频推荐系统研究。此外，对每种技术研究的代表算法进行详细分析，并总结了不同代表算法的技术特点。

第 3 章，基于大模型文本特征增强与融合的短视频广告推荐模型设计。针对短视频广告推荐领域的技术需求和传统推荐系统的技术顽疾，本文提出了一种基于大模型文本特征增强与融合的短视频广告推荐模型。该模型以短视频广告所包含的特征信息作为输入，从而避免了由于使用用户隐私数据所引发的数据安全问题，还有效解决了传统推荐系统不可避免的冷启动问题。此外，利用大模型文本信息来增强图像场景信息，并单独设计了一种基于门控机制的多模态融合策略，以充分发挥文本信息的作用，进而提高模型推荐结果的准确性。

第 4 章，数据处理与实验分析。本章详细讲述了在本研究工作中所使用语料库的详细参数、获取图像特征、音频特征和文本特征的具体流程，并强调了具体流程中的注意事项。此外，通过多个消融实验证明了本文提出的推荐模型具有较高的推荐能力，为短视频广告推荐领域进一步探索提供了思路。

第 5 章，研究总结与未来展望。总结了本文的研究工作和研究成果，并分析了目前研究成果中的不足之处，并对今后的研究工作进行展望。

中国知网 https://www.cnki.net

1.4 本章小结

本章首先对研究背景以及意义进行表述，介绍了短视频行业以及短视频广告对我国国民娱乐和互联网经济推动的重要作用，还探讨了推荐算法在短视频广告行业的作用。与此同时，对目前推荐算法存在的痛点问题进行分析。接着，针对这些痛点问题提出了本文的研究工作，并详细列举了多个研究内容和创新点。最后，介绍了本文组织结构，并对每个章节的主要内容进行概述。下一章将对本文所涉及的技术研究进行详细阐述。

中国知网 https://www.cnki.net

第 2 章 相关技术研究

本章将介绍与本研究工作相关的技术研究，分别是：推荐算法研究和视频推荐算法研究。主要介绍这两种技术的基本概念和基础知识，并结合国内外研究文献，重点阐述并分析这两种技术的研究现状以及面临的问题。

2.1 推荐算法研究

2.1.1 推荐算法概述

推荐算法本质上是一种信息过滤算法，其主要功能是帮助用户减少在浏览无效内容上浪费时间和精力，以达到提升用户体验、提高信息获取效率的目的[11]。一般情况下，推荐算法依赖用户个人数据、历史信息和行为偏好等信息，从大量可选项中构建推荐列表。然后，根据推荐列表为用户提供符合其兴趣的推荐内容或物品，从而实现推荐算法的功能。

如果以推荐机制为规则划分，推荐算法可以分成三种类型：基于内容的推荐算法(Content-based Recommendation、CB)[12]、基于协同过滤的推荐算法 (Collaborative Filtering Recommendation、CF)以及混合推荐算法(Hybrid Recommender、HR)[13]。以下是对着三种推荐算法的概述：

1. 基于内容的推荐算法：这是一种建立在物品内容信息上的推荐算法。这里所提到的内容信息包括物品属性信息（如 Metadata 信息、标签、图像、文本等）和用户个人行为偏好信息（如评论、点赞、收藏、浏览时长等）。其核心思想依据用户行为偏好特征和物品属性特征的相似度进行推荐。具体地，对物品属性特征进行计算以确定物品间的相似程度，并相似度与用户行为偏好特征相匹配，以此向用户推荐相似度较高的物品[14]。该算法的优点包括：其一，数据依赖性低：只需要内容信息就能够实现物品推荐。其二，应用阶段广泛：可以在推荐系统的任意阶段使用，不存在物品冷启动问题。其三、用户独立性：用户之间相互独立，无论其他用户对同一个物品如何评价（例如，部分用户有恶意刷榜等特殊行为）都不会影响推荐结果。然而，该算法也存在一定缺点：其一、特征提取难度较高：从物品中抽取出准确的特征信息是一项严峻的挑战。其二、无法挖掘用户的潜在兴趣：该算法只会根据用户过去喜好推荐相似的物品，无法判断用户当前对此类物品是否感兴趣。

中国知网 https://www.cnki.net

2. 基于协同过滤的推荐算法：这是一种完全依赖用户和物品之间历史行为记录的推荐算法。其核心思想是根据整个用户群对物品的评价和反馈，筛选出具有相似喜好的用户或物品。此外，这种算法能够进行有效推荐的前提是用户群可以按照相似喜好进行类聚，即不同的用户具有相似的行为，那么他们的需求和偏好也存在一定的相似性。具体地，该算法主要分析用户对物品的交互信息（如点击、打分、评论等），计算出用户之间的相似度或物品之间的相似度。根据该相似度，能够找出具有相似喜好用户或相似的物品。然后，根据找出的用户或物品，来预测目标用户对新物品的喜好程度。最后，根据喜好程度对目标用户进行推荐。协同过滤算法主要分成基于物品的协同过滤算法[15]和基于用户的协同过滤算法[16]。该算法最大的优点是对推荐物品没有特殊限制，能够处理非结构化的混杂物品（如音乐、电影、艺术品等）。然而，该算法也存在一些缺陷问题：首先，冷启动问题：在系统建立之初，由于没有足够的交互信息，协同过滤算法不能为目标用户找到喜好相似的用户，因此无法向目标用户提供推荐结果。其次，冷门物品推荐困难：如果在推荐系统中存在一些小众或冷门的物品，而这些物品没有任何交互记录，那么它们是不可能推荐给用户的。并且，推荐系统中新加入的物品也存在同样的问题。最后，数据稀疏问题：在实际应用中，大多数用户只与少量物品存在交互记录，因此很难找到数量充足的相似用户和物品进行有效推荐。
3. 混合推荐算法：这是一种将不同技术的推荐算法结合起来的推荐算法。其核心思想是构建一种组合算法，既能够发挥不同推荐算法的优点，还能够弥补单一推荐算法的技术缺陷。在实际应用中，最常见的混合推荐算法是将基于内容的推荐算法与基于协同过滤的推荐算法相组合。该算法的优点在于：首先，综合利用不同的推荐算法，提高推荐结果的准确性。其次，提供更加灵活且丰富化的推荐算法，能够根据实际应用情况动态调整。然而，该算法也存在一些缺点：首先，算法实现的复杂度较高，需要设计有效的混合策略将不同的推荐算法的优势发挥出来。其次，相比单一的推荐算法，混合推荐算法需要更多的时间成本和训练资源，尤其是采用大规模数据集进行训练时。最后，混合推荐算法需要调试的参数数量和参数调试过程也相对复杂，需要更多的对比实验和测试结果来确定推荐性能最佳的混合策略。

中国知网 https://www.cnki.net

2.1.2 推荐算法国内外研究现状

如今，推荐算法俨然成为国内外研究的重要领域之一，特别是随着移动互联网的迅猛发展。在发展过程中伴随着信息量不断增加，用户需要更加便捷和高效地筛选信息。推荐算法能够有效地过滤掉无用信息，为用户找出感兴趣、个性化的信息或内容。此外，推荐算法还能够在改善用户使用体验、提高品牌商业价值以及提升信息检索效率等方面发挥重要作用。目前，研究工作者们专注于提升推荐算法的性能、准确率和使用广泛性，以便将该算法应用到不同领域。因此，它们广泛且深入地探索了不同技术特点的推荐算法进行推荐。

首先，回顾以往研究工作者所提出的推荐算法，并总结了这些推荐算法的优点。同时，这些出色的研究内容也为本文明确了研究思路。在以往的研究工作中，传统的推荐算法主要依赖于用户个人数据和行为数作。Ebesu 等人针对协同过滤推荐算法中忽略了邻域或注意力机制作用的问题，提出了一种 Collaborative Memory Networks(CMN)。该网络将记忆组件与神经注意力机制相结合，以学习用户-项目特定的领域。最终，输出模块利用邻域与用户和项目的记忆，构建项目排名。并且，在三个公开数据集上验证了 CMN 的效果优于其他模型[17]。Wu 等人针对现有的序列推荐算法大多偏向于序列之间的装换结构，忽略了时间顺序和上下文信息对预测结果影响的问题，提出了一种上下文时间注意力机制，该机制用来学习历史行为对当前行为的影响程度，不仅分析了具体行为是什么，还要分析行为发生的时间和方式，通过利用时间顺序和行为数据提升了模型的推荐能力[18]。Li 等人针对用户或物品存在多个特征或属性，而传统推荐方法将用户或物品与单个子群相关联不合理的问题，提出了一种 Soft K-indicators Alternative Projection(SKAP)算法。该算法能够有效处理高维数据，生成稀疏的分区矩阵，利用分区矩阵生成一个 TOP-k 推荐列表[19]。Sharma 等人针对电子商务网络推荐系统中普遍存在的产品过载问题，提出了一种基于协同过滤和内容过滤的混合推荐系统。该系统分成三个阶段：第一阶段是寻找与活跃用户相似的用户；第二阶段是为每个相似用户选择推荐候选项；第三阶段使用 Resnick 方程计算每个推荐候选项的预测值，根据预测值确定候选项并向目标用户进行推荐[20]。Forouzandeh 等人指出推荐算法在旅游行业中的广泛应用，尤其是游客决策的重要性。因此，提出了一种结合人工蜂群 ABC 算法和模糊 TOPSIS 的旅游业推荐系统。实验表明，这种推荐算法能够有效缩短实施时间，并使得推荐建议更加准确[21]。

其次，当新用户或新物品加入推荐系统中，由于缺乏行为数据和交互记录会导致推荐

中国知网 https://www.cnki.net

结果准确率下降的问题。因此，针对推荐算法中普遍存在的冷启动问题，相关研究者设计了多种策略来应对这一挑战。Zhao 等人针对跨领域推荐中如何有效地将用户的偏好从一个领域转移到另一个相关领域的问题，提出了一个名为 CATN 的跨领域推荐框架。首先，该框架以基于评论的推荐算法作为基础，利用评论文档从中提取每个用户和每个项目的多个方面，并使用注意力机制学习跨领域方面的相关性。此外，该框架还利用偏好相似用户的评论来增强目标用户的表示。最后，作者采用端到端的训练方式增强框架的鲁棒性[22]。Chen 等人指出推荐物品和推荐物品候选项的生成在个性化推荐中是十分基本且重要的过程，可以更有效地帮助用户找出合适的物品。然而，现有的方法只是将这一问题看作如何挖掘相似物品直接的关系，却忽略了用户的个人偏好。此外，物品之间的可替代关系是通过潜在特征来表示的，导致推荐结果解释性较差。针对上述问题，作者提出了属性感知协同过滤算法(A2CF)。该算法通过情感分析从用户评论中提取明确的、清晰的物品属性，并同时学习物品属性、用户和物品的特征。然后，将物品属性看作用户和物品之间的联系，从而对用户-项目的个性化推荐以及物品-物品的替代关系进行建模，进而实现个性化推荐[23]。Feng 等人针对用户历史行为数据稀少时，导致推荐系统性能不佳的问题，即新用户冷启动问题，提出了一种新颖的协同过滤推荐模型。该模型将基于评分的概率矩阵分解(PMF)方法和基于成对排名的贝叶斯个性排名(BRP)方法相结合，进而提高处理稀疏数据的能力，并解决新用户冷启动问题[24]。Wang 等人针对协同过滤推荐算法中冷启动物品的特征表示与协同过滤信号无法对齐的问题，提出了一种等变量学习框架。该框架通过三种对齐损失来调节插值特征表示，以实现插值特征和协同过滤信号的等变对齐。并且在三个数据集上验证了该框架具有改善物品冷启动推荐的作用[25]。阎红灿等人提出了一种基于模糊聚类的协同过滤推荐算法，用来解决新用户的冷启动问题。具体地，通过对新用户拥有的少量评分数据进行预处理，并利用 SMOTE 过采样技术填充数据，已解决数据量过少的问题。此外，该算法还利用模糊聚类和时间因子对评分数据进行分类和预测，以提高推荐效果[26]。

2.2 视频推荐算法研究

2.2.1 视频推荐算法概述

视频推荐算法是指通过智能算法，根据用户的历史观看记录、视频类型等数据，将符合用户兴趣和需求的视频推荐给用户的过程。在这个过程中，视频平台会通过人工审核、标签分类以及用户反馈等方式来提高推荐结果的准确性、多样性以及良好的视听体验。

中国知网 https://www.cnki.net

目前主流的视频推荐算法分成三种类型，包括：内容相似度算法、个性化推荐算法和深度学习算法。以下是对这三种算法原理的具体阐述：

1. 内容相似度算法：这类算法的核心思想是根据视频的文本描述、标签、关键词等信息，计算推荐视频与用户已观看视频之间的相似度，并将相似度较高的视频推荐给用户。这类算法适用于找出与用户已知兴趣相符的新内容，但是推荐结果较为单一，无法满足用户多样化的推荐需求。
2. 个性化推荐算法：这类算法的核心思想是根据用户的历史行为数据，如观看记录、视频评论、视频收藏等信息，对用户兴趣进行建模。这类算法能够为每个用户定制推荐内容，满足用户不同类型的视频需求。但是，这类算法存在信息茧房问题，即只能推荐与以往兴趣相符的内容，而忽略了用户的潜在兴趣或用户的兴趣发生变化。
3. 深度学习算法：这类算法的核心思想是利用深度神经网络模型对用户行为数据和视频内容进行建模的算法。相比与前两类视频推荐算法，此类推荐算法能够学到更为抽象的用户兴趣特征和视频内容特征，所以能够给出更加精准的推荐结果。

2.2.2 视频推荐算法国内外研究现状

鉴于本文的研究对象是以短视频的形成呈现，所以本文格外关注以视频为推荐内容的推荐算法。在这方面，Zhang 等人指出目前短视频推荐系统简单地将观看时长作为直接标签，忽略了其他丰富的语义信息，从而限制了以基于观看时长的用户兴趣模型的潜力。针对这一问题，作者提出了一个名为 Debiased Multiple-semantics-extracting Labeling(DML)框架。该框架利用观看时长的分位数来构建不同的语义标签，并优先考虑相对顺序而非绝对顺序。这种方法更有助于模型的学习。此外，该框架还引入一种受因果调整启发的方法来完善语义标签，从而减少标签层面的偏差[27]。Patil 等人指出目前基于多模态数据的算法被应用于众多推荐项目中，但这些推荐算法往往忽略了用户对不同模态信息的偏好程度，也未能对多模态数据的内在关系进行深入分析。为此，作者等人提出了一种用于微视频推荐的双感知多分辨率图神经网络(DP-MRGNN)框架。该框架利用用户-微视频双向图和用户共生图，共同识别每个用户的多模态融合方式。此外，该框架还设计了一种多模态表征学习模块，用来模拟用户对不同模态特征的注意力，并总结学习用户对多模态信息的偏好[28]。Cai 等人指出目前基于 GNN 的推荐算法在微视频推荐任务中发挥出了良好的性能，但是这

中国知网 https://www.cnki.net

些算法只含有一种类型节点或关系的同构图，无法将用户、微视频和多模态信息组成异构图。针对这一问题，该作者提出了一种用于个性化微视频推荐的新型异构分层特征聚合网络(HHFAN)。该模型在数据结构层面，构建了一个异构图，利用基于随机漫步的采样策略对用户和微视频的邻居进行采样。在特征学习层面，设计了一个分层特征聚合网络，其优点是更加充分地捕捉异构图中的复杂结构和丰富语义信息[29]。Liu 等人指出目前短视频平台具有流量大、视频寿命短和流媒体丰富的特点，而现有的推荐系统并不适用短视频的推荐任务。为了解决这个挑战，作者提出了一种面向短视频推荐的概念感知去噪图神经网络(CONDE)。该模型共分成三个部分来提取用户与短视频之间的特征表示：预热传播、图去噪和用户偏好细化。通过连接用户节点和视频节点，以及视频节点和从视频字幕和评论中提取的相关感念节点相连接，构成一个异构三方图。此外，为了去除图像中的噪声信息，该框架还引入了一个面向用户的图去噪阶段，用来提取一个能够表达用户偏好的子图[30]。Lei 等人指出现有的短视频推荐系统更关注用户对短视频是否浏览的行为，却忽略了用户在电子商务环境下对商品的购买意愿，导致了电子商务短视频推荐效果不佳的问题。针对这一问题，作者提出了一种顺序多模态信息传递网络(SEMI)，利用产品领域的用户行为来辅助短视频推荐。该模型能够有效选择短视频领域与产品领域多模态特征匹配的相关项，从而确定用户的偏好特征。为了模拟用户在两个不同领域的行为，作者还设计了一种跨领域对比学习算法，用以描述用户行为，从而缩小短视频领域和产品领域之间的行为模式差距。实验结果表明，作者所提出算法的性能要明显由于其他先进的推荐算法，并且，所提出的算法已经部署在电商平台中，进一步证明该算法的实际价值[31]。

2.3 推荐算法与视频推荐算法共同存在的问题

根据以往的研究工作，总结了目前推荐系统在现实应用中存在的模型问题和技术短板，主要涉及以下几个方面：

1. 用户行为数据不足：在实际应用中，用户只对推荐系统中少数物品进行了评价或互动，而绝大多数的物品并没有足够且明确的用户评价。这使得推荐系统在分析用户潜在兴趣和行为时，存在行为数据不足导致推荐效果不佳的问题。
2. 冷启动问题：对于推荐系统中新注册的用户或新加入的物品，由于没有用户历史行为数据和物品交互记录，使得推荐系统无法为新用户推荐符合其兴趣的物品，同样也无法将新物品推荐给合适用户。

中国知网 https://www.cnki.net

3. 个人数据安全问题：过往的推荐系统更加侧重于利用行为数据从用户的角度对推荐系统进行建模，而忽略了物品本身所包含多模态信息的重要性。此外，上述文献中所提出的方法都需要使用用户个人数据作模型输入，然而这些方法大都没有提出或设计用于保护用户个人数据安全的策略。这种模型设计缺陷很有可能引发数据安全问题。

2.4 本章小结

本章首先对推荐算法的定义以及三种不同类型的推荐算法进行介绍，并详细分析了每种推荐算法具有的技术优点和缺点。此外，还详细介绍了推荐算在国内外研究现状。其次，介绍了视频推荐算法的定义以及相应的国内外研究现状。最后，总结了目前推荐系统以及视频推荐系统存在的共同问题。针对这些问题提出了基于视听特征融合的短视频广告推荐模型，并通过实验证明了模型的有效性。这些内容为本文的研究工作提供了详尽的理论基础。下一章将对基于大模型文本特征增强与融合的短视频广告推荐模型设计进行详细表述。

中国知网 https://www.cnki.net

第 3 章 基于大模型文本特征增强与融合的短视频广告推荐模型设计

本章由“基于视听特征融合的短视频广告推荐模型设计”、“基于大模型文本特征增强与融合的短视频广告推荐模型设计”和“本章小结”，三部分内容构成。第一部分和第二部分详细介绍了模型中每个模块结构、原理和作用进行细致描述与深入分析。第三部分是对本章内容的总结。

3.1 基于视听特征融合的短视频广告推荐模型(SVARM)设计

SVARM 模型结构如图 3.1 所示，模型整体包含三个模块，分别是：特征编码模块(Encoder Module)、特征融合模块(Fusion Module)以及最终决策模块(Decision Module)。以下是对每个模块功能的简要介绍：

1. 特征编码模块(Encoder Module)：原始的特征输入具有高维度、语义性单一的缺点。通过特征编码模块的处理，首先能够有效降低输入特征的维度，进而减少模型计算和特征存储的资源开销。其次，该模块能够消除原始数据特征中存在的噪声和冗余信息，并提炼出语义性更丰富、代表性更强的特征表示。最后，这些特征表示有助于提高模型的性能。
2. 特征融合模块(Fusion Module)：在本研究中，所提出的模型将同时处理图像、音频和文本，这三种不同模态信息。为了获得语义信息更全面的特征表示，设计一个特征融合模块就显得十分必要。特征融合模块的作用是将来自不同模态的特征进行整合与融合，获取更全面、更具体的特征表示，进而提高整体模型的泛化能力和鲁棒性。
3. 最终决策模块(Decision Module)：该模块主要作用是将融合后的特征表示转换为最终决策结果。最终决策模块是由多个全连接层构成的，并且每层全连接层所包含的神经元数量依次递减，通过逐渐减少的神经元数量，可以逐渐减少该模块输入特征的维度。最终，该模块输出一个一维的数值，该数值将作为构建推荐预测排序的依据。在本研究中，将该数值定义为推荐样本的相关性得分，此得分体现了模型对不同样本推荐顺序的预测，其数值大小反映了模型对不同样本推荐程度的评估。因此，得分越高的样本则表明模型认为该样本拥有更高的推荐排名，更值

中国知网 https://www.cnki.net

得推荐，这也直接影响了推荐预测结果的准确性。

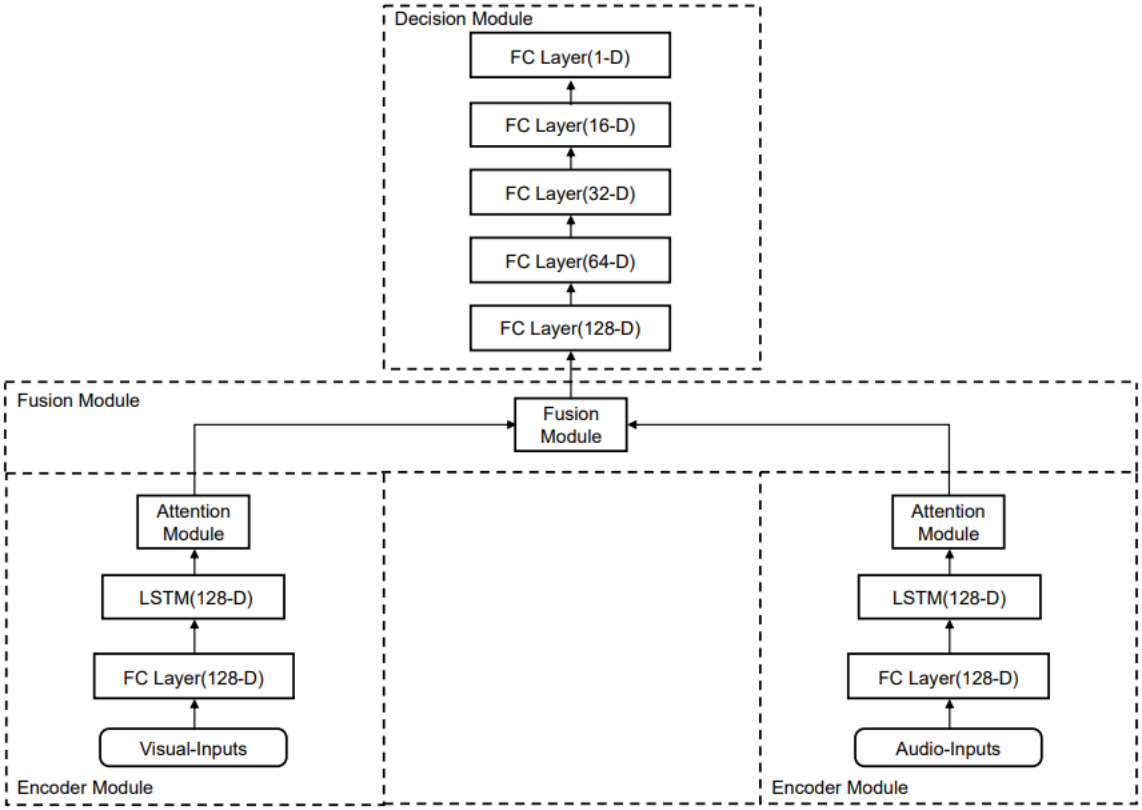

图 3.1 SVARM 结构图

3.1.1 特征编码模块(Encoder Module)

特征编码模块结构如图 3.2 所示，整个模块由三个部分构成：特征输入层、LSTM 层和特征注意力模块。以下是对这三个部分具体描述。

特征输入层：该层用来处理不同模态输入的特征序列。具体来讲，该层由单个全连接层构成，并且全连接层共有 128 个神经元。全连接层的结构是将前一层的所有神经元与当前层的每一个神经元进行连接。在全连接层中，每个神经元的输出值都是由前一层所有神经元的输入值与对应的权重值加权求和得到的，但是参与求和的权重值并不相同。因此，获取合适的权重值就显得十分必要。模型可以通过反向传播算法对权重值进行更新，在训练过程中根据数据不断调整权重值的大小。通过优化损失函数来确定合适的权重值，使得模型能够更好地适应数据，提高模型预测能力。

在本小节中，以三个神经元构成的全连接层为例，详细分析全连接层的计算过程。具体计算过程如公式(3.1)所示，式中$ai(i = 1,2,3)$表示全连接层有三个神经元；$xi(i = 1,2,3)$表示全连接层的输入；$W_{ij}(i = 1,2,3\ j = 1,2,3)$表示全连接层中可学习的参数；$b_i(i = 1,2,3)$

中国知网 https://www.cnki.net

表示每个神经元对应的偏置项。

$$a1 = W_{11} * x1 + W_{12} * x2 + W_{13} * x3 + b_1$$
$$a2 = W_{21} * x1 + W_{22} * x2 + W_{23} * x3 + b_2 \tag{3.1}$$
$$a3 = W_{31} * x1 + W_{32} * x2 + W_{33} * x3 + b_3$$

通过式 3.1 不难看出，全连接层的计算过程本质上是一个线性变化。而这种线性变换具有两种不可忽视的缺点：

1. 多个线性变化的组合将会等同于单个线性变换，进而使得多个全连接层的组合失去意义。
2. 式(3.1)本质上仍是线性计算，这使得模型只能够学习线性变化，限制了模型的表达能力。

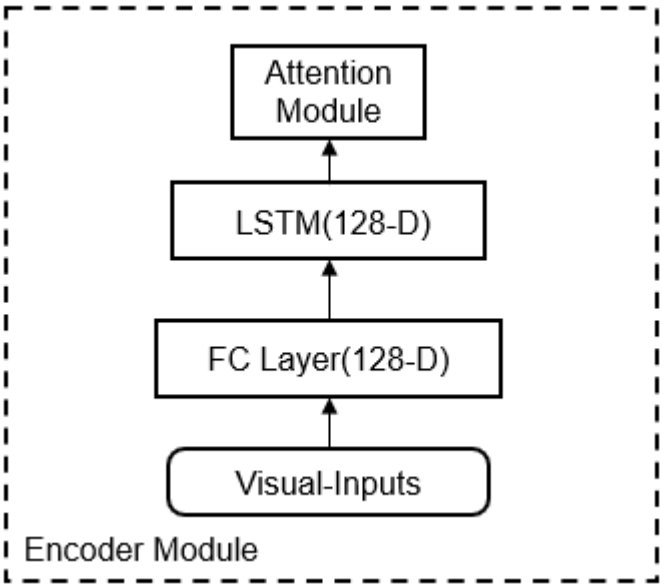

图 3.2 特征编码模块结构图

为了消除线性变化对模型产生的影响，在使用全连接层需要引入非线性变换。通常的做法是将激活函数与全连接层组合使用。因为激活函数具有非线性的特性，所以模型有能力学习更为复杂的函数关系。从而提高模型的表达能力，更好的拟合数据。常用的激活函数有以下三种：

1. Sigmoid 激活函数[32]：该函数图像如图 3.3 所示，计算过程如式(3.2)，导函数如式(3.3)。其优点在于，非常适合用于预测概率作为输出的模型。比如用于表示二分类任务或者模型输出值表示置信度的任务。其缺点在于，该函数的导数最大值只

中国知网 https://www.cnki.net

有 0.25，并且 x 在[-5,5]区间外所对应的导数值接近于零。这种情况会使得神经元处在饱和状态，在反向传播时参数值不能得到有效地更新，从而使得模型训练变得困难。这种现象也被称为梯度消失问题。

$$f(x) = \frac{1}{1+e^{-x}} \tag{3.2}$$

$$f'(x) = \frac{e^{-x}}{(1+e^{-x})^2} \tag{3.3}$$

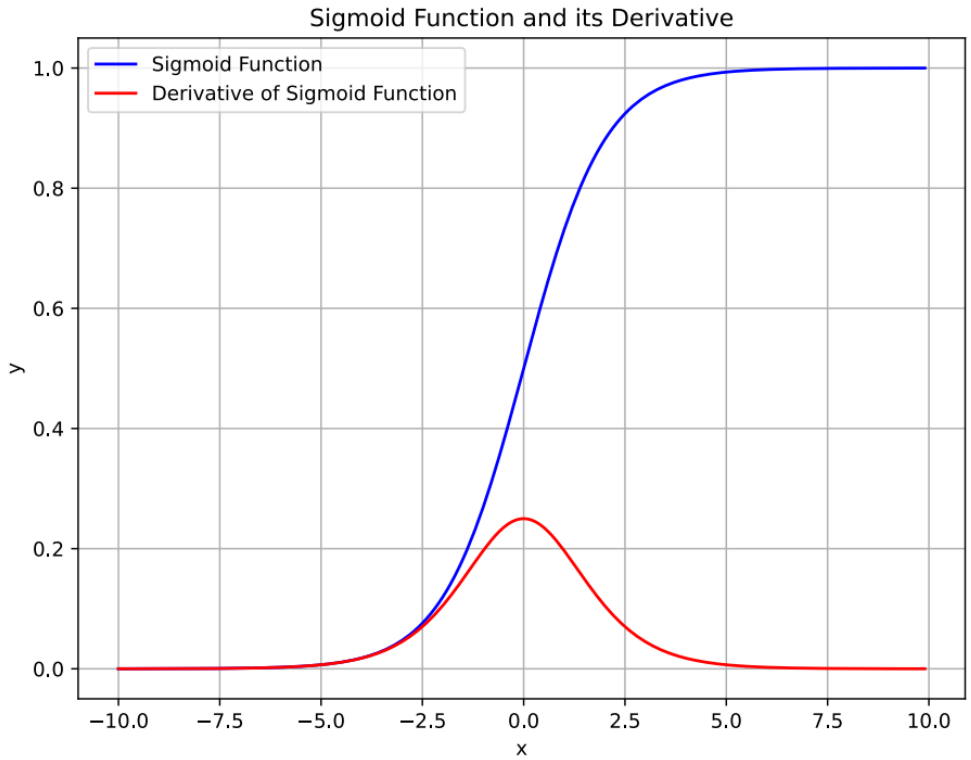

图 3.3 Sigmoid 函数图像与其导函数图像

2. Tanh[33]激活函数：该函数图像如图 3.4 所示，计算过程如式(3.4)，导函数如式(3.5)。其优点在于该函数完全可微分、反对称、对称中心在原点、并且可以解决 Sigmoid 函数输出值不以 0 为中心的问题。其缺点在于，当输入过大或是过小时，输出值较为平滑且导数值较小，不利于梯度的更新；该函数需要进行指数运算，会存在计算复杂度较高、计算成本较大的问题。

$$f(x) = \frac{e^{x}-e^{-x}}{e^{x}+e^{-x}} \tag{3.4}$$

$$f'(x) = \frac{4}{(e^{x}+e^{-x})^2} \tag{3.5}$$

中国知网 https://www.cnki.net

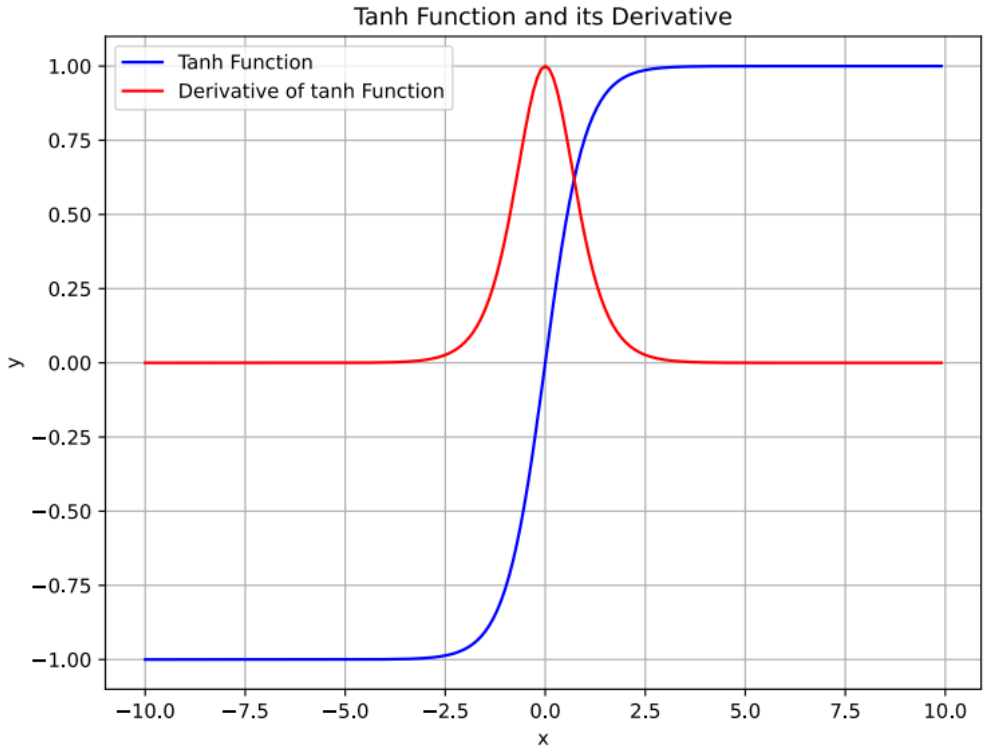

图 3.4 Tanh 函数图像与其导函数图像

3. ReLU[34]激活函数：该函数图像如图 3.5 所示，计算过程如式(3.6)，导函数如式(3.7)。其优点在于：当输入值大于 0 时，输出是线性的，一定程度上提升模型的收敛速度。并且正输入所对应的导数恒等于 1，梯度大小不变，不存在梯度消失问题和梯度爆炸问题。由于函数本身以及对应导函数都不包含复杂的计算过程，因此他的计算速度比 Sigmoid 函数和 Tanh 函数更快。其缺点在于：在输入值为负时，输出值始终为 0。这导致对应的导数也很等于 0，使得模型中部分神经元永远不能更新权重值，造成特征学习不充分。

$$f(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \tag{3.6}$$

$$f'(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases} \tag{3.7}$$

中国知网 https://www.cnki.net

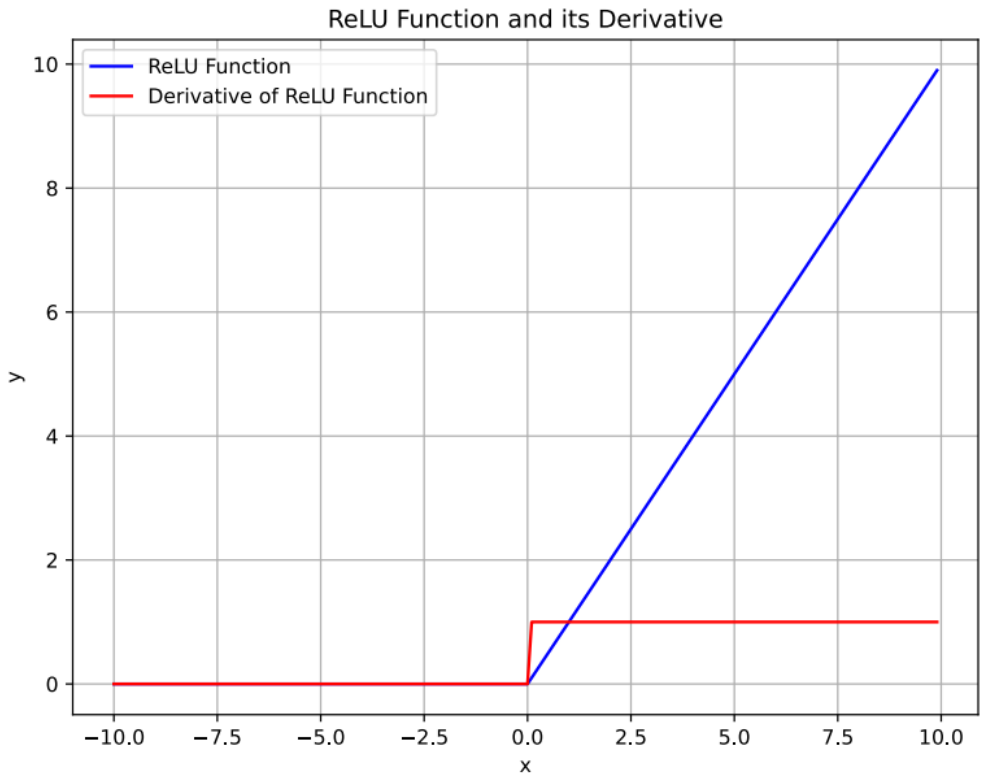

图 3.5 ReLU 函数图像与其导函数图像

综合上述不同激活函数的优缺点分析，在本研究工作中选用 ReLU 作为全连接层的激活函数。

LSTM 层（长短期记忆网络、Long Short-Term Memory）：每个原始特征序列在经过特征输入层后会输出单个二维的特征序列，在这个序列中，每行代表一个特征向量，而每个特征向量都对应与视频中的某一帧。正因为视频是由数帧图像组成，利用二维特征序列中的上下文信息，能够使模型更全面的理解整个视频中不同的模态信息。为了让模型能够学习到二维特征序列中的上下文信息，在特征编码模块中添加了单层的 LSTM。LSTM 不仅能够学习到这种短期的上下文信息，而且能够有效捕捉长期依赖关系。而选用 LSTM 主要原因有以下三点：第一，LSTM 在处理时间序列数据方面的优势；第二，考虑到有限的研究时间，选择较为熟悉和成熟的 LSTM 作为模型结构的一部分，以便更迅速的验证模型的性能；第三，考虑到模型复杂度和训练资源，需要在有限的资源下平衡模型的性能和可行性。

LSTM 有部分构成：遗忘门、输入门以及输出门。以下是对这三部分功能的具体介绍[35]。

1. 遗忘门：用来控制上一个时间点的信息是否传递到当前时间点并参与后续的运算。

中国知网 https://www.cnki.net

它通过一个 Sigmoid 激活函数来实现上述功能，决定上一个时间点的那些信息保留，哪些信息丢失。式(3.8)展示对应的计算过程。

$$f_t = Sigmoid\left(W_f \cdot [h_{t-1}, x_t] + b_f\right) \tag{3.8}$$

2. 输入门：用来控制当前时间点输入信息哪些需要参与更新。它依旧是通过 Sigmoid 激活函数来确定哪些信息参与更新。但是与遗忘门不同的是，它还通过 Tanh 激活函数创建了一个候选向量。候选向量与 Sigmoid 函数确定参与更新的信息共同更新当前时间点的信息。式(3.9)、式(3.10)展示对应的计算过程。

$$i_t = Sigmoid(W_i \cdot [h_{t-1}, x_t] + b_i) \tag{3.9}$$

$$\tilde{C}_t = tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \tag{3.10}$$

3. 输出门：根据当前时间点的输入信息和遗忘门与输入门保留的信息，由输出门决定当前时间点应该输出哪些信息。它先通过 Sigmoid 函数确定上一个时间点的信息与输入信息哪些信息应该输出。接着，通过 Tanh 函数确定保留信息中哪部分信息应该输出。最终，将这两部分信息相乘，得到该时间点最终的输出信息。计算过程如式(3.11)、(3.12)所示。

$$o_t = Sigmoid(W_o[h_{t-1}, x_t] + b_o) \tag{3.11}$$

$$h_t = o_t * tanh(C_t) \tag{3.12}$$

综上分析，LSTM 自身所包含的三种门结构，使得 LSTM 能够允许模型选择性的记忆重要的信息、忽略不重要的信息，进而提升模型在建模序列任务中的能力，提高模型全面理解数据的能力。

注意力机制模块：在原始特征序列经过 LSTM 之后，特征序列已经包含了丰富的上下文依赖信息以及时序信息，这使得模型已经能够很充分的理解输入特征序列的语义关联信息。然而，需要注意并不是整个特征序列中所有特征向量都具有代表性。为了让模型针对不同的特征序列所包含的特征向量，能够动态地赋予不同的权重数值，设计了一个注意力机制模块。该模块的本质作用是通过权重数值的大小体现出每个特征向量在特征序列中的代表性，以便模型能够更加有效的捕捉输入序列中重要的信息。该模块的具体结构如图 3.6 所示。

中国知网 https://www.cnki.net

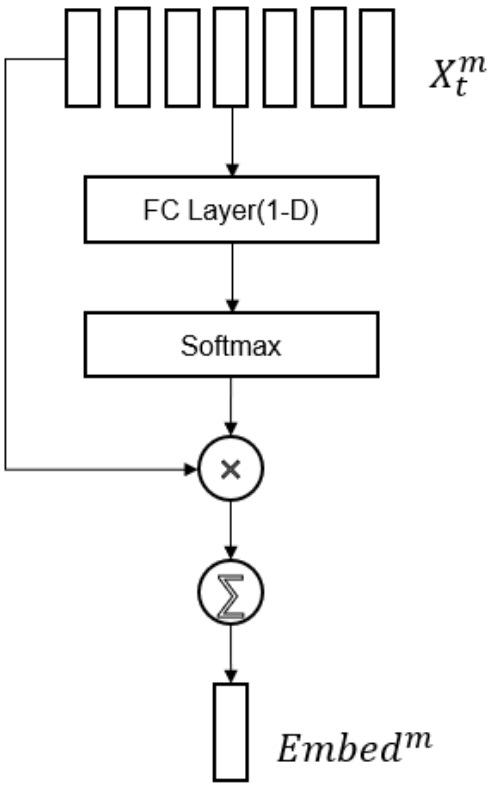

图 3.6 注意力机制模块结构图

以下是注意机制模块工作原理的介绍：该模型以 LSTM 输出的特征序列作为输入。首先，输入特征序列经过一个以 ReLU 作为激活函数的单神经元全连接层，该全连接层用于计算特征序列中所有特征向量的得分，将所有得分将构成一个一维的分数向量。具体计算过程如式(3.13)所示，其中$m \in \{Visual, Audio\}$表示图像模态和音频模态，t表示特征序列中每个特征向量的时间点，X表示输入的特征序列，W表示可以学习的参数。为简单起见，忽略偏置项。然后，分数向量经过 Softmax 函数得到每个特征向量对应的权重值得到权重值向量[36]。Softmax 函数的计算过程如式(3.14)所示，其中T表示单个输入特征序列的总长度。最后，将权重值向量与输入的特征序列根据式(3.15)进行加权计算，得到输入特征序列的加权表示，将其定义为加权特征向量。

$$S_t^m = ReLU(W^m X_t^m) \tag{3.13}$$

$$w_t^m = \frac{S_t^m}{\sum_0^{T-1} S_t^m} \tag{3.14}$$

$$Embed^m = \sum_0^{T-1}(w_t^m X_t^m) \tag{3.15}$$

中国知网 https://www.cnki.net

3.1.2 特征融合模块(Fusion Module)

通常来说，一个具体事物是由多种模态构成，不同模态表述同一事物的方式不同，且看待同一事物的角度也不同，因此不同模态之间会存在一些信息交叉和互补的情况。如果能够设计合理的融合方式处理多种模态信息，就能够获得更加丰富的特征信息，使得模型性能得到进一步提升。

在特征融合模块中，使用特征向量直接拼接的融合方式。该特征融合方式只需要将不同模态的特征向量按照规定顺序首尾拼接，则完成了特征融合过程，进而得到了维度更高的特征向量。在特征融合过程中，每种模态的特征信息都被保留了下来，使得模型能够获取不同模态完整的特征信息。但是，该融合方式会导致特征维度增加。当融合多种模态时，融合后的特征向量维度可能会变得非常高，一定程度上增加了计算成本与存储成本，并且在极端情况下可能引发维度灾难。

具体融合过程如图 3.7 所示，直接将图像加权特征向量与音频加权特征向量首尾相连，形成融合加权特征向量。

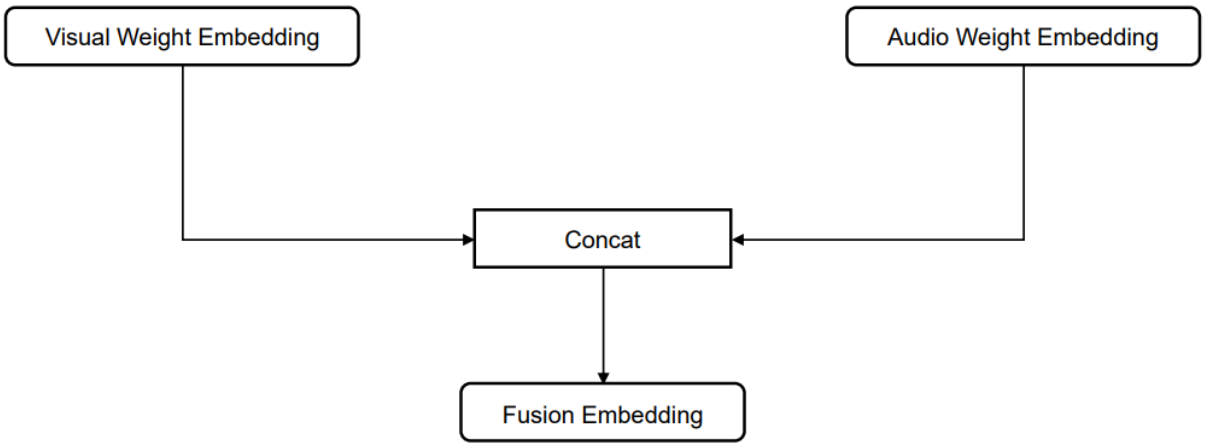

图 3.7 直接拼接特征融合过程图

中国知网 https://www.cnki.net

3.1.3 最终决策模块(Decision Module)

该模块的作用是将融合加权特征向量转换成推荐相关性得分，这些得分用来衡量广告推荐程度，确定广告推荐的最终排名。具体结构及其参数如图 3.8 所示，该决策模块包括五个全连接层，分别有 128 个神经元、64 个神经元、32 个神经元、16 个神经元以及 1 个神经元。其中前四层使用 ReLU 作为激活函数，最后一层不是用激活函数，用来输出一个分数，该分数将作为广告推荐排序的依据。

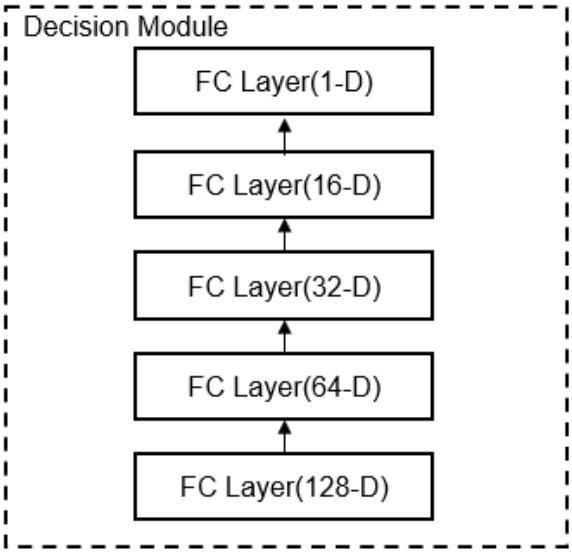

图 3.8 最终决策模块结构图

中国知网 https://www.cnki.net

3.2 基于大模型文本特征增强与融合的短视频广告推荐模型(TFE-SVARM)设计

基于大模型文本特征增强的短视频广告推荐模型结构如图 3.9 所示，整体结构与 SVARM 结构相似，但是在特征编码模块和特征融合模块有细微差异。对于 SVARM 具有的图像特征编码模块以及音频特征编码模块，又额外添加了一个用于处理文本特征序列的特征编码模块，并对原有的特征融合模块结构进行修改，引入了一种门控机制特征融合模块。

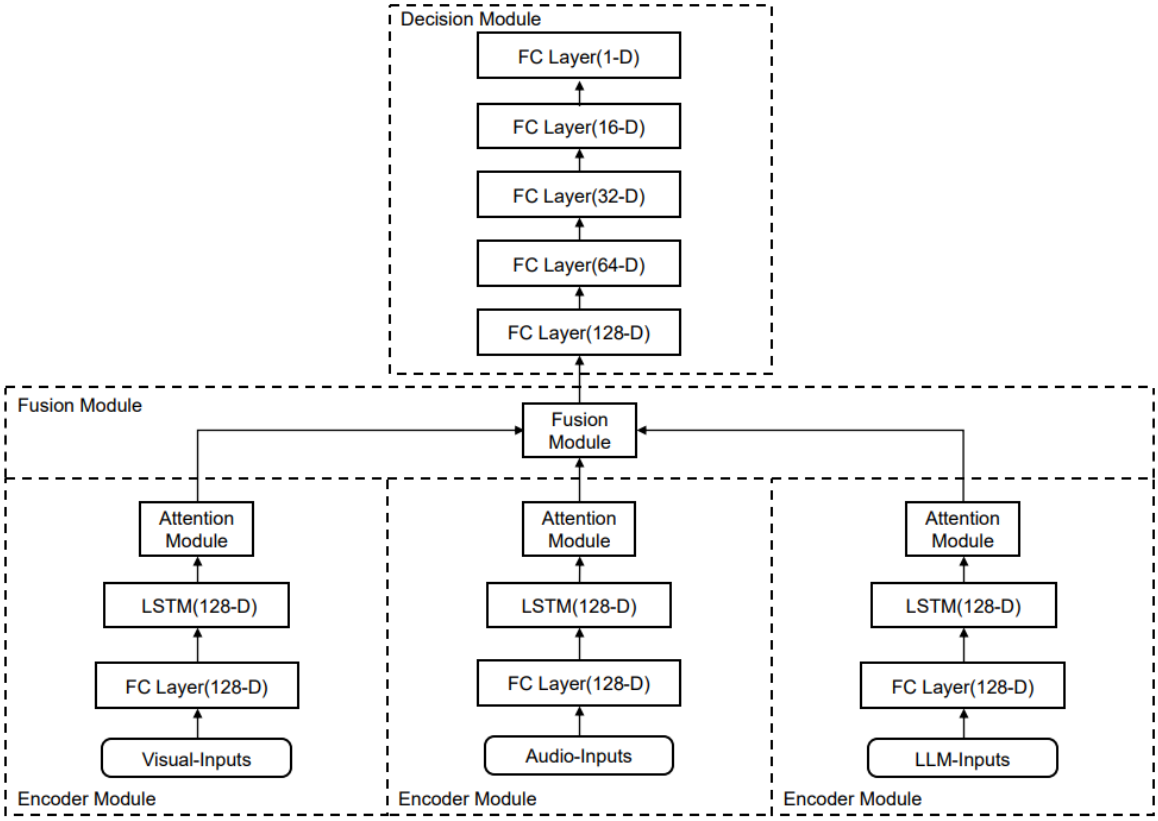

图 3.9 TFE-SVARM 结构图

3.2.1 文本特征编码模块

文本特征编码模块与本文 3.1.1 小节中提到了特征编码模块的结构是完全一样的，都是特征处理层、LSTM 层以及注意力机制模块组成。其主要作用分为两个层面：理论层面和现实层面。

1. 理论层面：文本特征编码器能够将原始文本特征序列转换成更具有语义信息的特

中国知网 https://www.cnki.net

征向量表示，帮助模型更充分、更全面的理解文本内容。并且通过 LSTM 层和注意力机制模块，可以有效捕捉文本特征序列中长期依赖关系，并着重关注文本特征序列中更具代表性的部分，从而提升模型性能。

2. 现实层面：文本特征编码模块是将文本特征序列转换成文本加权特征向量，这些向量作为特征融合模块的输入。

3.2.2 门控机制特征融合模块

在 TFE-SVARM 结构中，设计了一种门控机制特征融合模块，用来处理三种模态各自的加权特征向量。具体结构如图 3.10 所示，它采用了门控机制，其灵感来源于[37,38]。首先，每种模态的加权特征向量经过以 ReLU 作为激活函数的单神经元全连接层，得到加权特征分数。接着，加权特征分数输入 Sigmoid 函数以获得加权特征权重值。由于 Sigmoid 函数的输出范围在[0,1]之间，使其类似于一个通道闸门，用来控制加权特征向量对下一步处理的贡献程度。然后，将加权特征权重值与输入的特征向量相乘。随后，将三种模态相乘后的特征向量进行元素级相加，并通过一个全连接层，其激活函数是 Tanh。最终，得到融合加权特征向量。

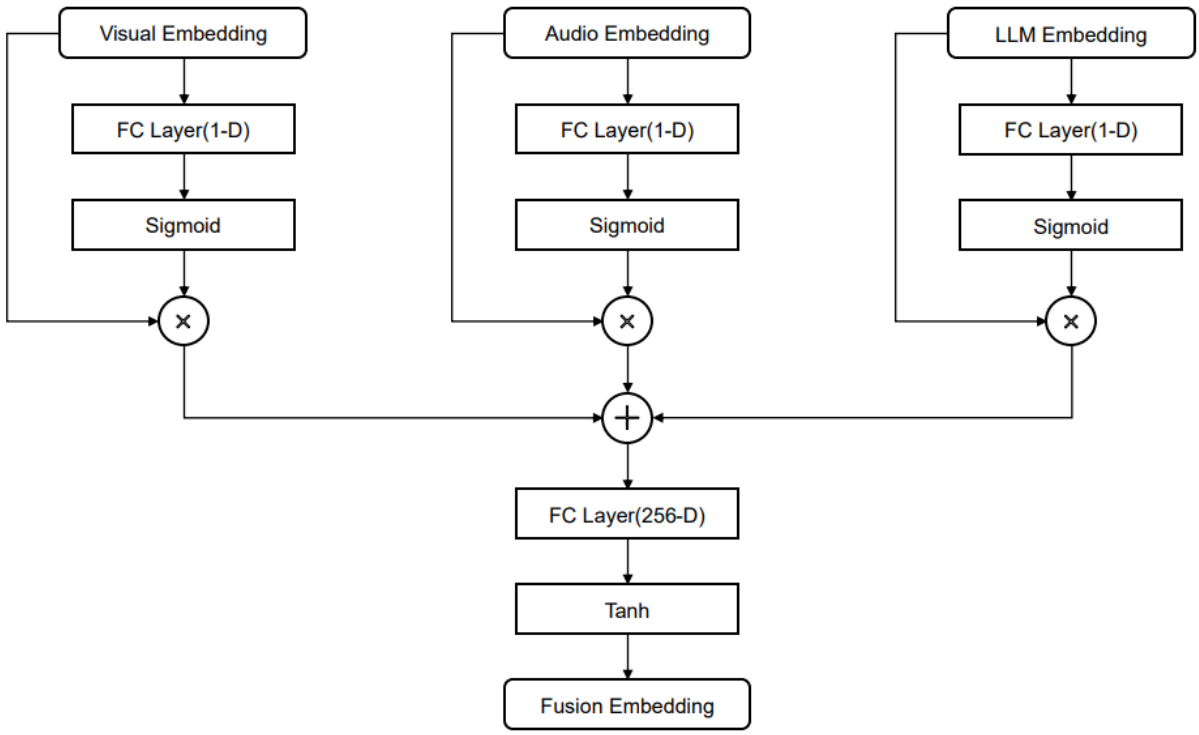

图 3.10 门控机制特征融合过程图

与普通的加权特征融合相比，在设计门控特征融合机制时，借鉴了加权融合的思路。

中国知网 https://www.cnki.net

但是，本文提出的特征融合方法在现有的应用场景中具有有效性，并且与普通的加权融合存在区别。普通的加权融合中权重通常是固定值，而门控机制是利用全连接层和激活函数计算权重，能够控制每种特征对最终融合结果的贡献度。

3.3 本章总结

本章详细介绍了短视频广告推荐模型(Short Video Ads Recommendation Model，SVARM)，介绍了组成该模型的三个部分，分别是：特征编码模块、特征融合模块以及最终决策模块。还介绍了优化版 SVARM——文本特征增强的短视频广告推荐模型(Text feature-enhanced Short Video Advertisement Recommendation Model，TFE-SVARM)，着重强调了文本特征编码模块以及门控机制融合模块的结构。

本章提出的文本特征增强的短视频广告推荐模型，意指在提高模型预测推荐排序的准确率。首先，通过特征编码模块，将原始特征序列进行有效编码以及压缩，以在缩小数据维度的同时最大程度地保留原始特征序列中重要的特征信息。然后，通过门控机制特征融合模块，将来自不同模态的加权特征向量进行有效地融合，使得模型能够充分理解并利用这三种模态信息。最后，通过最终决策模块将融合加权特征限量转换为推荐相关性得分，用于生成预测推荐排序。

通过上述模型，可以有效提高模型推荐的准确率，从而促进短视频广告的点击率，以达到既定的广告效果和商业价值。下一章将对本研究工作所涉及的数据处理过程、实验步骤与结果进行详细的阐述与分析。

中国知网 https://www.cnki.net

第 4 章 数据处理与实验分析

在本章中，对所提出的 SVARM 以及 TFE-SVARM 进行性能评估，主要包括以下五个部分：数据集和评价指标、多模态（图像、音频、文本）特征提取、实验平台设置、模型训练——RankNet 算法、实验设置与结果分析、本章小结。

4.1 数据集和评价指标

4.1.1 数据集

在本研究工作中，使用了一家电子商务公司提供的多媒体短视频广告语料库(Multimedia Short Video Advertisement Corpus，Multi-SVAD)。该语料库包含了该公司真实发布的 744 条短视频广告，这些广告视频被投放在四个短视频平台上，分别是：TikTok(TT)、Google(GG)、Facebook(FB)和 Snapchat(SC)。如图 4.1 展示了在语料库中，从两个短视频广告样本抽取的视频帧。

图 4.1 短视频广告视频帧样例

本文对语料库中所有广告视频的各种参数进行了详细分析，参数包括：平台广告数量(Number)、平台广告总时长(Total Dura)、平台广告最大时长(Max Dura)、平台广告最小时长(Min Dura)、每秒视频帧数(Vid FPS)、音频采样频率(Aud FS)以及音频通道数(Aud Ch)，具体统计结果在表 4.1 中所示。在语料库中，所有视频都是由 RGB 图像构成，但是原始视频

中国知网 https://www.cnki.net

的分辨率并不统一，包括：1080*1080、720*720、720*1280、1080*1920、1992*1120 和 1920*1080。此外，这些视频还包含两种不同的帧率：25 帧/秒和 30 帧/秒。值得注意的是，研究初期选择使用单个数据集进行实验，以便在有限的时间和资源内验证模型的基本性能。然而，收集有效的数据却十分困难，我们也认识到单一数据集的局限性，并在研究后续扩展现有数据集。

表 4.1 语料库统计结果

Platform	Number	Total Dura	Max Dura	Min Dura	Vid FPS	Aud FS	Aud Ch
FB	101	1,538.11	21.89	6.75	25/30	44,100	2
GG	46	698.38	39.34	8.64	25/30	44,100	2
SC	494	6,809.19	23.62	5.33	25/30	44,100	2
TT	103	1,644.61	24.17	8.17	25/30	44,100	2

4.1.2 评价指标

在本小结中，将详细介绍两种评价指标。第一种是：广告效果评价指标；第二种是：模型性能评价指标。以下是对这两种评价指标的具体介绍。

广告效果评价指标——点击率(Click-Through Rate，CTR)：在广告业中，CTR 是指一段时间内广告点击次数与广告被展示次数的比值，用来衡量在线广告的效果，式 4.1 展示了点击率的计算过程[39]。

$$CTR = \frac{Click}{Show\ Content} \times 100\% \tag{4.1}$$

在广告业中，CTR 是衡量广告质量十分重要的评价指标之一，其原因可以总结为以下三点：

1. 衡量广告质量：CTR 数值的大小可以直接反映出在线广告与用户的交互频率，即广告被点击的概率。因此较高的点击概率表示广告能够更好的吸引用户的注意力，进而体现了广告具有更广泛的宣传效果。
2. 评估广告内容：通过比较 CTR，广告商可以评估广告内容和创意的效果。假如某个广告的 CTR 高于其他广告，这可能意味着该广告的内容或者创意更具有吸引力，从而优化其他广告的设计思路。
3. 优化广告投放：CTR 也可以帮助广告商优化广告投放策略；通过分析 CTR 数据，

中国知网 https://www.cnki.net

可以明确哪些广告在平台上获得了更高的点击率，从而调整广告投放策略，降低广告投放成本。

在本文中，短视频广告 CTR 也是由同一家电子商务公司提供的。CTR 能够准确体现出语料库所包含的短视频广告在真实环境中的广告效果。因此，依据 CTR 数值的大小构建广告真实推荐排序，然后将真实排序与模型输出的广告预测排序进行比较。通过比较结果来评估所提出的模型性能。

为了进一步分析每个平台的 CTR 值，在图 4.2 中展示了每个平台的 CTR 分布。从图中可以清楚地看出，四个短视频平台的 CTR 分布存在明显差异，这种分布差异可能会给模型带来一定的训练困难。

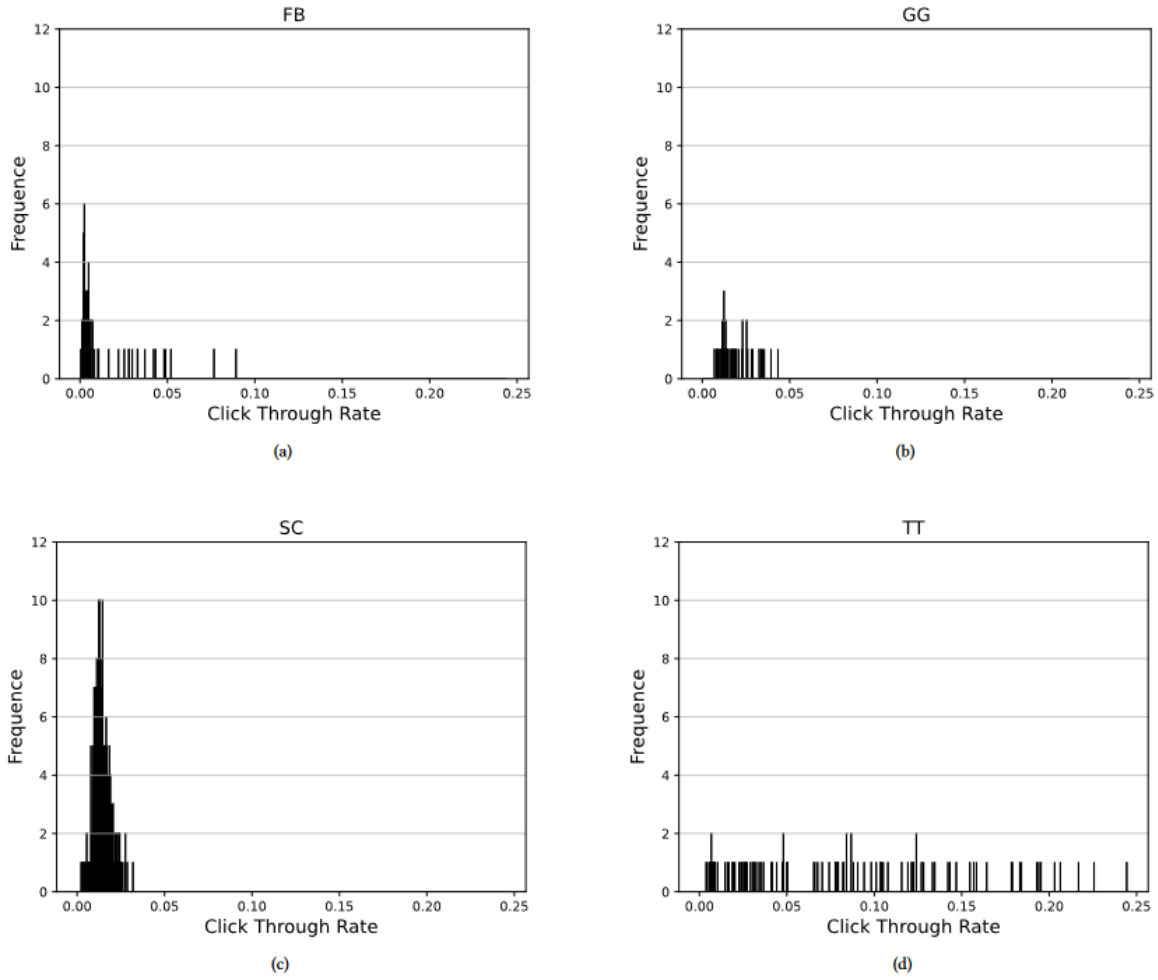

图 4.2 不同平台 CTR 直方图

模型评价指标——归一化折损累计增益(Normalized Discounted Cumulative Gain，NDCG)：该指标是一种用于衡量信息检索系统、排名系统或推荐系统的重要指标[40]。NDCG 的优点在于考虑了推荐列表中每个物品的相关性以及物品的排名位置，因此能够更加准确

中国知网 https://www.cnki.net

地体现出推荐系统在生成推荐列表的质量。在深入分析 NDCG 原理和计算过程之前，先介绍四个相关的概念。

累计增益(Cumulative Gain，CG)：累计增益是用来计算模型生成的推荐列表中所有物品相关性的总和，通常对每个推荐物品的相关性通过加权求和的方式进行计算，具体计算过程如式 4.2 所示。

$$CG_K = \sum_{i=1}^{k} rel_i \tag{4.2}$$

在式(4.2)中，参数k表示推荐列表中所包含的物品个数，其数值大小可以根据项目要求自由设定。例如，假定从十个视频中选取三个视频推荐给用户，则$k = 3$，用“TOP-3”来表示。而参数rel_i表示相似度分数或是相关性分数，其具体含义取决于给定任务所使用的数据集。通常情况下，相似度分数可分成两种类别：显示反馈和隐式反馈。

1. 显示反馈：显示反馈是指数据集中，包含能够体现出每个物品具体评分。例如，一个用户对视频内容质量进行评分，分数范围从 1 分至 5 分。这个分数就表示相似度分数，也就是参数rel_i的取值，而这种数据集也被称为用户评分数据集。
2. 隐式反馈：隐式反馈是指数据集中，包含能够体现出每个是否被点击。例如，一个用户在浏览短视频时，在浏览过程中是否点击过某个短视频广告。如果点击过则用 1 表示，而没有店家过则用 0 表示。数字 0 和 1 就表示相似度分数，也就是参数rel_i的取值，而这种数据集也被称为用户点击数据集。

由于，CTR 本身就是平台用户对于短视频广告吸引力程度的评分。因此，在本研究工作中使用的数据集属于显示反馈的类别，CTR 可以直接用于参数rel_i的取值。

折损累计增益(Discounted Cumulative Gain，DCG)：在计算 CG 的过程中忽略了一个很重要的因素，推荐列表中每个物品的排名。例如：从十个广告中选取三个广告推荐给用户，最理想的推荐列表是“广告一、广告二、广告三”，而推荐模型生成的推荐列表是“广告二、广告一、广告三”。值得注意的是这两个推荐列表的 CG 值是完全相同的，所以无法通过 CG 值来比较这两个推荐列表的质量。

为了解决这个问题，在由式 4.2 得到 CG 值后，在除以一个折损因子得到 DCG。具体计算过程如式 4.3 所示。

$$DCG_k = \sum_{i=1}^{k} \frac{rel_i}{\log(i+1)} \tag{4.3}$$

中国知网 https://www.cnki.net

在式 4.3 中，参数k依旧表示推荐列表中所包含的物品个数，参数i表示推荐列表中第i个推荐物品的排序。$\log(i+1)$用来计算第i个推荐物品所在排名的折损因子，这使得在推荐列表中物体排名越靠前的折损因子越小，物体排名靠后的折损因子越大。所以，与 CG 相比，CG 只是单纯的将推荐物品的相关性分数进行累加。而 DCG 的思想是不仅要关注推荐物品的相关性分数，更应该强调推荐列表中每个物品排名重要的重要性。因为，不同排名对于 DCG 的影响程度是不同的，通常情况下，排名靠前的物品影响程度较大，排名靠后的影响程度较小。

理想折损累计增益(Ideal Cumulative Gain Discounted，IDCG)：IDCG 是指理想化的 DCG，即 DCG 能够取得的最大值，具体计算过程如式 4.4 所示。

$$IDCG@k = \sum_{i=1}^{|REL|} \frac{rel_i}{\log_2(i+1)} \tag{4.4}$$

参数$|REL|$表示推荐列表中所有物品的理想排名，即按照物品的相关性分数，由大到小构成的排名。其他参数的定义与式(4.3)中的参数定义完全相同。需要强调的是，IDCG 和 DCG 在计算原理上没有本质的区别。只是 DCG 使用模型预测的物品排名参与计算，而 IDCG 使用物品的相关性分数构成的排名参与计算，所以 DCG 永远小于 IDCG。

归一化折损累计增益(Normalized Discounted Cumulative Gain, NDCG)：将 DCG 除以 IDCG 就得到了 NDCG，具体计算过程如式 4.5 所示。

$$nDCG@k = \frac{DCG@k}{IDCG@k} \tag{4.5}$$

在式(4.5)中，nDCG 的取值区间在[0,1]之内。在这个区间内，计算结果越靠近 1 表示模型生成的预测排名与真实排名差异越小，模型的推荐能力越好；计算结果越靠近 0 表示预测排名与真实排名差异越大，模型的推荐能力越差。

综合上述分析，NDCG 之所以能够衡量推荐系统的效果，可以归纳为以下几点原因：

1. 信息综合性高：在计算 NDCG 过程中综合了多种信息，包括物品的相关性分数，物品的预测排名和物品的真实排名。通过综合这些信息，使得 NDCG 能够综合体现推荐系统的能力。
2. 更注重排名因素影响：推荐系统的核心作用是给用户推荐感兴趣的物品，因此生成正确的推荐列表是至关重要的。但是，推荐列表中物品的排序更假重要。因为，用户更愿意浏览或选择排名靠前的物品。

中国知网 https://www.cnki.net

3. 能够体现用户浏览行为：折损因子在一定程度上够能反映用户的浏览行为。因为，通常情况下用户更倾向于浏览或点击排名靠前的推荐物品，排名靠后的推荐物品更容易被忽视。而折损因子恰好体现了这一现象，推荐列表中排名靠前的物品折损因子更小，排名靠后的物品折损因子更大。这会减小排名靠后的物品对 NDCG 的影响，而用户很大程度上会忽视这些排名靠后的物品。因此，通过添加折损因子，能够更好的体现推荐列表中不同排名物品的影响程度，进而提升了 NDCG 衡量推荐系统性能的全面性。

4.2 多模态特征提取

本小节主要介绍图像特征、音频特征以及文本特征的提取过程。以图像特征提取为例，首先介绍使用的预训练模型以及特征提取的过程。其次，论述选用预训练模型的原因以及优势。最后，详细描述使用预训练模型生成特征的具体方法。

4.2.1 图像特征提取

在图像特征提取方面，选用 MobileNetV2 预训练模型作为特征提取器[41]。MobileNetV2 是谷歌在 2017 年开发的一种轻量级神经网络模型，主要应用于移动设备和嵌入式设备的图像分类任务。该模型结构优势在于，既保证模型精度和准确性，同时保证较低的模型参数，以达到模型轻量化的目的。以下是 MobileNetV2 模型的一些关键特点：

1. 倒残差结构(Inverted Residuals)[41]：传统残差结构通常是，输入特征先通过一个卷积核大小是 1*1 的卷积层进行特征降维，然后通过一个卷积核大小是 3*3 的卷积层进行特征扩展，最后经过一个卷积核大小是 1*1 的卷积层进行特征升维。整个过程类似与一个两头大中间小的结构。而 MobileNetV2 中的残差结构则与传统残差结构相反，称为倒残差结构。在倒残差结构中，输入特征先通过一个卷积核大小是 1*1 的卷积层进行特征升维，然后通过一个卷积核大小是 3*3 的卷积层进行特征扩展，最后经过一个卷积核大小是 1*1 的卷积层进行特征降维。整个过程类似与一个两头小中间大的结构。
2. 线性瓶颈(Linear Bottlenecks)[41]：这个概念是指在倒残差结构中使用线性激活函数来代替非线性激活函数。这与传统残差结构使用非线性激活函数有所不同。

在 4.1.1 小节中提到过语料库中，广告视频分辨率并不统一。因此，在提取图像特征之

中国知网 https://www.cnki.net

前，还需要对视频数据进一步处理。图 4.3 展示了提取图像特征序列的完整过程。具体来说，首先将视频分辨率统一转变成 224*224(Unified video resolution)，以满足图像特征提取器的输入要求。接着，将视频中每一秒的第一帧图像抽取出来，不足一秒钟也抽取第一帧图像，用 Fame-ns 代表第 n 秒的第一帧图像。然后，将图像序列中包含的图像按照抽取的先后顺序依次送入图像特征提取器(Extract visual embedding)。最终，得到图像特征序列，用 Ve-ns 表示第 n 秒的图像特征向量。

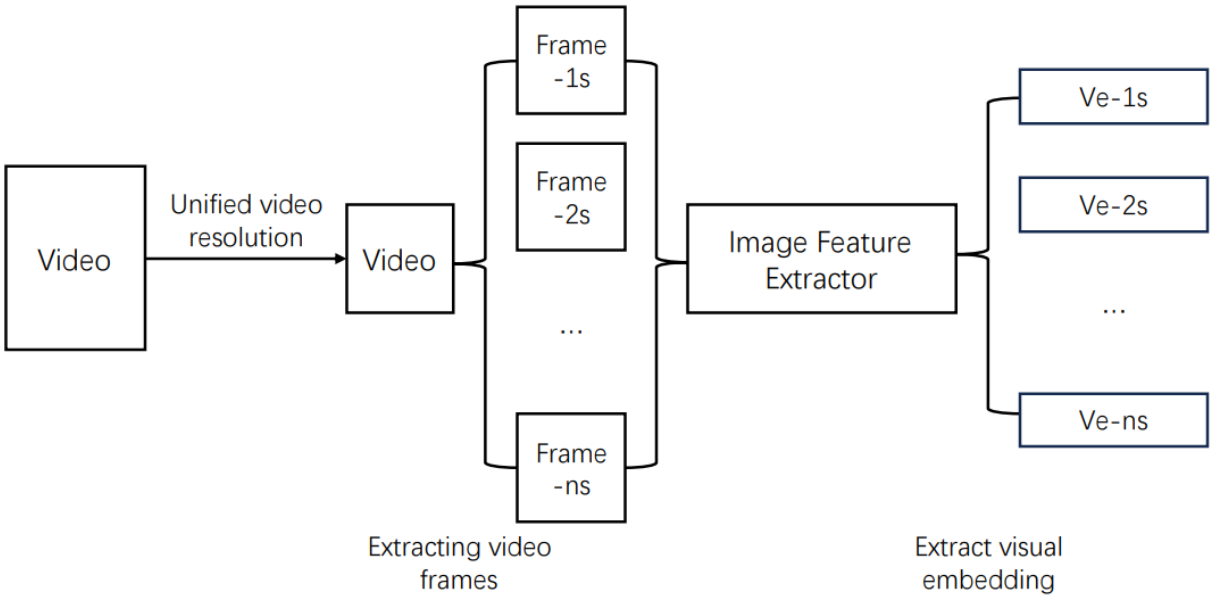

图 4.3 图像特征序列提取流程图

4.2.2 音频特征提取

在音频特征提取方面，选用 VGGish[42]作为特征提取器。VGGish 是由谷歌研发的一种用于音频特征提取的神经网络。该模型在 2017 年发布的大规模音频数据集 AudioSet[43]上进行预训练，该数据集包含了 632 种音频类别以及 210 万时间长度为 10 秒的音频片段。选用 VGGish 作为音频特征提取器的原因归纳为以下三点：

1. 易于部署和使用：相较于一些复杂的音频特征提取模型，VGGish 参数量相对较小，模型复杂度相对较低。这意味着该模型在资源有限的环境中能够更容易地部署和运行。
2. 经过大规模数据集训练：由于 AudioSet 包含大量且不同的语音片段，使其具备从不同音频类类别捕获特征的能力，具备较强的泛化能力。
3. 能够捕获丰富的语义特征：该模型可以将音频信号转换成具有丰富语义的特征表

中国知网 https://www.cnki.net

示，从而为后续任务提供有效的输入。

图 4.4 展示了提取音频特征序列的完整过程。在提取音频特征之前，还需要对音频数据进行进一步处理。首先将音频从完整视频中剥离出来(Extract full audio)；接着，将音频作为音频特征提取器的输入(Extract audio embedding)；最后，通过音频特征提取器得到音频特征序列，用 Ae-ns 表示第 n 秒的音频特征向量。

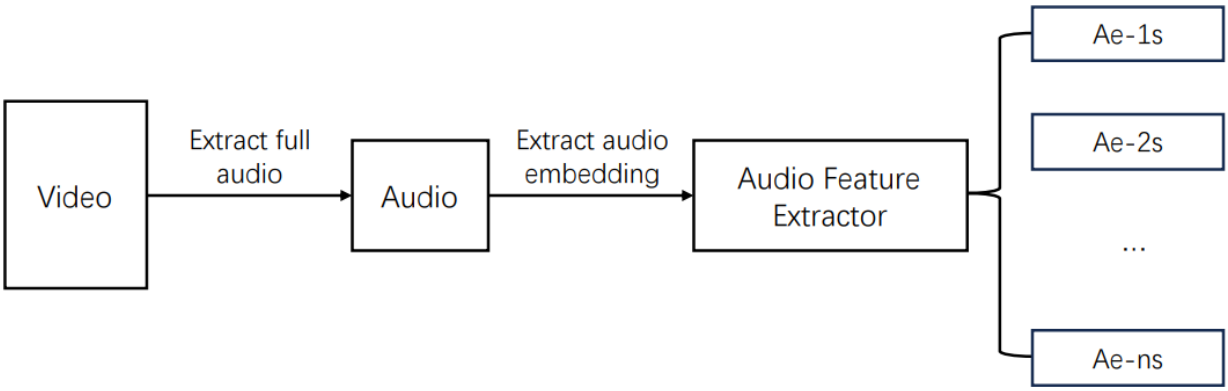

图 4.4 音频特征序列提取流程图

4.2.3 文本特征提取

在本文特征提取方面，首先使用大模型生成文本内容，然后再使利用 BERT[44]，从文本内容中提取文本特征。MobielNetV2 本质上是一个图像分类网络，虽然它具有捕捉图像中物体信息的能力，但是缺乏捕捉图像场景信息的能力。具体而言，图像场景信息指的是图像展现场景内容，包括图像描绘了何种场景，场景中包含了哪些具体的物体，以及物体与物体的空间关系等。目的是利用图像场景信息，提升 SVARM 对于视频内容的理解，从而提升模型的性能。

在本研究工作中，利用大模型作为文本生成器，生成描述图像内容的文本，通过文本的形式体现图像场景信息。具体来说，选用大型语言和视觉助手(Large Language and Vision Assistant，LLaVA)[45]作为文本生成器。LLaVA 本身是一个大型语言和视觉助手，主要目的是帮助用户处理各种语言和视觉任务，其主要功能可总结为以下两点：

1. 以文本作为输入的基础任务：LLaVA 可以处理并分析文本内容，允许用户提出问题和用户交谈，完成用户输入的既定任务，例如提炼文本内容、分析文本内容情感、续写文本内容等。
2. 以图像作为输入的基础任务：LLaVA 可以分析并理解图像场景，同样允许用户提出有关图像的问题并与用户交流，生成满足用户要求的文本内容。

中国知网 https://www.cnki.net

由于 LLaVA 具有描述图像内容的优秀能力，所以将 4.2.1 小节中抽取的视频帧，按照抽取的先后顺序输入到 LLaVA 模型，LLaVA 模型会对每个视频帧生成描述视频帧内容的文本。随后，将所有文本组合成一个文本序列。整个文本序列包含了视频从开始到结束所有内容的描述，通过文本序列可以更加全面地理解视频内容。

然而，在查阅文本内容时发现，文本内容与图像场景信息存在不匹配的问题。为了解决这个问题，提出了一种基于文本相似度的过滤方法。图 4.5 展示了文本过滤的完整过程，该过滤流程可以归纳为以下四个步骤：

1) 计算一个视频输出中的一个句子与所有其他句子之间的余弦相似度得分，V_{k-j}表示第k个句子和第j个之间的余弦相似度得分。
2) 计算每个句子的相似度得分的平均值以获得总体相似度得分，记作V_{k-M}。
3) 将总体相似度得分低于预设阈值的句子过滤掉，将预设阈值记作T。
4) 重新构建文本序列。

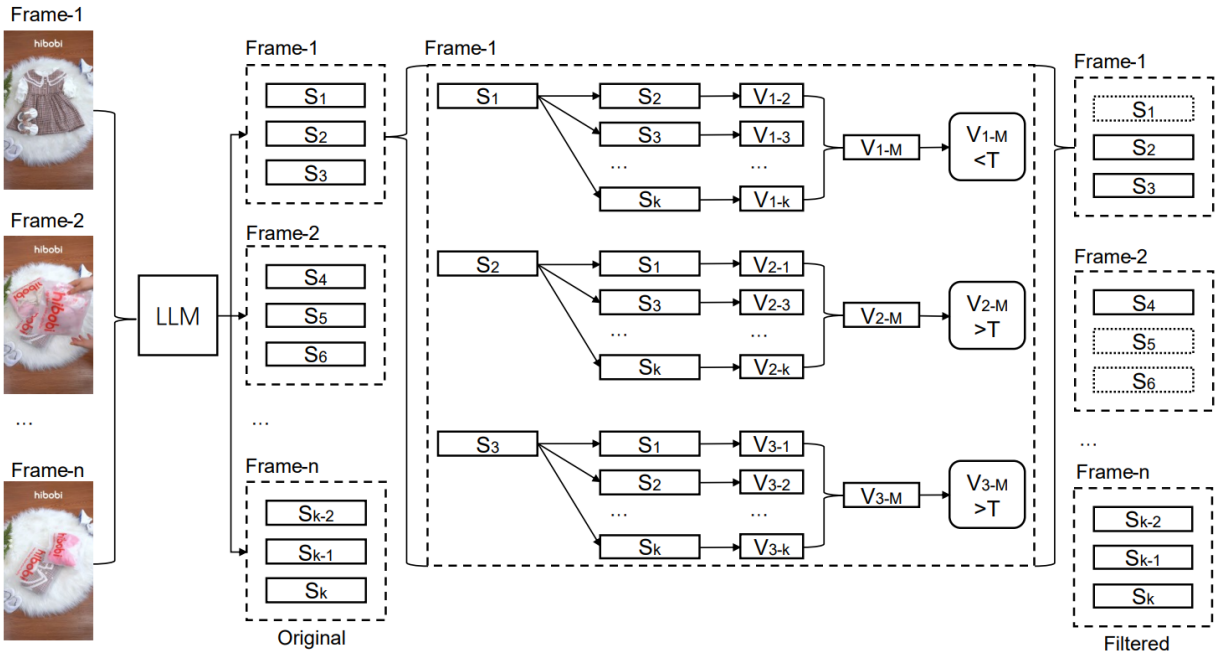

图 4.5 文本过滤流程图

虽然通过上述方式构造了文本序列，但是文本序列并不能直接作为模型的输入。因此，需要利用文本特征提取器将文本序列转换成文本特征序列。在本研究工作中，选定基于变换器的双向编码器表示技术(Bidirectional Encoder Representations from Transformers，BERT)作为文本特征提取器。

BERT 是谷歌在 2018 年发布的一款预训练语言模型，该模型以 Transformer[46]的编码

中国知网 https://www.cnki.net

器作为基础架构，并使用大量文本进行预训练。使得该模型具有理解文本中上下文信息的能力，适用于多种自然语言处理任务，如文本分类、语义理解、文本特征提取等。BERT 模型的特点可以总结为以下几点：

1. 双向编码：BERT 模型借鉴自然语言任务中完形填空任务的思想（双向编码），使得模型能够同时考虑文本中每个词的上下文信息，从而提升模型理解文本的能力。
2. 特征提取器的选用：BERT 作为一款预训练语言模型，借鉴了图像领域中的预训练思想。首先在大规模数据集上采用无监督的训练方式进行学习，然后通过在特定任务上微调模型使其达到于不同的任务要求。
3. 预训练以及任务微调：BERT 并没有采用传统的循环神经网络作为特征提取器，而是使用 Transformer Encoder 作为特征提取器，而 Transformer 又使用的注意力机制作为特征提取器，从而使得模型能够学习更加丰富的语言表示。

综合上述分析，可以得出 BERT 模型在自然语言处理领域具有重要地位。虽然 BERT 采用双向编码技术使其不在具有文本生成能力，但是采用 Transformer Encoder 作为特征提取器，使得 BERT 具有更强的语义信息提取能力。正式基于这个优点，本文选用 BERT 作为文本特征提取器。

图 4.6 展示了提取文本特征序列的完整过程。具体而言，将文本序列转换成文本特征序列具体流程如下：首先，将文本特征序列中包含的文本依次输入 BERT 模型中进行处理。然后，每一个文本都会对应一个 BERT 生成的文本特征向量。最后，将所有文本特征向量组合，形成最终的文本特征序列。

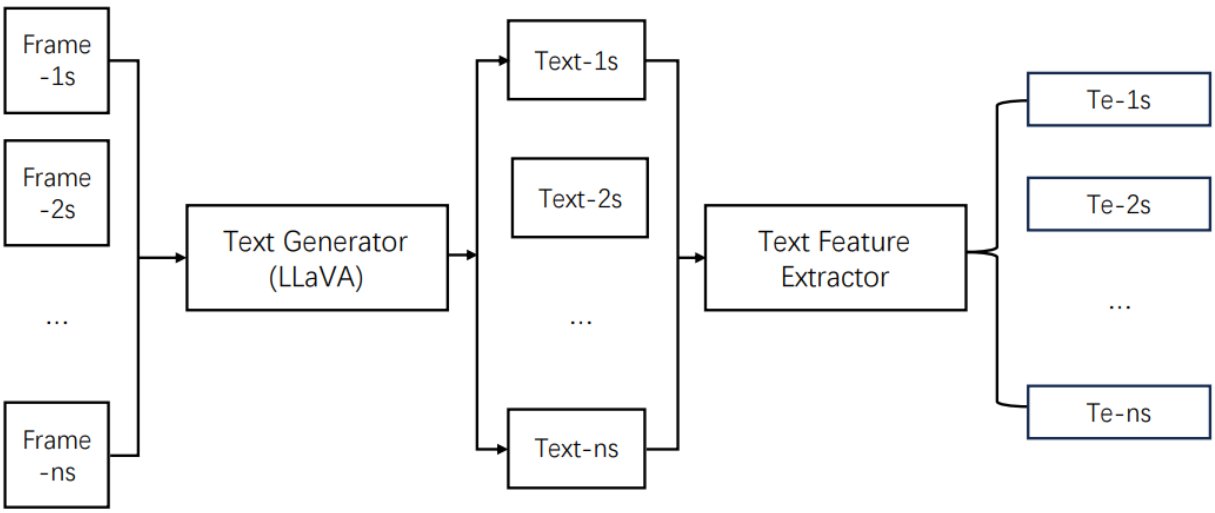

图 4.6 文本特征提取流程图

中国知网 https://www.cnki.net

4.3 实验平台设置

在本研究工作中，所使用的实验平台设置如表 4.2 所示。

表 4.2 实验平台设置

名称	配置
运行系统	Ubuntu22.04
CPU	Intel(R)Xeon(R) CPU E5-2678 V3
显卡	TITAN RTX*4
内存	62G DDR4
显存	96G
深度学习框架	PyTorch 2.0.0

4.4 模型训练——RankNet 算法

在本小节中，将详细介绍训练模型所使用的方法和原理。一共包含三个部分，分别是：排序学习介绍、RankNet 算法介绍和模型训练具体实现流程[47]。前两个部分主要介绍算法原理，最后一个部分主要介绍算法具体实现的过程。

4.4.1 排序学习(Learning to rank, LTR)

排序学习是解决排序问题时采用机器学习技术或深度学习技术来训练模型的方法[48]。排序学习的对象可以是任何具体事物，并且在不同领域中预测排名的方法也有所不同。在视频推荐领域中，通过利用用户的个人数据、历史行为数据、兴趣和偏好等信息，对一组视频的排序进行预测，并将排名靠前的视频推荐给用户。在信息查询领域中，根据搜索结果与查询词相关性，对一组搜索结果的排序进行预测，并将排名靠前搜索结果的推荐给用户。需要强调的是，排序问题的核心在于如何准确预测每个对象之间的相对顺序关系，而不仅仅是模型生成结果的准确性。这一点会在 4.4.2 小节中有更为详细的阐述。

目前来看，常用的排序学习方法可以分为三种类型：单文档方法(Pointwise) [49]、文档配对方法(Pairwise) [50]和文档列表方法(Listwise) [51]。以下是对这三种类型的详细分析：

1. 单文档方法：这种方法的核心思想是将排序问题转换成多分类问题或回归问题。具体地，该方法将每个文档看成独立的样本，利用多分类模型或回归模型计算文

中国知网 https://www.cnki.net

档与特定查询值之间的相关性等级或相关性分数，再根据计算结果对文档进行排序。

2. 文档配对方法：这种方法的核心思想是将排序问题转换成二元分类问题。该方法将数据集中所有文档两两组合构成文档对，并修改模型结构使其能够计算文档相关性分数的二元分类器。通过二元分类器计算所有文档对中两个文档的相关性分数，根据计算结果构建整个文档排序。
3. 文档列表方法：与上述两种方法的思想不同，这种方法的核心思想是将排序列表看作一个样本。通过减小排序列表和真实排序列表之间的差异，来促进模型的学习。

4.4.2 RankNet 算法介绍

在 4.4.1 小节中详细介绍三种不同类型的排序学习方法，并具体分析了每种方法的核心思想、优点和缺点。目前，这三种方法在工业界中相比，文档配对方法是比较流行的排序学习方法。因此，在本研究工作中使用文档配对方法中比较经典的 RankNet 算法来解决排序问题。将分为三个部分来详解介绍和分析 RankNet 算法，分别是：算法简介、算法基本原理和算法优缺点分析。

（1）算法简介

RankNet 算法是由微软在 2005 年提出的一种 Pairwise 的 LTR 算法，该算法从概率的角度解决排序问题。该算法的核心思想是利用一种概率损失函数来学习排序函数(Rank Function)，并利用学习好的排序函数对样本进行排序预测。需要强调的是，这里所指的排序函数可以是任意参数可微的模型。因此，概率损失函数并不依赖指定的模型结构。这使得在搭建模型结构时，可以根据不同排序任务的特点搭建不同的模型结构，在构建模型结构方面具有更强的灵活性和通用性。

由于 RankNet 算法属于 Pairwise 方法，因此该算法也继承了 Pairwise 方法的思想。在 4.4.1 小节中提到了，Pairwise 方法的核心思想是将排序问题转换成二元分类问题。具体而言，这种方法的重点并不在于确定某个样本与特定查询值之间相关性程度的具体分数，而是将所有样本的排序问题转化为判断任意两个样本排序先后的问题，或者是两个样本之间的相对顺序。换句话说，根据模型计算的样本相关性分数，比较任意两个不同样本的相关性分数大小，并将相关性得分更高的样本排在前面。用 Sami 和 Samj 来表示两个不同的样

中国知网 https://www.cnki.net

本。通常情况下，相关性程度被分成三个等级：Sami 比 Samj 更相关、Samj 比 Sami 更相关和 Sami 和 Samj 相关程度相同，并分别使用{+1、-1、0}作为这三种等级的标签。在本研究工作中，由于没有出现相关程度相同的情况，所以将相关程度等级分成两个等级：Sami 比 Samj 更相关和 Samj 比 Sami 更相关，并分别使用{+1、0}作为这两种等级的标签。综合上述分析，通过比较任意两个不同样本的相关性程度，或者更进一步地说，通过比较任意两个样本的相关性分数的大小构建排序。由此，Pairwise 方法将排序问题转换成了分类问题。

（2）算法基本原理

RankNet 算法就是基于上述思想的一种排序算法。整个算法可以分成四个步骤：计算相关性分数、计算预测相关性概率、计算真实相关性概率和定义损失函数。

1. 计算相关性分数：同样使用 Sami 和 Samj 表示两个不同的样本，用x_i和x_j表示两个样本的特征。式(4.6)和式(4.7)表示某种排序函数，该排序函数用来计算输入样本的相关性分数。在式(4.6)和式(4.7)中，参数x和参数w分别表示输入的特征和可学习的参数。则样本 Sami 和样本 Samj 的相关性分数为s_i和s_j。

$$s_i = f(x_i; w) \tag{4.6}$$

$$s_j = f\left(x_j; w\right) \tag{4.7}$$

2. 计算预测相关性概率：通过算法简介可分析出，Pairwise 方法仅关心任意两个不同样本之间的相对顺序。因此，在 RankNet 算法中，利用 Sigmoid 函数来定义 Sami 比 Samj 更相关的概率。在 3.1.1 小节中详细分析了 Sigmoid 函数，从函数图像可知，Sigmoid 函数值域在[0,1]。该函数的这一特性使得它能够将 Sami 比 Samj 更相关的概率映射到[0,1]区间内的实数，这也是在 RankNet 算法使用 Sigmoid 函数定义相关性概率的原因。具体的计算过程如式(4.8)，其中σ是待学习的参数，s_i和s_j分别代表两个不同样本的相关性分数。如果$P_{ij} > 0.5$，则认定 Sami 比 Samj 更相关，从而判定 Sami 的排名高于 Samj 的排名。如果$P_{ij} < 0.5$，则认定 Samj 比 Sami 更相关，从而判定 Samj 的排名高于 Sami 的排名。

中国知网 https://www.cnki.net

$$P_{ij} = P\left(U_i > U_j\right) = \frac{1}{1+e^{-\sigma\left(s_i - s_j\right)}} \tag{4.8}$$

3. 计算真实相关性概率：对于样本 Sami 和样本 Samj 都有一个衡量相关程度的真实值。本研究中，根据 CTR 大小来衡量不同短视频广告的相关程度。Sami 和 Samj 仍旧表示两个不同的短视频广告样本，这两个样本的 CTR 值用$CTRi$和$CTRj$表示。如果$CTRi > CTRj$，则 Sami 相比于 Samj 更相关。在本文中，式(4.9)定义 Sami 比 Samj 更相关的真实概率。在计算预测相关概率的小节中，Pairwise 的类别标签用{-1,+1,0}进行表示。由于 RankNet 算法属于 Pairwise 方法，所以在 RankNet 算法中依旧沿用这套类别标签。然而，在本研究工作中，将 Pairwise 的类别标签分成两类，并用{+1、0}表示。因此，在 RankNet 算法中将沿用这套两分类的标签类别，并将其记为S_{ij}，式(4.10)对两个不同广告样本的相关程度分配标签，本文用$final\ label$来表示标签。

$$\bar{P}_{ij} = \frac{1}{2}\left(1 + S_{ij}\right) \tag{4.9}$$

$$final\ label = \begin{cases} 0, & CTRi < CTRj \\ 1, & CTRi > CTRj \end{cases} \tag{4.10}$$

4. 定义损失函数：对于一个排序结果，RankNet 根据不同样本的相对顺序衡量整体排序结果的好坏。具体而言，排序结果越接近真实排序，那么排序结果中相对顺序出现错误的样本对就越少。所谓出现相对顺序错误的样本对是指，如果根据模型输出的相关性分数判定 Sami 的排名小于 Samj 的排名，但是根据相关性程度标签可知 Sami 的排名高于 Samj 的排名，则记作一个错误的样本对，而 RankNet 整个计算过程的核心就是以最小化错误样本对数量为目标。在定义损失函数时，RankNet 算法引入了概率的思想：不是直接判断 Sami 的排名高于 Samj 的排名，而是计算 Sami 排名高于 Samj 排名的概率 P，即最小化预测相关性概率与真实相关性概率的差距为目标。在 RankNet 算法中采用交叉熵函数作为损失函数[52]，用来衡量预测概率与真实概率的拟合程度，具体计算过程如式(4.11)。

$$loss\ function = -\bar{P}_{ij}\log P_{ij} - \left(1 - \bar{P}_{ij}\right)\log\left(1 - P_{ij}\right) \tag{4.11}$$

将式(4.8)、式(4.9)代入式(4.11)中，简化后得到式(4.12)：

中国知网 https://www.cnki.net

$$C = \frac{1}{2}\left(1 - S_{ij}\right)\sigma\left(s_i - s_j\right) + \log\left(1 + e^{-\sigma\left(s_i - s_j\right)}\right) \tag{4.12}$$

当$S_{ij} = 1$时，则有：

$$C = \log\left(1 + e^{-\sigma\left(s_i - s_j\right)}\right) \tag{4.13}$$

当$S_{ij} = 0$时，则有：

$$C = \log\left(1 + e^{-\sigma\left(s_j - s_i\right)}\right) \tag{4.14}$$

因此，当$S_{ij} = 1$时，模型预测s_i比s_j越大，损失函数越小，代价越小；Sij=0 时，损失函数的最小值在s_i和s_j相等处取得。该损失函数有以下两个特点：

1) 如果两个相关性不同的样本，通过模型计算的相关性分数却相同，则损失函数的输出值仍大于 0，依旧会对该样本对进行惩罚，进而区分这两个样本的排名位置。
2) 该损失函数是类似线性函数，这种函数可以有效减少异常样本对模型性能的影响，具有良好的鲁棒性。

（3）算法优缺点分析

通过前两部分内容能够分析出，RankNet 算法是一种用于解决排序问题的算法。其核心思想是通过减小预测概率和真实概率之间的差距来优化排序结果。在本小节中将详细列举该算法的不同优点和缺点。

RankNet 算法的优点在于：

1. “端到端”训练方式：这种训练方式的优点是不需要人为将整个训练过程划分为多个独立的训练步骤，而是将训练数据完全交给构建好的模型，该模型直接学习从原始输入到期望输出的映射关系。这种训练方式具有协同增效的优势，增加了获得全局最优解的可能性。
2. 模型结构灵活性：在第 4.4.2 小节的第一部分算法简介中提到，排序函数可以是任意参数可微的模型结构，并不受固定模型结构的限制。因此，RankNet 算法可以根据不同的任务需求构建不同的模型结构。这种模型结构高自由度的特性使得 RankNet 算法可以应用在不同领域，具有广泛的适用性。

中国知网 https://www.cnki.net

RankNet 算法的缺点在于：

1. 训练数据不均衡：不同的查询值对应的样本数量差异可能会很大。在构成样本对之后，有的查询值对应几千个样本对，而有的查询值对应几十个样本对。如果不对数据进行处理，直接将所有样本对提供给模型学习。那么，模型学到的排序函数会更符合样本数量多的排序结果。最终，可能会出现模型在数量较小的样本集排序效果不佳的情况。
2. 忽略绝对位置信息：在 RankNet 算法中，仅考虑了两个不同样本之间的相对位置关系，并没有考虑样本在排序结果中绝对位置关系。这使得该算法存在一定的局限性，可能影响最终的排序效果。

4.4.3 具体实现

在本小节中，将详细介绍如何将 4.1.1 小节中所提到的语料库中包含的视频样本构成视频对、如何构成视频对标签和如何修改模型结构，使其满足 Ranknet 算法的对于输入数据结构和模型结果的要求。本小节总体分成三个部分，第一部分是构建视频对，第二部分是构建视频对标签，第三部分是修改模型结构。

（1）构建视频对

在 RankNet 算法中，需要为每个样本对标记对应的标签，以表示样本之间的相对顺序。通常用数字 1 和数字 0 作为相对顺序的标签，其中数字 1 表示样本一的排序高于样本二的排序，数字 0 表示样本一的排序低于样本二的排序。具体到本研究工作中，可以根据 CTR 的比较结果构建样本之间的相对顺序。这个过程可以归纳为以下三步骤：

步骤一，在 4.1.2 小节中提到了本研究所使用的语料库不仅包含四个平台的短视频广告，还包含一个用于存放 CTR 值的列表，该列表记录了所有短视频广告的 CTR 值。通过查询的方式，可以获取每个视频对中两个视频样本分别对应的 CTR 值。

步骤二，将每种视频集中所包含的视频样本，任取两个视频样本构成一个视频对，直至遍历所有配对结果。需要强调的是，在配对过程中忽略了视频对中视频样本的顺序因素。例如：一个视频对中包含两个视频样本：“视频 A、视频 B”，则“（视频 A，视频 B）”和“（视频 B，视频 A）”被视作同一个视频对。如果在配对过程中出现相同情况，则只保留一个配对结果，从而确保每个视频对都具有唯一性。并且，在配对过程中还会出现一个视频对中包含两个相同视频样本的情况。例如：“（视频 C，视频 C）”组合成一个视

中国知网 https://www.cnki.net

频对。这种视频对模型训练是没有意义的。因此，通过技术手段删除了由相同视频样本构成的视频对，从而确保所有视频对都是由两个不同的视频样本组成。

步骤三，统计了各个平台每种视频集构成视频对的数量，统计结果如表 4.4 所示。与表 4.3 不同视频集数量统计结果相比，三种视频集在构成视频对之后，视频对样本数量相比视频样本数量有显著提升。这在一定程度上减小了训练模型的难度。因为，使用样本数量过小的数据集，会增加模型训练难度，导致模型训练不充分。所以，通过构建视频对的方式增加训练样本数量，降低模型训练难度，从而提高模型的性能和泛化能力。

表 4.3 不同视频集数量统计表

Platform	Number	Train Number	Val Number	Test Number
Facebook(FB)	101	71	20	10
Google(GG)	46	32	9	5
Snapchat(SC)	494	346	99	49
TikTok(TT)	103	72	21	10

表 4.4 不同平台视频对统计表

Platform	Train Pair Number	Val Pair Number	Test Pair Number
Facebook(FB)	2556	210	55
Google(GG)	528	45	15
Snapchat(SC)	60031	4950	1225
TikTok(TT)	2628	231	55

（2）构建视频对标签

在 RankNet 算法中，需要为每个样本对标记对应的标签，以表示样本之间的相对顺序。通常用标签“1”和标签“0”作为相对顺序的标签，其中标签“1”表示样本一的排序高于样本二的排序，标签“0”表示样本一的排序低于样本二的排序。具体到本研究工作中，可以根据 CTR 的比较结果构建样本之间的相对顺序。这个过程可以归纳为以下两个步骤：

步骤一，在 4.1.2 小节中提到了本研究所使用的语料库不仅包含四个平台的短视频广告，还包含一个用于存放 CTR 值的列表，该列表记录了所有短视频广告的 CTR 值。通过查询的方式，可以获取每个视频对中两个视频样本分别对应的 CTR 值。

步骤二，将两个 CTR 值代入式(4.10)中，根据比较结果得到视频对的标签。在式(4.10)

中国知网 https://www.cnki.net

中，用$CTRi$表示视频样本i的 CTR 值，用$CTRj$表示视频样本j的 CTR 值。标签“1”表示视频样本i的排序高于视频样本j的排序，标签“0”表示视频样本i的排序低于视频样本j的排序

（3）构建 RankNet 算法结构

在 RankNet 算法中，需要模型结构具有接受样本对作为输入的条件，且具有计算样本对中两个样本之间相关性分数的能力。具体到本研究工作中，需要对 3.1 和 3.2 节中提出的模型结构进行修改，以满足上述要求。整个过程可以归纳为以下两个步骤：

步骤一，将 3.1 节中提出的 SVARM 或 3.2 节中提出的 TFE-SVARM 采用并联方式进行组合。SVARM 并联之后的模型架构，称作 SVARM-Rank；TFE-SVARM 并联之后的模型架构，称作 TFE-SVARM-Rank。

步骤二，将 SVARM-Rank 或 TFE-SVARM-Rank 输出的计算结果输入到 Sigmoid 函数中，利用 Sigmoid 函数计算两个样本之间的相关性分数。

4.5 实验设置与结果分析

4.5.1 实验参数设置

在本文中，使用构建好的数据集和标签，并采用 RankNet 算法对提出的模型进行训练。在模型训练之后，根据模型输出的相关性分数构建推荐排序列表，其中分数较大的广告样本具有更高的排名。此外，本研究采用 Adam[53]作为优化器，学习率设定为 0.01，并将模型迭代了 100 次，以确保模型得到充分训练。在表 4.4 中，SC 平台具有数量最多的视频对。因此，以下所有实验只使用该平台的视频对作为模型训练数据。

在评价指标上，不仅计算准确率和归一化累计增益(NDCG)，还添加了其他三个评价指标，分别是：查准率、召回率以及 F1-Score，下是对这个五个评价指标作用的具体解释。

1. 查准率(Precision)：查准率是指模型预测结果为正例样本中，确实为正例样本所占的比例[54]。该指标用来衡量模型在预测正例样本的准确性。具体地，查准率越高表明模型将负例样本错误地判断为正例样本的情况发生得越少。计算过程如式(4.15)，其中 TP(True Positive)表示真正例，FP(False Positive)表示假正例。

$$Precision = \frac{TP}{TP+FP} \tag{4.15}$$

2. 召回率(Recall)：召回率是指所有真正例样本中，模型预测正例样本正确的比例。

中国知网 https://www.cnki.net

该指标用来衡量模型从所有样本中找出真正例样本的能力[54]。计算过程如式(4.16)，其中 FN(False Negative)表示假反例。

$$Recall = \frac{TP}{TP+FN} \tag{4.16}$$

3. F1 Score：F1 Score 本质上是查准率和召回率的调和平均值[54]。它是一种综合评价指标，只有当模型的查准率和召回率都较高时，模型才能够取得较高的 F1-Score，计算过程如式(4.17)。

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{4.17}$$

4. 准确率(Acc)：准确率是指在所有样本中，模型判断正确的样本数量占所有样本数量的比例，计算过程如式 (4.18)。

$$Acc = \frac{TP+TN}{TP+TN+FP+FN} \tag{4.18}$$

5. 归一化累计增益(NDCG)：NDCG 用来衡量推荐系统中推荐排序的质量，这是衡量推荐性能的重要指标。在 4.1.2 小结中，详细分析了 NDCG 的理论基础和计算过程。需要强调的是，本文根据测试数据构建了 1000 个广告组，每个广告组包含五个广告视频，并且每个广告组中不包含相同广告视频。最终，计算这 1000 个广告组的 NDCG@5 并求取平均值。

4.5.2 实验一：模型设置对比实验

在实验一中，设计了不同的实验设置来佐证本文所提出模型的有效性。详细的实验结果存放在表 4.5 中，该表格的第一列表示模型设置。“Baseline”表示基线模型，即在 3.1 小节中提出的“SVARM”，此外，在基线模型中采用直接拼接的特征融合方式；“Baseline+BLIP+Concat”表示在基线模型中添加文本模态，并采用直接拼接的特征融合方式，记作“BBC”。需要强调的是，BLIP 模型同样能够生成描述图像内容的文本[55]，但是与 LLaVA 相比，BLIP 只能够生成的文本内容比较概括，而 LLaVA 能够生成文本内容更加细致。“Baseline+LLaVA+Concat”表示在基线模型中添加 LLaVA 生成的文本特征，并依旧采用直接拼接的特融合方式，记作“BLC”。“Baseline+LLaVA+Gating”表示在基线模型中添加 LLaVA 生成的文本特征，但是选用基于门控机制的特征融合方式，即“TEF-

中国知网 https://www.cnki.net

SVARM”。第二列到第五列表示每种模型设置在不同评价指标下的实验结果。

实验结果表明，本文所提出的“TEF-SVARM”在五个评价指标上都取得了最佳测试结果。特别值得注意的是，“TEF-SVARM”在准确率方面，相比“Baseline”高出 2.8%，相比“BBC”高出 2.63。在 NDCG@5 方面，相比“Baseline”高出 0.64，相比“BBC”高出 0.15。这证明了“TFE-SVARM”的有效性，还证明大模型文本特征确实能够提升模型性能。

表 4.5 模型设置对比实验结果统计表

模型设置	查准率	召回率	F1-Score	Acc	NDCG@5
SVARM	57.55%	52.96%	55.16%	54.42%	92.67
BBC	57.77%	52.64%	55.09%	54.59%	93.16
BLC	57.76%	51.71%	54.57%	54.42%	92.12
TFE-SVARM	59.02%	59.28%	59.15%	57.22%	93.31

4.5.3 实验二：模态消融实验

为了进一步证明多模态的重要性，因此设计了模态消融实验。详细的实验结果存放在表 4.6 中，该表格的第一列表示模态设置，共分成三类：单模态、双模态以及全模态。

1. 单模态：“Visual”、“Audio”、“Text(LLaVA)”表示单模态模型。其中，“Visual”表示图像单模态模型、“Audio”表示音频单模态模型、“Text(LLaVA)”表示 LLaVA 文本单模态模型。在单模态模型中，删除了其余两种模态特征对应的特征编码模块以及特征融合模块，以构成单模态模型结构。
2. 双模态：双模态特征是指该模型使用两种模态特征作为模型输入。其中，“Visual+Audio”表示图像+音频的双模态模型、“Visual+Text(BLIP)”表示图像+BLIP 文本内容的双模态模型、“Visual+Text(LLaVA)”表示图像+LLaVA 文本内容的双模型模型。在双模态模型中，采用直接拼接的融合方式，以减小特征融合方式对实验结果的影响。
3. 全模态：全模态特征是指使用图像、音频和文本特征作为模型输入。其中“Visual+Audio+Text(BLIP)”表示图像+音频+BLIP 文本内容的模态设置；“Visual+Audio+Text(LLaVA)”表示图像+音频+LLaVA 文本内容的模态设置。该模态设置中，依旧采用直接拼接的融合方式。

具体实验结果存在表 4.6 中。首先在单模态特征中，“Visual”模态在查准率、F1-Score

中国知网 https://www.cnki.net

以及准确率的测试结果优于“Audio”和“Text(LLaVA)”。这表明图像模态贡献度高于音频模态和文本模态。其次在双模态特征中，“Visual+Audio”模态组合在四个指标下的测试结果，高于其他两种双模态组合。这表明图像模态与音频模态的组合对模型性能有积极影响。而图像模态与文本模态的组合对模型性能产生了消极影响。但是，从整体来看，双模态特征的测试结果优于单模态的测试结果。最后在三模态特征中，三模态特征的整体测试结果要优于双模态特征和单模态特征，这也进一步证明了使用多模态的重要性。

然而，在表 4.6 中注意到，模态设置为“Visual+Audio+Text(BLIP)”与模态设置为“Visual+Audio+Text(LLaVA)”，在四个评价指标下的实验结果十分接近，特别是在准确率方面，基线模型在添加了 LLaVA 文本特征的准确率还略低于基线模型添加 BLIP 文本特征的准确率，降低了 0.17%。然而，在 4.5.2 小节中提到过，LLaVA 生成的文本内容中图像内容信息的含量是远远高于 BLIP 生成的文本内容。这使得我们十分怀疑在基线模型中采用直接拼接的融合方式会限制 LLaVA 文本特征的作用。通过模型设置为“Text(LLaVA)”，即文本特征单模态实验也印证了前面的怀疑。具体而言，在仅使用 LLaVA 文本特征模型输入时，该模型在四个评价指标下也取得了不错的测试结果，尤其是准确率方面，仍达到了 47.63%。

为了解决这一问题，本文提出了一种基于门控机制的多模态融合策略。具体的设计过程、技术原理在 3.2.2 小节中有详细表述。为了进一步证明所提出的多模态融合策略的有效性，设计了实验三，即多模态融合策略对比实验。

表 4.6 模态消融实验结果统计表

模态设置	查准率	召回率	F1-Score	Acc
Visual	55.17%	53.08%	54.27%	52.38%
Audio	54.89%	53.36%	54.12%	51.78%
Text(LLaVA)	50.60%	45.06%	47.67%	47.63%
Visual+Audio	57.55%	52.96%	55.16%	54.42%
Visual+Text(BLIP)	47.24%	56.47%	51.45%	43.96%
Visual+Text(LLaVA)	52.40%	52.67%	52.54%	49.23%
Visual+Audio+Text(BLIP)	57.77%	52.64%	55.09%	54.59%
Visual+Audio+Text(LLaVA)	57.76%	51.71%	54.57%	54.42%

中国知网 https://www.cnki.net

4.5.4 实验三：多模态融合策略对比实验

在实验三中，设置了三种不同的多模态融合策略与本文所提出的基于门控机制的多模态融合策略进行比较，分别是：直接拼接、特征相加、特征相乘。

1. 直接拼接(Concat)：将不同模态的特征向量首尾相连，构成融合向量。具体的计算过程在 3.1.2 小节中有详细表述。
2. 特征相加(Add)：将不同模态的特征向量中，对应位置的元素进行累加，构成融合向量。
3. 特征相乘(Multiply)：将不同模态的特征向量中，对应位置的元素进行相乘，构成融合向量。

具体的实验结果存放在表 4.7 中，第一列为模态设置，共两类：第一类是“Visual+Audio”、第二类是“Visual+Audio+Text”。需要强调的是，在第二类模型设置中，使用 LLaVA 生成的文本特征。第二列为多模态融合方式，共有四种。第三列至第六列为使用不同模态融合方式在四个评价指标下的测试结果。

实验结果表明，在采用直接拼接的特征融合方式时，第一类模态设置与第二类模态设置在准确性方面取得了相同的实验成绩，均为 54.42%，并且其他三个评价指标的测试结果也都十分接近。然而，在采用本文所提出特征融合方式时，第二列模态设置在全部评价指标的实验成绩均得到了提升，尤其是准确率，提升了 2.8%。这也进一步证明，在利用大模型文本特征时，设计合理的特征融合策略是十分必要的。

表 4.7 多模态融合策略对比试验结果统计表

模型设置	融合策略	查准率	召回率	F1-Score	Acc
Vis+Aud	Concat	57.55%	52.96%	55.16%	54.42%
Vis+Aud	Add	56.54%	55.37%	55.95%	53.74%
Vis+Aud	Multiply	55.10%	51.39%	53.18%	51.87%
Vis+Aud	Gating	58.08%	56.57%	57.31%	55.61%
Vis+Aud+Text	Concat	57.76%	51.71%	54.57%	54.42%
Vis+Aud+Text	Add	57.00%	48.16%	52.21%	53.14%
Vis+Aud+Text	Multiply	58.56%	55.62%	57.05%	55.95%
Vis+Aud+Text	Gating	59.02%	59.28%	59.15%	57.22%

中国知网 https://www.cnki.net

4.6 本章小结

本章首先对本文所使用的数据集进行详细的介绍，并对数据集的规律，参数的信息进行了统计。同时，还介绍了广告效果评价指标和模型性能推荐指标，并且给出了详尽的理论分析和计算过程。其次，详细描述了图像特征、音频特征以及文本特征提取的具体流程。然后，介绍了模型训练采用方法、原理以及具体的实现过程。最后，通过实验结果与分析验证了所提出模型在短视频广告推荐领域的有效性。

中国知网 https://www.cnki.net

第5章 研究总结与未来展望

5.1 研究总结

如今，短视频广告作为短视频平台营收的主要来源，在推动短视频行业发展的方面具有重要的作用。而推荐系统可以将这种推动作用最大化，因此，设计并提出一种针对短视频广告推荐算法就显得尤为重要。然而，传统推荐系统在推荐新的短视频广告时，由于缺乏足够且有效的用户行为数据，导致推荐效果不佳。针对这一问题，本文提出了一系列相应的优化措施，本文所作的工作如下：

1. 介绍了传统推荐算法、视频推荐算法，并结合国内外相关文献对目前的研究现状予以总结和分析。
2. 在本研究工作中，提出了一种基于大模型文本特征增强与融合的短视频广告推荐模型(TFE-SVARM)，旨在提升推荐效果。该算法在 SVARM 的基础上添加了大模型生成的描述图像内容的文本特征，以此弥补图像特征中内容信息不足。实验结果表明，TFE-SVARM 的准确率达到了 57.22%，NDCG@5 达到了 93.31%，凸显推荐模型的有效性。
3. 针对用户行为数据不足的问题，提出了一种基于视听特征融合的短视频广告推荐模型(SVARM)，旨在解决物品冷启动问题。该模型仅使用视频自身所包含的图像特征、音频特征作为模型输入，进而避免了模型对用户行为数据的依赖。实验结果证明了该模型的有效性。
4. 针对特征信息不一致的问题，本文设计了一种基于门控机制的多模态融合策略，旨在充分利用大模型文本特征。该融合策略的核心思想是将 Sigmoid 看作一个可以灵活控制不同模态贡献程度的闸门。这使得模型可以根据不同的样本自适应地调节不同模态的权重，从而更充分、更全面发挥不同模态特征的作用。通过实验结果证明，本文所提出的多模态融合策略有助于提升模型的性能。

中国知网 https://www.cnki.net

5.2 未来展望

本文提出的基于大模型文本特征增强与融合的短视频广告推荐模型为短视频广告推荐领域拓展了新的研究思路和成果。然而，受限于本文作者的研究水平以及研究数据的影响，所提出的模型仍存在一些问题需要进一步探究：

1. 文本过滤机制不完善问题：虽然本研究工作提出了一种基于文本相似度的过滤机制，但是依旧存在少量与图像内容不相符的文本难以过滤掉。因此，需要进一步完善文本过滤机制，提升检测异常文本的能力。
2. 视频对数量差异过大问题：由表 4.4 可以看出，四个平台的视频对数量存在严重的不均衡问题。具体地，SC 平台具有最多的视频对数量，而其他三个平台全部的视频对数量还不及 SC 平台视频对数量的一半。这种数据量不均衡的情况会严重阻碍模型的训练过程，导致模型推荐效果变差。因此，在后续的研究工作中，需要收集更多其余三个平台的视频样本，以改正这种数据量不均衡的问题。

中国知网 https://www.cnki.net

参考文献

[1] Jiang X, Geng Y, Xiong Y, et al. A Privacy-aware Framework for Assessing and Recommending Short Video Advertisement[C]//2023 IEEE International Symposium on Product Compliance Engineering-Asia (ISPCE-ASIA). IEEE, 2023: 1-7.

[2] Zhang Y, Tao F, Liu X, et al. Short Video-based Advertisements Evaluation System: Self-Organizing Learning Approach[J]. arXiv preprint arXiv:2010.12662, 2020.

[3] Zhan R, Pei C, Su Q, et al. Deconfounding duration bias in watch-time prediction for video recommendation[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022: 4472-4481.

[4] Yu S, Liu Z, Wan S, et al. MDP2 Forest: A Constrained Continuous Multi-dimensional Policy Optimization Approach for Short-video Recommendation[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022: 2388-2398.

[5] Markapudi B, Chaduvula K, Indira D, et al. Content-based video recommendation system (CBVRS): a novel approach to predict videos using multilayer feed forward neural network and Monte Carlo sampling method[J]. Multimedia Tools and Applications, 2023, 82(5): 6965-6991

[6] 周青松, 蔡晓东, 刘家良. 结合社交影响和长短期偏好的个性化推荐算法[J]. 浙江大学学报(工学版), 2023, 57(03): 495-502.

[7] Zhang Y, Tao F, Liu X, et al. Short Video-based Advertisements Evaluation System: Self-Organizing Learning Approach[J]. arXiv preprint arXiv:2010.12662, 2020.

[8] Lin X, Chen X, Song L, et al. Tree based progressive regression model for watch-time prediction in short-video recommendation[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023: 4497-4506.

[9] Lei C, Liu Y, Zhang L, et al. Semi: A sequential multi-modal information transfer network for e-commerce micro-video recommendations[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021: 3161-3171.

[10] Gong X, Feng Q, Zhang Y, et al. Real-time Short Video Recommendation on Mobile Devices[C]//Proceedings of the 31st ACM international conference on information and

中国知网 https://www.cnki.net

knowledge management. 2022: 3103-3112.

[11] Yu F, Zeng A, Gillard S, et al. Network-based recommendation algorithms: A review[J]. Physica A: Statistical Mechanics and its Applications, 2016, 452: 192-208.

[12] Nair A, Benny O, George J. Content based scientific article recommendation system using deep learning technique[C]//Inventive Systems and Control: Proceedings of ICISC 2021. Springer Singapore, 2021: 965-977.

[13] 许海玲, 吴潇, 李晓东, 等. 互联网推荐系统比较研究[J]. 软件学报, 2009, 20(02): 350-362.

[14] 任妮, 吴琼, 栗荟荃. 推荐系统算法分析与研究[J]. 电子技术与软件工程, 2022(17): 238-241.

[15] Jiang L, Liu R, Jia C. User-location distribution serves as a useful feature in item-based collaborative filtering[J]. Physica A: Statistical Mechanics and its Applications, 2022, 586: 126491.

[16] Wang H, Shen Z, Jiang S, et al. User-based collaborative filtering algorithm design and implementation[C]//Journal of Physics: Conference Series. IOP Publishing, 2021, 1757(1): 012168.

[17] Ebesu T, Shen B, Fang Y. Collaborative memory network for recommendation systems[C]//The 41st international ACM SIGIR conference on research & development in information retrieval. 2018: 515-524.

[18] Wu J, Cai R, Wang H. Déjà vu: A contextualized temporal attention mechanism for sequential recommendation[C]//Proceedings of The Web Conference 2020. 2020: 2199-2209.

[19] Li M, Wen L, Chen F. A novel collaborative filtering recommendation approach based on soft co-clustering[J]. Physica A: Statistical Mechanics and its Applications, 2021, 561: 125140.

[20] Sharma S, Rana V, Malhotra M. Automatic recommendation system based on hybrid filtering algorithm[J]. Education and Information Technologies, 2022, 27(2): 1523-1538.

[21] Forouzandeh S, Rostami M, Berahmand K. A hybrid method for recommendation systems based on tourism with an evolutionary algorithm and topsis model[J]. Fuzzy Information and Engineering, 2022, 14(1): 26-50.

[22] Zhao C, Li C, Xiao R, et al. CATN: Cross-domain recommendation for cold-start users via

中国知网 https://www.cnki.net

aspect transfer network[C]//Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval. 2020: 229-238.

[23] Chen T, Yin H, Ye G, et al. Try this instead: Personalized and interpretable substitute recommendation[C]//Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval. 2020: 891-900.

[24] Feng J, Xia Z, Feng X, et al. RBPR: A hybrid model for the new user cold start problem in recommender systems[J]. Knowledge-Based Systems, 2021, 214: 106732.

[25] Wang W, Lin X, Wang L, et al. Equivariant Learning for Out-of-Distribution Cold-start Recommendation[C]//Proceedings of the 31st ACM International Conference on Multimedia. 2023: 903-914.

[26] 阎红灿, 王子茹, 李伟芳, 等. 伴随时间的模糊聚类协同过滤推荐算法[J]. 计算机工程与科学, 2021, 43(11): 2084-2090.

[27] Zhang Y, Bai Y, Chang J, et al. Leveraging Watch-time Feedback for Short-Video Recommendations: A Causal Labeling Framework[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 4952-4959.

[28] Patil S, Patil R, Kotwal A. Micro video recommendation in multimodality using dual-perception and gated recurrent graph neural network[J]. Multimedia Tools and Applications, 2023: 1-30.

[29] Cai D, Qian S, Fang Q, et al. Heterogeneous hierarchical feature aggregation network for personalized micro-video recommendation[J]. IEEE Transactions on Multimedia, 2021, 24: 805-818.

[30] Liu Y, Liu Q, Tian Y, et al. Concept-aware denoising graph neural network for micro-video recommendation[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. 2021: 1099-1108.

[31] Lei C, Liu Y, Zhang L, et al. Semi: A sequential multi-modal information transfer network for e-commerce micro-video recommendations[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021: 3161-3171.

[32] Kyurkchiev N, Markov S. Sigmoid functions: some approximation and modelling aspects[J]. LAP LAMBERT Academic Publishing, Saarbrucken, 2015, 4.

中国知网 https://www.cnki.net

[33] Lau M M, Lim K H. Review of adaptive activation function in deep neural network[C]//2018 IEEE-EMBS Conference on Biomedical Engineering and Sciences (IECBES). IEEE, 2018: 686-690.

[34] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 807-814.

[35] Yu Y, Si X, Hu C, et al. A review of recurrent neural networks: LSTM cells and network architectures[J]. Neural computation, 2019, 31(7): 1235-1270.

[36] Wang M, Lu S, Zhu D, et al. A high-speed and low-complexity architecture for softmax function in deep learning[C]//2018 IEEE asia pacific conference on circuits and systems (APCCAS). IEEE, 2018: 223-226.

[37] Tao F, Busso C. Gating neural network for large vocabulary audiovisual speech recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2018, 26(7): 1290-1302.

[38] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[39] Richardson M, Dominowska E, Ragno R. Predicting clicks: estimating the click-through rate for new ads[C]//Proceedings of the 16th international conference on World Wide Web. 2007: 521-530.

[40] Baltrunas L, Makcinskas T, Ricci F. Group recommendations with rank aggregation and collaborative filtering[C]//Proceedings of the fourth ACM conference on Recommender systems. 2010: 119-126.

[41] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.

[42] Hershey S, Chaudhuri S, Ellis D, et al. CNN architectures for large-scale audio classification[C]//2017 ieee international conference on acoustics, speech and signal processing (icassp). IEEE, 2017: 131-135.

[43] Gemmeke J, Ellis D, Freedman D, et al. Audio set: An ontology and human-labeled dataset

中国知网 https://www.cnki.net

for audio events[C]//2017 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2017: 776-780.

[44] Devlin J, Chang M, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[45] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2024, 36.

[46] Han K, Wang Y, Chen H, et al. A survey on vision transformer[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(1): 87-110.

[47] Burges C. From ranknet to lambdarank to lambdamart: An overview[J]. Learning, 2010, 11(23-581): 81.

[48] Liu T Y. Learning to rank for information retrieval[J]. Foundations and Trends® in Information Retrieval, 2009, 3(3): 225-331.

[49] Li M, Liu X, van de Weijer J, et al. Learning to rank for active learning: A listwise approach[C]//2020 25th International Conference on Pattern Recognition (ICPR). IEEE, 2021: 5587-5594.

[50] Cao Z, Qin T, Liu T Y, et al. Learning to rank: from pairwise approach to listwise approach[C]//Proceedings of the 24th international conference on Machine learning. 2007: 129-136.

[51] Li M, Liu X, van de Weijer J, et al. Learning to rank for active learning: A listwise approach[C]//2020 25th International Conference on Pattern Recognition (ICPR). IEEE, 2021: 5587-5594.

[52] Ho Y, Wookey S. The real-world-weight cross-entropy loss function: Modeling the costs of mislabeling[J]. IEEE access, 2019, 8: 4806-4813.

[53] Kingma D, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

[54] Goutte C, Gaussier E. A probabilistic interpretation of precision, recall and F-score, with implication for evaluation[C]//European conference on information retrieval. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005: 345-359.

[55] Li J, Li D, Xiong C, et al. Blip: Bootstrapping language-image pre-training for unified vision-

中国知网 https://www.cnki.net

language understanding and generation[C]//International conference on machine learning. PMLR, 2022: 12888-12900.

中国知网 https://www.cnki.net