分 类 号： TP391

学校代码： 10109

密　　级： 公 开

太原科技大学硕士学位论文

(专业型)

学位论文题目：基于特征交互的广告点击率预测算法与应用

英 文 题 目：Research and Application of Advertising Click-Through Rate Prediction Method Based on Feature Interaction

研 究 生 姓 名：陈海青

导师姓名及职称：蔡江辉　教授

培　养　单　位：计算机科学与技术学院

工程领域/专业：计算机技术

论文提交日期：2023 年 5 月 3 日

论文答辩日期：2023 年 5 月 31 日

答辩委员会主席：王文剑 教授

中国知网 https://www.cnki.net

中 文 摘 要

点击率预测(CTR)是推荐系统中一个很重要的研究方向。广告点击率预测(CTR)指的是在特定的情形下需要对用户下一个可能点击的某个广告，在点击前系统根据推荐算法来预测其可能被点击概率大小。如果广告有很大概率被点击就向该用户展示广告，如果概率低，就不展示。广告推荐和投放对于许多互联网公司来说是必不可少的。在大数据时代的点击率(Click-through Rate Prediction，CTR)预测任务中，输入数据不仅数量多而且特征维度很高，对其中的重要特征选择、特征交互方式极大地影响了预测性能。本文针对点击率预测任务中的特征选择和特征交互方面存在的问题进行优化改进，其主要研究内容包括：

(1)提出了一种基于特征加权与自动交互的点击率预测模型。首先，针对以往点击率预测模型在特征重要性选择过程中由于降维而存在信息丢失的问题，提出一种不需要降维的特征加权方法，该方法通过引入 ECANet 模块学习原始特征权重，有效避免了信息丢失；其次，针对单一模型建模能力有限、可解释性差等缺陷，分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，最后将两者的输出拼接到一起输入到预测层中进行预测。通过在 Criteo 等四个经典点击率数据集上的实验，证明了我们提出的加权方法能够有效解决信息丢失问题，而且使用显式和隐式相结合的特征交互方式可以增强模型的可解释性。

(2)提出了一种基于全局注意网络与特征交互的点击率预测模型。针对大多数模型将学习到的低阶和高阶特征信息直接拼接进行预测，而忽略低阶和高阶特征信息之间的关系。我们设计了一个全局注意交互模块(GAN)，将交互层学习到的高低阶交互信息进行进一步交互，充分挖掘重要信息。此外该模型利用注意力机制来学习不同交互特征和原始嵌入特征的重要性。最后，通过在 Criteo、KDD12 和 MovieLens-1M 数据集上的离线实验结果，证明该方法能够有效提高点击率预测的准确性。

(3)设计了一个基于特征交互的点击率预测原型系统。该系统利用收集到的用户特征来计算广告被点击的概率，从而帮助平台为每一位用户推荐最符合其偏好的广告，精准推荐可以增加用户粘性，提升平台的广告投放质量。

关键词：点击率预测；特征交互；特征选择；注意力机制；深度神经网络

中国知网 https://www.cnki.net

ABSTRACT

Click-through rate prediction (CTR) is a very important research direction in recommendation system. Click-through rate prediction (CTR) refers to a certain advertisement that needs to be clicked next by the user under certain circumstances. Before clicking, the system predicts the probability that it will be clicked according to the recommendation algorithm. If the AD has a high probability of being clicked, show the user the AD; if the probability is low, don't show it. Advertising recommendation and placement are essential for many Internet companies. In the Click-Through Rate Prediction (CTR) prediction task in the era of big data, the input data is not only large in quantity but also high in feature dimension, which greatly affects the prediction performance of important feature selection and feature interaction. This paper optimizes and improves the problems existing in feature selection and feature interaction in the click-through rate prediction task. The main research contents include:

(1) A click-through rate prediction model based on feature weighting and automatic interaction is proposed. Firstly, aiming at the problem of information loss caused by dimensionality reduction in the selection process of feature importance in the previous click-through rate prediction model, a feature weighting method without dimensionality reduction is proposed, which can effectively avoid information loss by introducing ECANet module to learn the original feature weight. Secondly, in view of the limited modeling ability and poor interpretability of a single model, the multi-head self-attention network and deep neural network (DNN) are respectively used to automatically learn explicit and implicit feature interactions. Finally, the outputs of the two are spliced together and input into the prediction layer for prediction. Experiments on four classical click-through rate data sets, such as Criteo, prove that our proposed weighting method can effectively solve the problem of information loss, and the combination of explicit and implicit feature interaction can enhance the interpretability of the model.

(2) A click-through rate prediction model based on the interaction between

中国知网 https://www.cnki.net

global attention network and feature is proposed. For most models, the learned low-order and high-order feature information is directly spliced for prediction, while the relationship between the low-order and high-order feature information is ignored. We designed a global attention interaction module (GAN) to further interact the high and low order interaction information learned from the interaction layer and fully explore the important information. In addition, the model uses attention mechanisms to learn the importance of different interactive features and original embedded features. Finally, the off-line experimental results on Criteo, KDD12 and MovieLens-1M data sets demonstrate that the method can effectively improve the accuracy of click-through rate prediction.

(3) A click-through rate prediction system based on feature interaction is designed. The system uses the collected user characteristics to calculate the probability of an advertisement being clicked, so as to help the platform recommend the most suitable advertisement for each user. Accurate recommendation can increase user stickiness and improve the quality of advertisement delivery on the platform.

Key words: Click-through rate prediction;Feature interaction; Feature weighting; Attention mechanism; Deep neural network

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....3
1.2.1 基于传统机器学习的点击率预测模型.....3
1.2.2 基于深度学习的点击率预测模型.....4
1.2.3 基于注意力机制的点击率预测模型.....5
1.3 主要研究内容.....5
1.4 论文组织结构.....6
第二章 基于特征加权与自动交互的点击率预测模型.....7
2.1 引言.....7
2.2 相关工作.....9
2.2.1 点击率预测.....9
2.2.2 ECANet 模块.....9
2.2.3 多头自注意网络和残差网络.....9
2.3 基于特征加权与自动交互的预测算法.....10
2.3.1 输入层.....10
2.3.2 嵌入层.....10
2.3.3 ECANet 层.....11
2.3.4 交互层.....12
2.3.5 输出层.....13
2.3.6 损失函数.....14
2.4 实验分析.....14
2.4.1 实验数据集及设置.....14
2.4.2 FWAI 模型与基线模型性能对比.....16
2.4.3 ECANet 层对模型性能的提升.....16
2.4.4 显式和隐式交互方式对模型性能的影响.....17
2.4.5 超参数设置对模型性能的影响.....18
2.5 本章小结.....19
第三章 基于全局注意网络与特征交互的点击率预测模型.....21
3.1 引言.....21
3.2 相关工作.....22
3.3 模型介绍.....23
3.3.1 嵌入层.....23
3.3.2.交互层.....24

中国知网 https://www.cnki.net

3.3.3 全局注意力层.....25
3.3.4 预测层.....25
3.3.5 损失函数.....25
3.4.实验.....26
3.4.1 数据集描述.....26
3.4.2 对比模型.....26
3.4.3 参数设置.....26
3.4.4 评价指标.....26
3.4.5 离线实验结果.....27
3.4.6 消融实验.....27
3.5 本章小结.....28
第四章 基于特征交互的点击率预测原型系统的设计与实现.....29
4.1 引言.....29
4.2 系统可行性分析.....30
4.3 系统设计.....30
4.3.1 系统总体功能图.....30
4.3.2 系统页面设计.....31
4.3.3 广告点击率预测模块结果展示.....36
4.4 系统开发环境.....36
4.5 本章小结.....36
第五章 总结与展望.....37
5.1 总结.....37
5.2 展望.....37
参考文献.....39

中国知网 https://www.cnki.net

第一章 绪 论

1.1 研究背景与意义

随着大数据时代的到来，现在世界上的所有的信息大概有多少呢？2020 年美国南加州大学(USC)曾发布过一组数据。该报告指出截至 2020 年，人类创造的信息总量约为 295EB，如果把这些信息放到 CD 里存储起来，大约需要 4060 亿张。再过 5 年，这个量还会增长 10 倍左右。但拥有海量的数据，并不等于我们就能掌握和利用他们。实际上大数据带来的最直接的挑战就是如何让普通人在数据汪洋中找到自己需要的内容。目前来看，推荐系统是解决上述“信息过载”问题最好的手段之一。推荐系统主要是向目标用户推荐其可能会感兴趣的物品。推荐系统近年来非常流行，应用于各行各业。而网络广告的点击率预测(Click-through Rate Prediction，CTR)是推荐系统中一个很重要的研究方向。

网络广告指的是通过各种各样的网站或平台，以文字、视频、图片等各种形式，直接或间接的在互联网发布的商业广告。网络广告是随着 Internet 的发展而诞生的，1994 年美国著名的 Wired 杂志第一次在其主页为 14 个公司做了广告，成为了网络广告史上的里程牌事件。网络广告可以在互联网上向目标用户推销商家的产品或服务，增加了宣传范围，提升了影响力。而传统线下广告的表现形式有限且内容比较单调、无趣。比如平面广告就是普通的文字或图片，音频广告只能是声音。并且以往的媒体对广告的形式和内容也有着不同程度的限定。与传统的线下广告相比，而网络广告的表现形式则十分丰富。在浏览的过程中，受众不但能够看广告，还可以与广告互动。随着技术的成熟，有些广告还能够以游戏的形式出现，使用户在玩游戏中宣传产品，增加了用户对广告的记忆。这些五花八门的表现形式与内容，可以传递多维立体的广告信息，让用户全方位、多角度、立体化的感受商品或服务。使得网络广告具有无与伦比的的竞争优势，如传播覆盖面广，受众基数大，传播速度快，不受时间、空间限制，形式丰富等多重优势。

网络广告的发展，同广告推荐和投放密不可分。对于许多互联网公司来说，广告推荐和投放是重要的营收来源，各大互联网公司通过数字化的产品聚合了大量的用户，利用各种各样的方法让用户长时间地停留在产品上，再利用大量的流量吸引广告主来平台上投放自己产品的广告，然后把广告推送给用户，广告主就可以从用户身上获取他想要的价值。在这样一个体系中，用户体验了数字化的网络模式，广告主找到了他的目标用户并将自己的产品进行了宣传，各个互联网平台也获得了来自广告主投放广告时所花费的钱，比如腾讯和新浪微博等。这些任务背后的主要技术是点击率预测，即 CTR。如图

中国知网 https://www.cnki.net

1.1 所示，根据 CNNIC 统计数据显示，2023 年中国互联网广告市场规模预计将达到 12877 亿元，同比增长了约 16%，总体规模比 2017 年扩大了 3.44 倍，从 2017 年开的始终保持高速发展，充分证明我国拥有着广阔的网络广告市场空间和极大的广告发展潜力。

图 1.1 2016-2020 年中国互联网广告市场规模

Fig1.1 Size of China's Internet advertising market from 2016 to 2020

广告点击率预测(CTR)指的是在特定的情形下需要对用户下一个可能点击的某个广告，在点击前系统根据推荐算法来预测其可能被点击概率大小。如果广告有很大概率被点击就向该用户展示广告，如果概率低，就不展示。早期的点击率预测主要通过专家手动构造特征工程，建立一种人工干预的特征相关性，但这类方法只能将特征两两之间进行交互计算，因此其泛化能力较弱。近年来深度学习在计算机视觉、自然语言处理、图像分类等领域取得了突破性的进展。很多学者将其运用到了点击率预测的研究中。由于其能够通过神经网络来拟合各种复杂函数，所以能够更高效地挖掘高阶特征及信息交互。

本文主要针对特征选择和高低阶特征交互方面进行了研究，具有十分重要的意义。其研究意义可以分为以下三点：

(1)在广告推荐场景中，输入数据不仅数量多而且特征维度很高。以往的预测模型在特征选择时存在信息干扰或丢失等问题，而且模型的建模能力有限、可解释性差。因此急需一种可以解决这些问题的算法。

(2)在点击率预测研究中，大多数模型将学习到的低阶和高阶特征信息直接拼接进行预测，而忽略低阶和高阶特征信息之间的关系。而这一问题极大的影响了预测的准确率，

中国知网 https://www.cnki.net

目前现有的算法还没有很好的解决思路。

(3)现在很多广告点击率预测系统虽然设计的功能很强大，但其对于数据特征的处理以及最终的点击率预测都表现一般。本文设计的系统利用收集到的用户特征来计算广告被点击的概率，从而帮助平台为每一位用户推荐最符合其偏好的广告。

1.2 国内外研究现状

1.2.1 基于传统机器学习的点击率预测模型

在广告点击率预测任务中，已经提出了很多模型。其中，最早使用的是线性模型，即逻辑回归(Logistic Regression，LR)，因为 LR[1]模型是线性回归模型，所以结构简单，可解释性好，实现起来简单，时间复杂度低，适合工业界使用。但特征之间为线性关系。模型本身不具备非线性能力，需要通过加入非线性特征的方式来实现非线性的描述能力。表达能力不强，会造成信息损失；而且需要依赖手工特征工程，无法通过算法的自动化方式来做特征工程，来提升效果。于是，Polynomial-2[2] (Poly2)模型将所有的输入特征都进行两两组合并为交互后的特征分配一个权重参数，使模型可以挖掘出任意两个特征之间的交互信息。但由于数据稀疏，模型无法很好的学习参数。对此，Steffen[3]提出了因子分解机(Factorization Machine，简称 FM)，FM 模型的输出结果由两部分组成，一部分是线性模型，另一部分是由每个特征的二阶交叉组合构成。因此 FM 模型可以看作是由 LR 模型延伸扩展而来，由于模型可以为每个特征都单独学习一个稠密隐向量，使得 FM 模型能很好地从稀疏的特征向量中学习到隐藏于其中的特征关联关系。在具备高效的计算性能的同时又具备良好的可解释性，但主要缺点是，它对所有特征之间都进行交互建模，没有对不同的特征区别对待，引入了大量冗余的交互信息。为此，Juan 等人通过引入了“域”这一概念对 FM 模型进行优化和改进，并提出了域感知分解机 FFM[4](Field-aware Factorization Machines，FFM)模型。他们在因子分解机的结构中加入了域的概念，把广告数据集中那些性质相近或相同的特征放入一个域内，不同性质的特征属于不同的域。在 FFM 中，模型针对每一个特征及其所在的域，都会通过学习得到一个包含所有信息的隐向量。所以，隐向量不仅与特征有关，也与其所在的域有关。这就是所谓的“域感知”。通过该方法可以更好的挖掘出不同特征域之间的隐含信息。但由于 FFM 模型的表达式无法进行化简，所以时间复杂度与 FM 相当，在特征维度较大且数据量较多时，FFM 模型的运算性能将远不如 FM。

上述模型虽然表现出一定的效果，但大多都不能对特征间的所有组合方式构造与之相对应的组合特征。除此之外，这些模型都属于浅层结构，难以提取特征间存在的高阶

中国知网 https://www.cnki.net

非线性交互信息，无法进行更加复杂的特征交互学习，因此模型的表现力仍然有限。为了提升模型的泛化能力，一个顺其自然的想法就是应用深度神经网络加深浅层网络。

1.2.2 基于深度学习的点击率预测模型

随着深度学习[5-6]的发展，神经网络在挖掘特征组合方面展现出极大的优势。如：Huifeng Guo 等提出了基于向量积的神经网络(Product-based Neural Networks，PNN)。PNN[7]通过二阶向量积层对 FM 嵌入后的向量两两进行向量内积或外积操作，将内积或者外积结果进行一定的变换作为之后全连接层的输入。Xiangnan He 等在 2017 年提出了神经网络因子分解机(Neural Factorization Machines，NFM)。NFM[8]通过二阶交互池化层对 FM 嵌入后的向量两两进行元素级的乘法操作，形成相同维度的向量，将其求和后作为全连接层的输入。Weinan Zhang 等提出了因子分解机神经网络模型(Factorization Machine supported Neural Network，FNN)。FNN[9]模型先使用 FM 进行预训练，然后将预训练得到的特征交互向量及其权重作为神经网络的第一层参数的初始值，之后叠加多层全连接层，最终输出预测的点击率。由于 FFN 的初始值是通过 FM 预训练得到的，因此在神经网络中训练的时候，模型收敛速度会加快；并且由于预训练已经包含了特征交互的信息，所以可以不用做额外的特征工程；不过由于整个训练过程分成了预训练和预测两个阶段，所以模型不是一个端到端的训练过程，而是一种基于参数的迁移学习。

上述算法通过引入深度神经网络来挖掘特征之间的高阶组合，能够显著增强模型的学习能力，这种方法为以后的深度推荐模型发展开辟了新的道路。但其专注于高阶组合特征，但是却没有对低阶特征进行建模。

对此，Wide&Deep[10]模型被提出。Wide&Deep 模型的主要思路正如其名，是一个由 Wide 和 Deep 构成的混合模型。在此模型中，Wide 部分是线性模型，其主要功能是使模型具备更高的“记忆能力”；Deep 部分是由神经元网络组成的，它的功能是赋予模型“泛化能力”，由于该模型使用双塔架构，所以它同时具备了两个部分各自的优势，可以对海量数据进行快速的计算和存储。同时，它还具备了很强的表达能力。在当时不仅快速地变成了业内争相使用的主要模式，而且还产生了很多以 Wide&Deep 模型架构为基础的其他模型，直到今天都有很强的影响力。如：在 2017 年，华为 Huifeng Guo 等提出了深度因子分解机模型(Deep Factorization Machine, DeepFM)，DeepFM[11]模型也采用了双塔结构，它将 Wide&Deep 模型中 Wide 部分 FM 替换 LR。因为 FM 模型能够自动学习交互特征，避免了繁琐的人工特征工程，提升了模型的效率。而且 DeepFM 模型的 FM 和 Deep 两部分可以共享原始输入特征，减少了模型在训练过程中需要学习的参数，有利于训练。但是这样的模型学习出的交互特征是隐式的。同时它们的特征交互是元素

中国知网 https://www.cnki.net

级的，而不是在特征向量之间操作交互来体现的。于是，2018 年 Jianxun Lian[12]等提出了极深因子分解机模型(xDeepFM)来应对这一问题，该模型同时以显式和隐式的方式自动学习高阶的特征交互，使特征交互发生在向量级，还兼具记忆与泛化的学习能力。通过大量实验证明了 xDeepFM 模型的有效性。

1.2.3 基于注意力机制的点击率预测模型

注意力机制[13-14](Attention Mechanism)是机器学习中的一种数据处理方法，广泛应用在自然语言处理(NLP)[15-16]、图像处理(CV)[17-18]及语音识别[19-20]等各种不同类型的机器学习任务中。随着注意力结构的兴起，一些点击率预测模型也尝试在模型中引入注意力来进行特征交互，进而提高预测能力。Jun 等人[21]提出了 AFM 模型，AFM 使用注意力来加强 FM 模型，使得不同的交互特征对结果的贡献不同。在每一次计算中，一对特征交互的结果会经过一个注意力网络来计算其各自的权重，这些权重与交互向量相乘，来衡量对结果贡献的大小。受到自然语言处理中自注意力结构的影响，AutoInt[22]模型使用一个带残差链接的多头注意力网络来显式的进行不同阶的特征交互，同时其得到的权重赋予模型一定程度的可解释性，此外模型可建模任意高阶特征交互。模型使用的多头注意力机制，相当于可以同时再多个子空间中，根据不同的特征之间的相关性策略去让特征交互然后融合，再这个交互过程中，特征之间通过互相计算相关性得到多个权重，然后加权汇总，最后使得每个特征上都有其他特征的信息，且其他特征的信息重要性也根据权重得到了体现。但模型的训练时间较长，时间复杂度和空间复杂度都比较高。在此基础上，InterHAt[23]模型将注意力结构升级为了 Transformer 模块，使得训练的效率进一步提高。由于注意力网络在点击率预测中取得了越来越好的效果，因此成为近年来学术界的研究热点。

1.3 主要研究内容

本课题主要的研究内容是基于特征交互的点击率算法，主要研究内容可以分为三点：

(1)提出了一种基于特征加权与自动交互的预测模型。此模型为了解决在点击率预测任务中特征选择时容易存在信息干扰或丢失等问题。首先，引入 ECANet[24]模块提出一种不降维的特征加权方法，该方法可以通过对 k 个相邻特征进行一维卷积有效实现。然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，最后将两者相结合进行预测，从而有效挖掘特征间的交互信息。一方面，它具备良好的解释性；另一方面，它能同时以显式和隐式的方式自动学习任意低阶和高阶的特征交互。

中国知网 https://www.cnki.net

通过在四个真实数据集上的实验，验证了其能够比以往的预测模型获得更好的准确度。

(2)提出了一种基于全局注意网络与特征交互的点击率预测模型。设计了一个全局交互模块(GAN)来学习高阶交互，同时平衡多个特征的不同影响。其主要作用是显式地捕获原始特征(即低阶)和生成的交互特征(即高阶)之间的关系。此外，我们利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。最后，通过实验结果证明了我们提出的方法的有效性。

(3)设计了一个基于特征交互的点击率预测原型系统。

该系统拥有多种功能，能够从各个方面来收集到用户的特征，最后利用收集到的用户特征来计算广告被点击的概率。本文主要从系统可行性分析、结果展示、页面设计等方面进行介绍。

1.4 论文组织结构

整篇论文的全部内容由五个章节组成，具体组织结构如下：

第一章是绪论，主要阐述了选题的背景与意义，并对目前的国内外研究现状进行了介绍。

第二章主要介绍我们提出的基于特征加权与自动交互的预测模型 FWAI，首先，对该模型的思想与理论进行了详细的介绍，然后，通过从不同的角度做消融实验来对模型进行分析。

第三章提出了基于全局注意网络的点击率预测模型 CGAN，并且对其思想与过程进行详细的描述，之后对其实际的实验效果进行分析。

第四章设计了一个基于特征交互的点击率预测系统，首先在引言部分解释了开发系统的意义，然后从系统可行性分析和系统功能两方面来详细介绍该系统。

第五章总结了本论文的研究成果，并且提出了下一步的工作方向。

中国知网 https://www.cnki.net

第二章 基于特征加权与自动交互的点击率预测模型

本章首先通过引言来提出研究动机，然后对点击率预测算法的相关工作进行简单介绍，之后提出了一种基于特征加权与自动交互的点击率预测模型，用于学习原始特征权重并进行自动交互。首先，引入 ECANet[24]模块提出一种不降维的特征加权方法，该方法可以通过对 k 个相邻特征进行一维卷积有效实现。然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，最后将两者相结合进行预测，弥补了单一模型的缺陷。一方面，提出的模型具备良好的解释性；另一方面，它可以同时用显式和隐式的特征交互方式去自动学习任意高低阶的特征交互信息。通过在 Criteo、KDD12、MovieLens-1M 和 Avazu 等经典点击率数据集上的实验，验证了本模型比以往的预测模型获得了更好的准确度。

2.1 引言

点击率(CTR)预测[25-27]，指的是在特定的情形下需要对用户下一个可能点击的某个广告，在点击前系统根据推荐算法来预测其可能被点击概率大小。如果广告有很大概率被点击就向该用户展示广告，如果概率低，就不展示。预估的点击率可能会影响后续的推荐决策，例如项目排名和广告投放。准确的预测不仅可以改善用户体验，还可以提高服务提供商的利润。

在 CTR 预测任务中，原始输入特征起着重要作用。由于直接使用原始特征很少能获得理想的预测结果，数据科学家一般会对原始特征进行交互获得更加全面的数据信息，以生成最佳预测系统。但并非所有的特征交互都对预测任务有用，无用的特征交互可能引入噪声信号，进而导致过度拟合。同时，模型的输入特征大多都是类别特征，而且数量在几十到数百，不同的特征对预测目标影响不同。所以大多数现有的 CTR 模型都需要解决以下两个问题。第一，对于重要性不同的输入特征如何进行选择。第二，如何构建有效的特征交互。

在早期阶段，Polynomial-2 (Poly2)模型将输入特征进行两两组合并为每一个交叉项设置一个权重参数。但由于数据稀疏，模型无法很好的学习参数。于是，Steffen 提出了因子分解机(FM)，它在具备高效的计算性能的同时又具备良好的可解释性：但主要缺点是，它对所有特征交互进行建模，包括有用和无用的组合。与无用特征的交互可能会引入噪声并降低性能。近年来，深度神经网络以其强大的特征表示学习能力在计算机视觉、语音识别和自然语言处理方面取得了成功。出现了许多基于深度学习的预测模型如：FNN、PNN、Wide&Deep 等模型。这些模型的共同缺点是，它们更多的对高阶特征交互

中国知网 https://www.cnki.net

进行关注，而很少去关注低阶交互。这些模型都使用深度神经网络(DNN)来学习高阶特征交互，然而 DNN 是一种典型的隐式建模方法，因此无法用来直观的解释某些特征组合是否是有意义的。而 FNN、Wide&Deep、(Attentional Factorization Machines AFM)、DeepFM、XdeepFM、AutoInt 等，这些模型则通过显式建模来学习不同阶的特征组合，并将学习到的特征映射到低维空间，增强了模型的解释性。但是显式特征交互的缺点是：(1)对非线性的建模能力是有限的；(2)很难扩展到更高阶的特征交互；(3)数据稀疏性很大时，模型训练比较困难；(4)对所有特征交叉项一视同仁，可能会限制模型的表达能力。为了弥补显式和隐式模型的不足，我们用多头自注意网络[10]和深度神经网络(DNN)去自动学习显式和隐式的特征交互。一方面，提出的方法具备良好的解释性；另一方面，它可以同时用显式和隐式的特征交互方式去自动学习任意高低阶的特征交互信息。

同时，在广告推荐场景中，输入数据不仅数量多而且特征维度很高，在特征选择时容易存在信息干扰或丢失等问题，限制了模型的表达能力。虽然AFM利用attention机制对特征交叉模块进行加权，从而改变交互特征的重要性。但该方法没有考虑到在特征交互时会引入干扰信息并且只考虑了特征两两交互的情况，因此模型的预测准确度并不高。而FiBiNET[28]利用了挤压提取网络来获取特征重要性。但这种网络在挤压信息时会造成大量特征信息的丢失，进而影响模型性能。

综上，以往方法在对特征进行选择时存在信息干扰和丢失问题，另外在进行特征交互时不同的交互方式也会极大地影响预测准确性。对此，在本章中提出了一种基于特征加权与自动交互的点击率预测模型(Automatic feature interaction prediction model based on feature weighting，FWAI)，首先引入ECANet模块[11]对输入特征进行加权，该模块通过一维卷积有效地提取特征权重，解决了在特征选择时存在信息干扰和丢失问题。然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，从而有效挖掘特征间有用的交互信息。

在本章中我们的主要贡献如下：

(1)提出的模型分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，从而有效挖掘特征间的交互信息。

(2)提出一种基于特征加权与自动交互的预测模型，通过利用带有残差结构的 ECANet 对输入特征进行加权，使得模型可以有选择性地学习重要特征，并解决了信息干扰和丢失问题。

(3)在四个大型数据集上的大量实验表明，我们提出的模型优于基线模型，并且具备良好的模型解释性。

中国知网 https://www.cnki.net

2.2 相关工作

本章节工作涉及三个方面：1)点击率预测；2)ECANet 网络；3)多头自注意网络和残差网络。

2.2.1 点击率预测

CTR 预测任务中的关键挑战是如何有效地建模特征交互。在该领域已经提出了许多模型，如逻辑回归(LR)、多项式-2(Poly2)、基于树的模型[29]、基于张量的模型[30]、贝叶斯模型[31]和基于因子分解机的模型。随着深度学习在各个领域都取得了巨大成功，近年来提出了许多基于深度学习和神经网络的 CTR 模型，如：DeepFM 和 IPNN 使用 FM 层学习二阶特征交互，使用 MLP 学习高阶特征交互。DIN[32]和 AFM 利用注意网络来区分每个二阶特征交互的重要程度。

2.2.2 ECANet 模块

注意力机制是机器学习中的一种数据处理方式。在图像分类任务中，传统地注意力机制是一个动态选择过程。ECANet 是 2020 年在 CVPR 上提出的一种通道注意力模块，并在很多任务中被引用。如：Han[33]等人为了对具有不同外观和遮挡的复杂背景图像中绝缘子串的准确识别和分割，提出一种绝缘子分割方法基于改进的 U-Net。该算法在 U-Net 的编码阶段嵌入了注意机制 ECA-Net，以提高模型提取语义特征的能力，从而提高绝缘子检测的准确性。Gera 等人[34]提出一种用于面部识别的算法，该算法利用 ECANet 来消除冗余特征，显著提高了模型的鲁棒性。基于该模块在特征重要性提取上的优势，我们提出的 FWAI 通过 ECANet 对输入特征进行动态加权，以提高模型的准确率。

2.2.3 多头自注意网络和残差网络

我们提出的模型利用了深度学习文献中的最新技术：注意力机制[35-36]和残差网络[37]。注意力最早是在视觉图像领域提出的，并在各种任务中被证明是有效的，如问答[38]、文本摘要[39]和推荐系统[40-41]。Vaswani[42]等人利用多头自注意模型，来建模机器翻译中每个单词之间的各种关联关系。Roberto[43]等人将多头自注意网络用于脸部表情识别。Li[44]等人提出一种用于语言感情识别的算法，该算法用多头自注意网络对学习到的超分段特征序列中不同位置的元素之间的内部依赖关系进行建模，从而增强了情感显着信息的导入。在此模型中，我们利用它来建模不同特征之间的交互。

残差网络在 2016 年的 ImageNet 竞赛中取得了非常优秀的表现。由于残差连接可以解决神经网络中梯度消失、梯度爆炸以及网络退化等问题，因此成为一种用于训练深层神经网络的流行网络结构。

中国知网 https://www.cnki.net

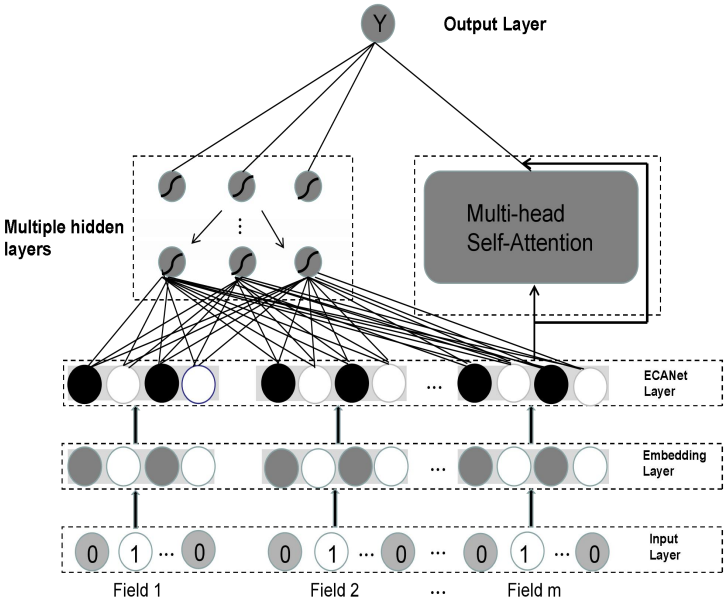

图 2.1 基于特征加权与自动交互的点击率预测模型

Fig.2.1Click-through rate prediction model based on feature weighting and automatic interaction

2.3 基于特征加权与自动交互的预测算法

在本节中，我们介绍FWAI模型，如图 1 所示。FWAI可以划分为以下几个部分：输入层(Input Layer)，嵌入层(Embedding Layer)，ECANet层(ECANet Layer)，交互层(Interacting Layer)，输出层(Output Layer)。其中输入层将稀疏特征向量x作为输入，然后将所有输入特征x投影到嵌入层，使分类特征和数字特征进入相同的低维空间。ECANet层可以对嵌入层的输出进行加权，使模型可以有选择性地学习重要特征，并抑制不太有用的特征。接下来将加权后的特征输入到交互层，然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互。最后输出层用sigmoid函数得到点击率预测值。接下来，我们介绍所提出的方法的细节。

2.3.1 输入层

在 CTR 预测任务中，数据中的特征通常分为类别特征和数值特征。我们将所有特征输入用稀疏向量表示：

$$x = [x_1; x_2; \cdots; x_m] \tag{2.1}$$

其中m是总特征字段的数量，x_i是第i个字段的特征表示。如果第i个字段是分类的，那么x_i是一个热编码向量(one-hot vector)。如果第i个字段是数值的，x_i是一个标量值。

2.3.2 嵌入层

在数据集中分类特征的维度通常可达到几十都是稀疏高维的，如果直接将这样的稀疏向量输入到深度神经网络中来训练，将带来巨大的时间复杂度。因此需要通过

中国知网 https://www.cnki.net

Embedding 技术将高维稀疏的原始特征向量映射成低维稠密向量。我们用低维向量表示每个分类特征，即：

$$e_i = V_i \cdot x_i \tag{2.2}$$

其中V_i是场i的嵌入矩阵，x_i是一个热编码向量。在真实数据中，分类特征可能拥有多个值，x_i是一个多值热编码向量(multi-hot vector)。以播放音乐预测为例，其中有一个描述音乐类型的特征字段，它可能是多值的(例如，音乐《哪里都是你》既是中文歌，也是网络热歌、抒情摇滚等)。为了与多值输入兼容，我们对等式(2.2)进行修改，并将多值特征表示为相应特征嵌入向量的平均值：

$$e_i = \frac{1}{n} V_i \cdot x_i \tag{2.3}$$

n是第i个特征字段的值的数量，x_i是该字段的多个热向量表示。

因为数据中也会存在数值特征，为了允许分类特征和数值特征之间的相互作用，我们必须将数值特征也表示在同一低维特征空间中。即：

$$e_l = V_l \cdot x_l \tag{2.4}$$

其中V_l是字段m的嵌入向量，x_l是标量值。

最后，嵌入层的输出是多个特征嵌入向量的串联，$E = [e_1, e_2, \cdots, e_m]$。

2.3.3 ECANet 层

在真实应用场景和数据中，不同类型的特征对于同一个预测任务的重要性显然是不一样的。比如在音乐广告预测场景下，显然演唱者这个特征比其他特征更重要。受 ECANet 在计算机视觉领域取得重大成功的启发，我们将 ECANet 机制引入到模型中。对于特定的 CTR 预测任务，我们可以通过 ECANet 机制动态增加重要特征的权重，降低干扰特征的权重。

用嵌入特征作为输入，ECANet 为嵌入特征生成权重向量$A = \{a_1, \cdots, a_i, \cdots, a_m\}$，然后用向量$A$重新缩放原始嵌入$E$，得到新的嵌入$V = [v_1, \cdots, v_i, \cdots, v_m]$，其中$a_i \in R$是一个标量，表示第$i$个特征的$V_i$的权重。

如图 2 所示，ECANet 由三个步骤组成：特征压缩、权重提取、特征加权。这些步骤可以详细描述如下：

(1)特征压缩(FGAP)

第一步用于获取每个特征向量的统计信息，我们使用的方法是平均池化，将嵌入特征

$E = [e_1, \cdots, e_m]$转化为统计向量$Z = [z_1, \cdots, z_m]$，其计算方法如式(2.5)所示：

$$z_i = F(e_i) = \frac{1}{k} \sum_{t=1}^{k} e_i^{(t)} \tag{2.5}$$

其中$e_i^{(t)}$表示第i个输入向量的第t维信息，$t = 1,2, \cdots, k$，k是嵌入向量的维度。

中国知网 https://www.cnki.net

(2)权重提取(Ew)

第二步用来学习基于统计向量Z的每个字段嵌入的权重。我们通过挖掘单个特征及其k个相邻特征来得到其交互信息。它可以通过卷积核大小为k的一维卷积来实现，在这里k表示参与卷积运算的特征个数，即，该特征附近有多少邻居特征参与了这个特征的注意力预测。形式上，字段嵌入的权重可以计算如下：

$$A = \sigma(conv1D_k(Z)) \tag{2.6}$$

其中，$conv1D$表示一维卷积，$A \in R^m$是一个向量，K表示卷积核的大小，σ是激活函数。

(3)特征加权(Fw)

ECANet 最后一步是特征加权，这一步将原始嵌入向量 E 和学习到的权重向A进行相乘，得到加权后的嵌入向量$V = [v_1, \cdots, v_i, \cdots, v_m]$。计算过程如公式(2.7)所示：

$$V = F(A, E) = [a_1 \cdot e_1, \cdots, a_m \cdot e_m] = [v_1, \cdots, v_m] \tag{2.7}$$

其中，$a_i \in R$，$e_i \in R^k$，$v_i \in R^k$，i表示第i个特征域，k表示嵌入向量的维度。

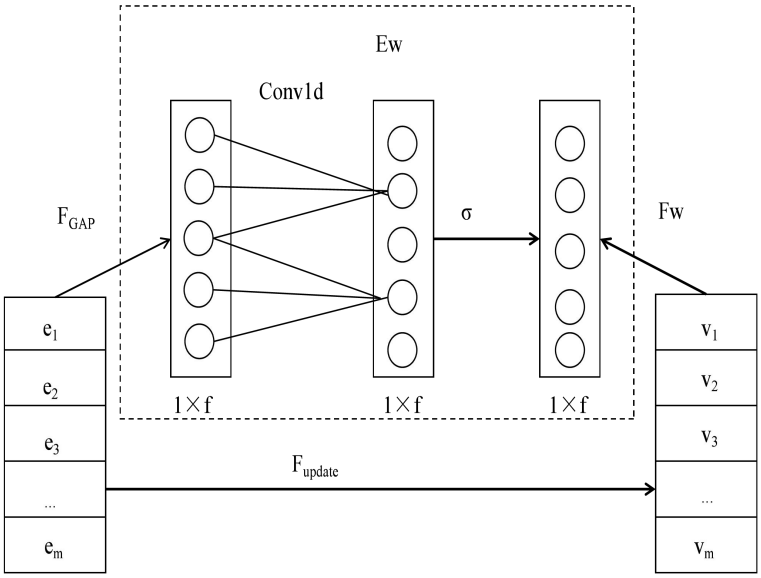

图 2.2 ECANet 层

Fig.2.2 ECANet layer

2.3.4 交互层

2.3.4.1 隐式高阶交互

在此模型中，我们在特征嵌入向量v上使用前馈神经网络对隐式特征交互进行建模，其计算公式为:

$$x^1 = \sigma(W^{(1)}v + b^1) \tag{2.8}$$

$$x^n = \sigma(W^{(n)}v^{(n-1)} + b^n) \tag{2.9}$$

其中，n表示神经网络层的深度，σ是激活函数，x^n表示第n层神经网络的输出，这

中国知网 https://www.cnki.net

种前向神经网络的模型架构是以 bit-wise 的方式来建模交互关系的，也就是说，即使是同一个嵌入向量内的 bit 元素也会互相影响。

2.3.4.2 显式高阶交互

在此模型中，我们用多头自注意网络来进行显式特征交互。以特征j为例，接下来我们将具体介绍该网络如何学习与特征j相关的全部交互信息。我们首先定义特定注意头h下特征j和特征k之间的相关性，如下所示：

$$a_{j,k}^{(h)} = \frac{\exp(\psi^{(h)}(v_j, v_k))}{\sum_{l=1}^{M} \exp(\psi^{(h)}(v_j, v_l))} \tag{2.10}$$

$$\psi^{(h)}(v_j, v_k) = \left\langle W_{Query}^{(h)} v_j, W_{Key}^{(h)} v_k \right\rangle \tag{2.11}$$

其中$\psi^{(h)}(\cdot,\cdot)$是定义特征j和k之间相似性的一个函数。它能定义成神经网络或内积。在本模型中，我们使用内积，因为它运算简单而且效率高。$W_{Query}^{(h)}$，$W_{Key}^{(h)} \in R^{d\times d}$是方程(10)将原始嵌入$R^d$映射到新空间$R^d$的变换矩阵。最后，在子空间$h$下，我们通过自由组合系数$a_{j,k}^{(h)}$，引导所有与特征$j$相关的特征来更新特征$j$的表示：

$$\tilde{v}_j^{(h)} = \sum_{k=1}^{M} a_{j,k}^{(h)} \left(W_{Value}^{(h)} v^k \right) \tag{2.12}$$

$\tilde{v}_j^{(h)} \in R^d$是特征$j$及其相关特征(在空间$h$下)的组合，它代表了通过我们的方法学习的一种新的组合特征。此外，一个特征也可能涉及不同的组合特征，我们通过使用多个 head 来实现这一点，这些 head 分别创建不同的子空间来学习每个特征的不同组合特征。最后将这些子空间中学习到的交互特征放到一个向量中，如下所示：

$$\tilde{v}_j = \tilde{v}_j^{(1)} \oplus \tilde{v}_j^{(2)} \oplus \cdots \oplus \tilde{v}_j^{(H)} \tag{2.13}$$

在此公式中，$\oplus$代表串联运算符，H则表示子空间的个数。

为了保留以前学习到的组合特征，包括原始个体(即一阶)特征，我们在网络中添加了标准的残差网络。即：

$$v_j^{Res} = ReLU(\tilde{v}_j + W_{Res} v_j) \tag{2.14}$$

其中，W_{Res}表示残差部分，$ReLU$是非线性激活函数。

通过这样一个交互层，每个特征的表示将更新为新的特征表示v_j^{Res}。我们可以将多个这样的层与前一个交互层的输出叠加，然后输入到下一个交互层中。通过这样我们能够对任何组合特征进行建模。

2.3.5 输出层

模型 FWAI 将隐式高阶特征交互(DNN)与显式高阶特征交互(多头自注意网络)结合起来，这样既包含低阶和高阶特征交互，同时又包含隐式和显式特征交互。其输出为：

$$\hat{y} = \sigma(W^T(v_1^{Res} \oplus v_2^{Res} \oplus \cdots \oplus v_M^{Res}) + W_{dnn}^T X_{dnn}^n + b) \tag{2.15}$$

中国知网 https://www.cnki.net

其中，σ是 sigmoid 函数，将值转化为用户单击概率。X_{dnn}^{n}是 DNN 的输出，W^{T}和W_{dnn}^{T}是可学习的权重参数，b是偏差。

2.3.6 损失函数

我们的损失函数是交叉熵损失，定义如下：

$$Logloss = -\frac{1}{N}\sum_{j=1}^{N}\left(y_j log(\hat{y}_j) + (1 - y_j) log\,(1 - \hat{y}_j)\right) \tag{2.16}$$

其中，y_j和$\hat{y}_j$分别表示用户实际点击的情况和模型预测的情况，j代表训练样本索引，N为训练样本总数。

2.4 实验分析

本小节主要介绍模型的参数设置、评价指标以及使用的数据集，通过在四个公开广告数据集 Criteo、Avazu、KDD12 和 MovieLens-1M 上进行的实验，对 FWAI 模型的预测性能进行评价。实验内容包括：

(1)FWAI 与目前常见的 BaseLine(基线)模型对比

(2)ECANet Layer 对模型性能的提升

(3)显示和隐式交互方式对模型性能的影响

(4)超参数设置对模型性能的影响

表 2.1 实验数据集统计

Table 2.1 Experimental data set statistics

Data	Samples	Fields
Criteo	10,000,000	39
Avazu	10,000,000	23
KDD12	10,000,000	13
Movielens-1M	739,012	7

2.4.1 实验数据集及设置

2.4.1.1 实验数据集

我们使用 4 个公开的真实数据集。表 2.1 总结了数据集的统计数据。Criteo：这是一个众所周知的 CTR 预测的基准数据集，用于 Criteo 广告挑战赛。有 4500 万个样本，每个样本有 13 个数值字段和 26 个分类字段。Avazu 该数据集包含用户的移动行为，包括显示的移动广告是否被用户点击。它有 23 个功能字段，从用户/设备功能到广告属性。KDD12：此数据集由 KDDCup 在 2012 年发布，共有 14963 万个样本，每个样本有 13 个分类字段。MovieLens-1M：此数据集包含用户对电影的评分。在二值化过程中，我们

中国知网 https://www.cnki.net

将评分小于 3 的样本视为负样本，因为分数低表示用户不喜欢该电影。我们将评级大于 3 的样本视为正样本，并移除中性样本，即评级等于 3 的样本。Criteo、Avazu 和 KDD12 原始数据集的规模都超过了 4000 万条，由于实验条件限制，我们只对每个数据集都选取了前 1000 万条数据，然后将数据集按均匀随机抽样方式将数据集按 8:1:1 划分为三部分：80%用于训练，10%用于验证，10%用于测试。

2.4.1.2 评价指标

AUC[45]：AUC 在机器学习领域中是一种模型评估指标，其定义为：ROC 曲线下的面积。它衡量的是 CTR 预测因子对于从样本集中随机选取 1 个正样本、1 个负样本进行预测，其中正样本预测值比负样本预测值高的概率。AUC 的数值越高，表示性能越好。

Logloss[46]：对数损失，是基于概率的最重要的分类度量。它常用于评估分类器的概率输出.也是二分类问题中经常使用的评价标准，用来表示预测值与真实值之间的差距。在实验中，LogLoss 值越小预测模型性能越好。

2.4.1.3 对比模型

我们将所提出的方法与之前的三类模型进行了比较：(A)仅使用单个特征的线性方法；(B)考虑二阶组合特征的模型；(C)能够捕捉高阶特征交互的技术。

LR(A)：是工业界广泛使用的一种基线，其应用线性变换来建模所有特征的关系。

FM(B)；FM 使用因子分解机对二阶特征交互进行建模。

AFM(B)：AFM 主要用来学习二阶特征交互信息。它通过使用注意力机制来学习二阶组合特征的权重，从而达到泛化模型的目的。

FNN(C)：FNN 模型其实可以看做是由一个 FM 模型和一个 MLP 组成的。FM 的引入是为了高效地将输入稀疏特征映射到稠密特征，从而加快 FNN 模型的训练。

NFM(C)：NFM 将深度神经网络堆叠在二阶特征交互层之上。并使用 Bi-interaction Pooling 操作对二阶交叉特征进行处理，解决传统 FM 作为线性模型表达有限的问题和对高阶交叉特征学习不充分的问题。

DCN[47](C)：CrossNet 交叉网络是深度交叉模型的核心，它在逐位层次上取连接特征向量的外积来显式地建模特征交互。

HOFM(C)：HOFM 提出了高效的基于核的算法来训练高阶因式分解机。按照模型设置，我们使用公共实现构建了一个三阶因式分解机。

AutoInt(C)：AutoInt 模型利用带残差连接的多头自注意网络显式的进行交互特征的获取，能够自动学习高阶特征交叉。

中国知网 https://www.cnki.net

表 2.2 四个数据集上不同模型的性能对比

Table 2.2 Performance comparison of different models on four data

Model Class	Model	Criteo		Avazu		KDD12		MovieLens-1M	
		AUC	LogLoss	AUC	LogLoss	AUC	LogLoss	AUC	LogLoss
First-order	LR	0.7760	0.4758	0.7577	0.3849	0.7361	0.1684	0.7716	0.4424
Second-order	FM	0.7787	0.4743	0.7662	0.3816	0.7759	0.1573	0.8252	0.3998
	AFM	0.7895	0.4643	0.7665	0.3802	0.7659	0.1591	0.8227	0.4048
High-order	FNN	0.7923	0.4615	0.7657	0.3822	0.7715	0.1593	0.8386	0.3955
	NFM	0.7946	0.4562	0.7702	0.3795	0.7515	0.1631	0.8257	0.3883
	DCN	0.7951	0.4552	0.7719	0.3768	0.7773	0.1572	0.7968	0.4266
	HOFM	0.7986	0.4534	0.7713	0.3754	0.7707	0.1586	0.8304	0.4013
	AutoInt	0.7988	0.4507	0.7715	0.3729	0.7783	0.1587	0.8456	0.3880
	FWAI	**0.8017**	**0.4481**	**0.7765**	**0.3724**	**0.7838**	**0.1546**	**0.8522**	**0.3861**

2.4.1.4 实验超参数设置

上述所有方法都在 TensorFlow 环境下实现。对于所有的深度模型，我们根据经验将嵌入维度 d 设置为 16，batch size 设置为 1024，Drop Out Ratio 为 0.7，学习率设置为 0.0001，层深度设置为 3，最后，我们使用 Adam 优化所有基于深度神经网络的模型。

2.4.2 FWAI 模型与基线模型性能对比

本节在表 2.2 中总结了在四个数据集上 5 次不同运行的平均结果。由实验结果可得：(1)二阶特征组合和高阶特征交互的模型在所有数据集上的表现都优于 LR，这表明单个特征在 CTR 预测中是不够的，挖掘高级特征交互对于模型至关重要；(2)在四个数据集上，高阶交互模型显著优于二阶特征组合，这表明建模高阶特征交互有助于提升预测性能；(3)FWAI 模型在四个数据集上的性能始终优于其他模型。这是因为模型引入了注意力机制对输入特征进行加权，而且分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互。使得 FWAI 能够通过加权对输入特征进行重要性选择使得模型可以有选择性地学习重要特征，并抑制不太有用的特征，同时以显式和隐式的方式自动学习高阶的特征交互从而有效挖掘特征间的交互信息，显著提升了模型预测能力。

2.4.3 ECANet 层对模型性能的提升

在本节中，我们将讨论 ECANet 机制对模型性能的影响。为了方便起见，我们用 NO-ECA 表示从模型中删除 ECANet 层。实验结果如表 2.3 所示。从实验数据可以发现，当模型加入 ECANet 机制后，预测效果有很大提升。这说明，ECANet 层对于提升模型的性能是十分必要的，它对输入特征通过加权来进行重要性选择能够有效增强模型能力

中国知网 https://www.cnki.net

并使基线模型获得更好的性能。

表 2.3 ECANet 层对模型性能的提升

Table2.3 Model performance comparison inserted in ECANet layer

Data Sets	Models	AUC	LogLoss
Criteo	FWAI	0.8017	0.4481
	NO-ECA	0.8002	0.4493
Avazu	FWAI	0.7765	0.3724
	NO-ECA	0.7731	0.3743
KDD12	FWAI	0.7838	0.1546
	NO-ECA	0.7751	0.1633
MovieLens-1M	FWAI	0.8522	0.3861
	NO-ECA	0.8367	0.3894

2.4.4 显式和隐式交互方式对模型性能的影响

在本节中，我们讨论了显式和隐式交互方式对模型性能的影响。我们使用 E 和 I 来表示使用哪种交互方式。“E”表示使用显式特征交互方式(即多头自注意网络)，“I”表示使用隐式特征交互(即深度神经网络)，而“EI”表示同时使用显式和隐式交互。我们在四个不同数据集上进行了实验，并将结果总结在表 2.4 中，根据实验结果我们可以观察到将显性特征交互和隐性特征交互相结合的效果优于单个交互方式，证明了模型的有效性。

表 2.4 不同交互方式的模型性能

Table 2.4 Model performance of different interactions

Data Sets	Models	AUC	LogLoss
Criteo	FWAI-E	0.7895	0.4507
	FWAI-I	0.7995	0.4552
	FWAI-EI	0.8017	0.4481
Avazu	FWAI-E	0.7715	0.3729
	FWAI-I	0.7704	0.3767
	FWAI-EI	0.7765	0.3724
KDD12	FWAI-E	0.7814	0.1589
	FWAI-I	0.7809	0.1567
	FWAI-EI	0.7838	0.1546
MovieLens-1M	FWAI-E	0.8496	0.3878
	FWAI-I	0.8503	0.3864
	FWAI-EI	0.8522	0.3861

中国知网 https://www.cnki.net

2.4.5 超参数设置对模型性能的影响

本小节讨论了 FWAI 模型中的部分超参数设置对算法性能的影响，重点放在嵌入层和 DNN 部分。具体包括：(1)嵌入维度；(2)网络深度。

(1)我们研究了嵌入层的嵌入维度 d 的性能。

通过实验分析嵌入维度 d 对 FWAI 预测性能的影响，来选取出最优的嵌入维度，从而最大程度的提升模型性能。我们将嵌入维度大小按照 8，16，32，64 进行实验并在图 2.3 总结了实验结果。通过实验结果观察到了以下信息：从四个数据集上的实验结果可以看到，随着维度的增加，模型性能不断提高。但维度达到 32 后，性能开始下降。通过分析，认为原因是当参数太多时，模型拟合过度。

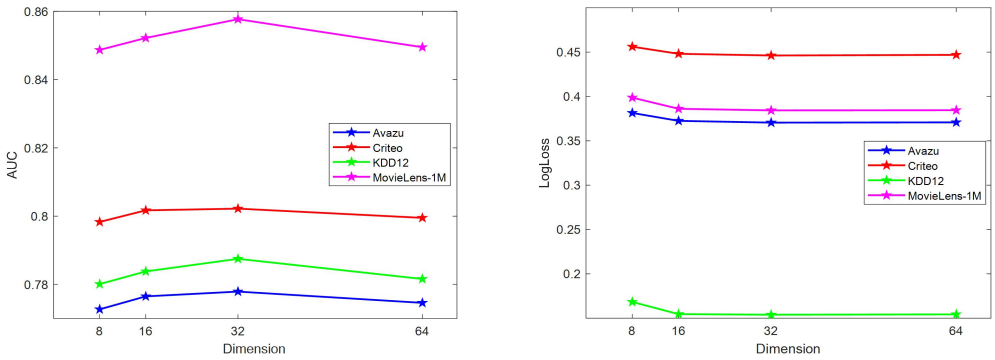

图 2.3 嵌入维度对模型 AUC 和 LogLoss 的影响

Fig2.3 Effect of embedding dimensions on model AUC and LogLoss

(2)网络深度对模型预测性能的影响

图 4 展示了隐藏层数量的影响。可以观察到，当隐藏层数小于等于 3 时 FWAI 的性能随着网络的深度而提升。但层数大于 3 时，性能反而下降。这是由于过度拟合造成的。

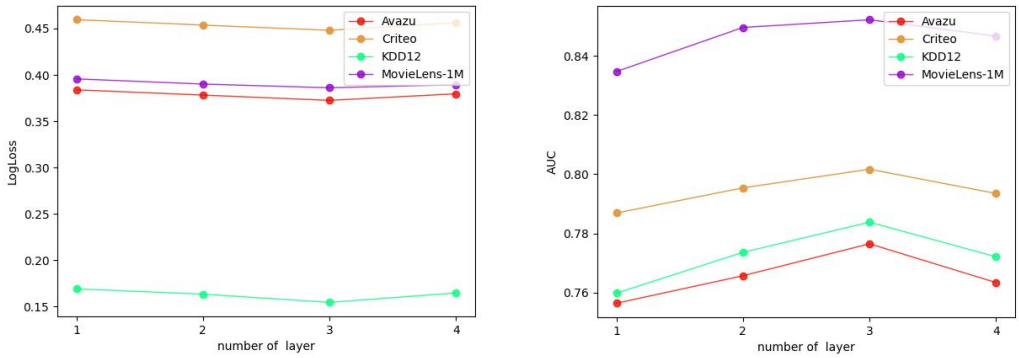

图 2.4 网络深度对模型 AUC 和 LogLoss 的影响

Fig2.4 Effect of network depth on model AUC and LogLoss

中国知网 https://www.cnki.net

2.5 本章小结

本章中我们提出了一种新的基于特征加权与自动交互的点击率预测模型(FWAI)，该模型旨在动态学习特征重要性和自动构建有效的特征交互。我们通过引入了注意力机制对输入特征进行加权，使得模型可以有选择性地学习重要特征，并解决了在特征选择时存在信息干扰和丢失问题。然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，从而有效挖掘特征间有用的交互信息。一方面，FWAI 能够通过加权对输入特征进行重要性选择；另一方面，它能同时以显式和隐式的方式自动学习高阶的特征交互。在四个真实数据集上的实验结果证明了该模型的有效性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第三章 基于全局注意网络与特征交互的点击率预测模型

本章主要介绍了基于全局注意网络与特征交互的点击率预测模型，近年来，越来越多的模型被提出来。然而，现有模型将学习到的低阶和高阶特征直接拼接后进行预测，忽略了低阶和高阶特征之间相互作用的重要性。为了解决这一问题，我们设计了一个全局交互模块(GAN)来学习高阶交互，并平衡多个特征的不同影响。其主要作用是显式地捕获原始特征(即低阶)和生成的交互特征(即高阶)之间的关系。此外，我们利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。最后，通过在三个数据集的离线实验结果，证明了我们提出的方法的有效性。

3.1 引言

CTR 预测旨在估计用户点击广告或项目的可能性，对许多应用程序，如在线广告[49-50]和推荐系统都至关重要。随着机器学习模型的日益复杂，特别是推荐系统中的机器学习模型，如何有效地处理丰富的输入特征成为一个关键问题。因此，开发高效算法已引起学术界和工业界越来越多的研究关注。

在学术界，针对这个问题提出了很多算法，比如：Logistic 回归(LR)、因子分解机(FM)及其变体场感知 FM(FFM)。在过去几年中，一些深度学习模型被提出来学习 CTR 预测中复杂的特征交互。例如，Wide&Deep 利用 LR 来挖掘低阶特征工程，同时通过深度神经网络生成高阶特征。Deep&Cross Network[47](DCN)和 DeepFM 通过用更实用、更健壮的网络取代较宽的部分来扩展它。近年来，随着注意力机制的发展，很多模型采用注意力机制来模拟特征交互，如：AutoInt 模型利用带残差连接的多头自注意网络显式的进行交互特征的获取，能够自动学习高阶特征交叉。AIM[51]则提出了三个核心组件(FIS、IFS、EDS)来提升预测精度。但这些模型的重点是挖掘数据中的高阶交互特征，并通过各种方法对其进行拟合，从而提升模型的预测准确率。但却忽略了低阶和高阶特征之间相互作用的重要性，限制了特征的表达。

为了解决这一问题，在本章中，我们提出了一种基于全局注意网络与特征交互的点击率预测模型(Click-through rate prediction model based on global attention Network and feature interaction，CGAN)。该模型的主要思路是：设计了一个全局交互模块(Global Interaction Module，GAN)来学习高阶交互并平衡多个特征的不同影响。其主要作用是显式地捕获原始特征(即低阶)和生成的交互特征(即高阶)之间的关系。此外，我们利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。

模型的主要贡献如下：

中国知网 https://www.cnki.net

(1)提出一种基于全局注意网络与特征交互的点击率预测模型，来学习高阶交互并平衡多个特征的不同影响。

(2)设计了一个全局交互模块(GAN)来显式地捕获原始特征和生成的交互特征之间的关系，此外利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。

(3)在三个大型数据集上的大量实验表明，我们提出的模型能够显著提升预测的准确率，而且具有良好的模型解释能力。

3.2. 相关工作

在推荐系统的早期阶段，人们花了很多时间在乏味和繁重的特性工程上。当时，原始特征的维度相对较小，这使得实现原始特征的不同组合成为可能。然后将新创建的特征输入浅层模型，如 Logistic 回归(LR)和梯度提升决策树(GBDT)[52]广泛用于 CTR 预测。然后，因子分解机(FM)将用户和项目特征的学习转化为一个小的共享向量形状。基于上述方法，场感知 FFM 和场加权 NFM 进一步考虑了特征所属场的不同影响，以提高 CTR 预测的性能。沿着这条线，提出了注意因子分解机(AFM)来自动学习深度交叉特征的权重，并且通过建模高阶和非线性特征交互来增强 FM。

进入二十一世纪后，深度神经网络(DNN)在自然语言处理和计算机视觉[53-56]中的成功为推荐系统带来了新的方向。其中，深度学习[57-58]将深度神经网络引入 CTR 预测。它与传统的线性模型一起训练深度神经网络。深度神经网络将人们从特征工程中解放出来，同时推广了更好的特征组合。Wide&Deep 学习的许多变体已经被提出，因为它彻底改变了 CTR 预测的发展。深度和交叉网络(DCN)用交叉网络代替了宽线性部分，这在低层和高层之间生成了明确的特征交叉。DeepFM 结合了 DNN 和因子分解机的功能，用于推荐系统中的特征表示。此外，xDepFM 通过提出压缩交互网络来枚举和压缩所有特征交互，扩展了 DNN 的工作。AutoInt 模型利用带残差连接的多头自注意网络显式的进行交互特征的获取，能够自动学习高阶特征交叉。AIM 则提出了三个核心组件(FIS、IFS、EDS)来提升预测精度。总体而言，上述深度模型都通过结合低阶和高阶特征来构建相似的模型结构，这大大减少了特征工程的工作量，提高了 CTR 预测的性能。

上述的模型认识到了交互信息的重要性，将统计和分类特征作为输入，去挖掘高阶交互。但是，他们只是将得到的高阶交互信息和原始特征拼接到一个向量中，并没有对原始特征(即低阶)和生成的交互特征(即高阶)之间的交互给予同等的关注。为了解决这一问题，我们提出了 GAN 模型，它可以来学习高阶交互并平衡多个特征的不同影响。其主要作用是显式地捕获原始特征(即低阶)和生成的交互特征(即高阶)之间的关系。此

中国知网 https://www.cnki.net

外，我们利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。

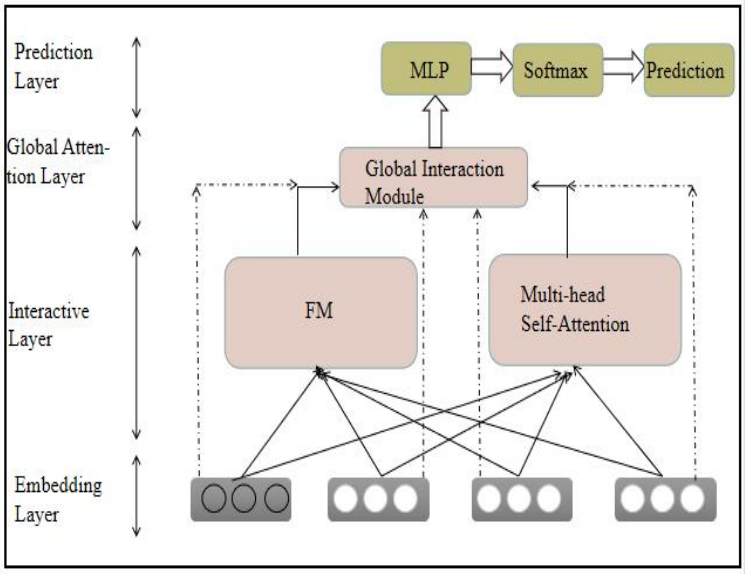

图 3.1 基于全局注意网络与特征交互的点击率预测模型

Fig.3.1 Click-through rate prediction model based on global attention network and feature interaction

3.3 模型介绍

图 3.1 展示了 CGAN 的总体架构，它由四个层组成：嵌入层、交互层、全局注意力层和预测层。在本模型中嵌入层与以往的点击率预测模型相同。交互层用来学习原始嵌入特征和高阶特征交互。随后将这些交互特征输入到全局注意力层中，用来捕获原始特征和生成的交互特征之间的关系。此外，我们利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。最后由预测层输出预测得分。每一层的细节将在以下章节中解释。

3.3.1 嵌入层

在 CTR 预测任务中[59-62]，原始数据集中的特征可以分为两类，一种是类别特征一种是数值特征。由于原始特征不是二进制编码，计算机无法识别，所以不能直接输入到模型中，因此需要通过 one-hot 编码将高维原始特征，转换为二进制向量表示。例如，在青少年服装推荐广告中，可以将衣服的性别特征按照男孩和女孩分别编码为[1,0]和[0,1]。衣服的尺码特征按照 S 码、M 码、L 码、XL 码分别表示为 4 维向量[0,0,0,1]、[0,0,1,0]、[0,1,0,0]、[1,0,0,0]。但在很多点击率预测场景中，有些特征的编码通常维度可达到几十。如果直接将这样的稀疏向量输入到深度神经网络中来训练，将带来巨大的计算复杂度。因此需要通过 Embedding 将高维稀疏的原始特征向量映射成低维稠密向量，这种方法在深度学习中被广泛应用。这种操作可以减少后续神经网络中的神经元数量和计算开销。

中国知网 https://www.cnki.net

我们将所有特征输入用稀疏向量表示：

$$x = [x_1; x_2; \cdots; x_m] \tag{3.1}$$

其中 m 是总特征字段的数量，x_i是第 i 个字段的特征表示。如果第 i 个字段是分类的，那么x_i是一个热编码向量(one-hot vector)。若第 i 个特征为数值型特征，则x_i是一个标量值。由于分类特征的特征表示是稀疏的和高维的，因此它们被投影到低维空间中，其可以被公式化如下：

$$e_i = V_i \bullet x_i \tag{3.2}$$

其中V_i是场 i 的嵌入矩阵，x_i是一个热编码向量。因为数据中也会存在数值特征，为了允许分类特征和数值特征之间的相互作用，我们必须将数值特征也表示在同一低维特征空间中。即：

$$e_l = V_l \cdot x_l \tag{3.3}$$

其中V_l是字段 m 的嵌入向量，x_l是标量值。通过这样做，嵌入层的输出将是多个嵌入向量的级联，可以表示为嵌入层的输出是多个特征嵌入向量的串联，$E = [e_1, e_2, \cdots, e_m]$ 。

3.3.2. 交互层

在本节中，我们将介绍模型的交互层部分。交互层主要由 FM 和多头自注意网络(Multi-headed Self-attention)两个组件。FM 用来学习二阶交互特征，多头自注意网络用来学习高阶交互。

FM 组件是一种因子分解机，在文献[3]中提出，主要用于学习点击率预测任务中的特征交互信息。除了特征之间的线性交互信息，FM 还学习任意两个特征之间的隐向量，并将学习到的隐向量通过内积来提取特征组合，其函数形式如下：

$$e_{FM} = \sum_{i=1}^{M} \sum_{j=i+1}^{M} w_{ij} e_i e_j \tag{3.4}$$

我们首先定义特定注意头 h 下特征 j 和特征 k 之间的相关性，如下所示：

$$a_{j,k}^{(h)} = \frac{exp\,(\psi^{(h)}(e_j, e_k))}{\sum_{l=1}^{M} exp\,(\psi^{(h)}(e_j, e_l))} \tag{3.5}$$

其中$\psi^{(h)}(\cdot,\cdot)$是一个注意函数，它定义了特征 j 和 k 之间的相似性。在子空间 h 下，我们通过自由组合系数$a_{j,k}^{(h)}$，引导所有与特征 j 相关的特征来更新特征 j 的表示。这些 head 分别建立不同的子空间对所有特征进行交互学习。最后把所有子空间中学习到的交互特征合并到一个向量中，如下所示：

$$\tilde{e}_j^{(h)} = \sum_{k=1}^{M} a_{j,k}^{(h)} \left(W_{Value}^{(h)} e^k \right) \tag{3.6}$$

$\tilde{e}_j^{(h)} \in R^d$是特征$j$及其相关特征(在空间$h$下)的组合，它表示通过多头注意力网络学习的一种新的组合特征。此外，我们通过创建不同的子空间来学习每个特征的不同组合

中国知网 https://www.cnki.net

特征。最后将这些子空间中学习到的交互特征放到一个向量中，如下所示：

$$\tilde{e}_j = \tilde{e}_j^{(1)} \oplus \tilde{e}_j^{(2)} \oplus \cdots \oplus \tilde{e}_j^{(H)} \tag{3.7}$$

在此公式中，$\oplus$代表串联运算符，H则表示子空间的个数。

3.3.3 全局注意力层

在这一阶段，我们将原始特征和生成的交互特征汇集到一起。因为 Deep&Cross 网络的有效性表明了低阶和高阶特征之间相互作用的重要性。为了继承这一思想，全局交互模块被设计为显式地捕获原始特征(即低阶)和生成的交互特征(即高阶)之间的关系。此外，我们利用注意力机制来提取不同交互模块和原始嵌入的重要性。具体来说，我们首先将所有特征连接到一个表示向量r_g中,其可表示为：

$$r_g = [e_i; e_{FM}; \tilde{e}_j] = [r_1; r_2; r_3] \tag{3.8}$$

然后将所有特征的组合作为全局交互模块的输入，该模块利用全局注意力单元来提取输入特征的不同部分之间的关系。输出通过以下公式计算：

$$R_g = \sum_{l=1}^{L} \frac{exp\ (tanh(r_l.W_l + \hat{b}_l\ \ ))}{\sum_{l=1}^{L} exp\ (tanh(r_l.W_l + \hat{b}_l\ \ ))} r_l \tag{3.9}$$

其中，W_l和b_l分别为权重和偏差矩阵。r_l是每个单独特征的表示，l是r_g中的总特征数,R_g是所有特征的全局表示，$tanh$ 表示激活函数。

3.3.4 预测层

最后，我们设计了一个包含 DNN 预测模块的预测层，以进一步增强挖掘高阶特征的能力。

DNN 预测模块。在本模块中，生成的全局特征表示R_s被送到 DNN 预测模块,利用常用的多层感知机(MLP)进行最终 CTR 预测。具体来说，我们堆叠多个完全连接的层，其间具有非线性激活函数，以自动学习输入特征之间的高阶交互。该流程制定如下：

$$R_l = Relu(W_l R_l + b_l), l = 1,2\cdots, h \tag{3.10}$$

其中，W_l，b_l是隐藏层中的可训练参数矩阵和偏差。R_h是第 h 层输出，也被视为 DNN 预测模块的输出。对于最后一个隐藏层，我们将进行最终 CTR 预测，可以表示如下：

$$\hat{y} = softmax(W_P R_h + b_q) \tag{3.11}$$

3.3.5 损失函数

为了估计模型的参数，我们需要指定一个目标函数来优化。为了更好地进行比较，我们指定了一个传统的损失函数，该函数在先前的工作中广泛用于模型训练。目标函数的目的是最小化预测值和实际标签的交叉熵，其定义为：

$$\lambda(y, \hat{y}) = -\ y\log\hat{y} - (1 - y)\log(1 - \hat{y}) \tag{3.12}$$

中国知网 https://www.cnki.net

其中，y_j和$\hat{y}_j$分别给出了用户点击的真实情况和估计的 CTR。此外，所有参数都通过标准反向传播算法进行了优化。

3.4. 实验

在本节中，我们介绍了实验的细节，包括数据集描述、基线方法、实验设置、评价指标和多个实验结果的分析。

3.4.1 数据集描述

我们使用三个公共数据集来评估我们的模型性能：Criteo、KDD12、MovieLens-1M，在数据预处理时将其随机分成 3 个部分，80%用于训练，10%用于验证，10%用于测试。

3.4.2 对比模型

LR：这是一种广泛使用的基线，并应用线性变换来建模所有特征的关系。

Wide&Deep：它联合训练线性模型和深度 MLP 模型以进行 CTR 预测。

Deep&Cross：DCN 被提出用于处理一组稀疏和密集特征，并与传统的深度 MLP 一起学习交叉高阶特征。

DeepFM：其将显式高阶交互模块与深度 MLP 模块和传统 FM 模块相结合，无需手动进行特征工程。

XDeepFM：使用压缩交互网络来枚举和压缩所有功能交互，以建立明确的交互顺序。

AutoInt(C)：AutoInt 模型利用带残差连接的多头自注意网络显式的进行交互特征的获取，能够自动学习高阶特征交叉。

3.4.3 参数设置

对于 CGAN 模型，我们使用 Adam 作为优化器，其学习率为 0.001。此外，MLP 层的尺寸为 32 和 8。多头自注意网络的头数和批次大小设置为 8 和 128。为了避免过度拟合和稳定训练，Drop Out Ratio 设置为 0.2，使用系数为 0.001 的 l2 正则化。

3.4.4 评价指标

AUC：AUC 在机器学习领域中是一种模型评估指标，其定义为：ROC 曲线下的面积(AUC)。它衡量的是 CTR 预测因子对于从样本集中随机选取 1 个正样本、1 个负样本进行预测，其中正样本预测值比负样本预测值高的概率。AUC 的数值越高，表示性能越好。

Logloss：对数损失，是基于概率的最重要的分类度量。它常用于评估分类器的概率输出，也是二分类问题中经常使用的评价标准，用来表示预测值与真实值之间的差距。在实验中，LogLoss 值越小预测模型性能越好。

中国知网 https://www.cnki.net

表 3.1：三个数据集上不同模型的性能对比

Tab.3.1 Comparing the performance of different models on the three data sets

	Criteo		KDD12		MovieLens-1M	
	AUC	Logloss	AUC	Logloss	AUC	Logloss
LR	0.7760	0.4758	0.7361	0.1684	0.7716	0.4424
Wide&Deep	0.7943	0.4690	0.7684	0.1597	0.7914	0.4251
Deep&Cross	0.7951	0.4552	0.7773	0.1586	0.7968	0.4266
DeepFM	0.7905	0.4468	0.7791	0.1572	0.8198	0.4153
XDeepFM	0.7952	0.4418	0.7824	0.1593	0.8367	0.4015
AutoInt	0.7988	0.4507	0.7783	0.1587	0.8456	0.3880
FWAI	0.8017	0.4481	0.7838	0.1546	0.8522	0.3861
CGAN	**0.8107**	**0.4461**	**0.7884**	**0.1542**	**0.8632**	**0.3791**
	+0.67%	-0.18%	+0.73%	-0.18%	+1.1%	-1.38%

其中，表 3.1 中最后一行的百分比是与最佳基线相比的相对改善值。

3.4.5 离线实验结果

表 3.1 显示了三个数据集上所有基线和 CGAN 的离线实验结果。从结果中，我们可以观察到：(1)在三个数据集中，二阶特征组合和高阶特征交互的模型在所有数据集上的表现都大大优于 LR，这表明单个特征在 CTR 预测中是不够的，挖掘高级特征交互对于模型至关重要；(2)与最佳基线方法相比，CGAN 对 AUC 的平均相对改善为 0.83%，对数损失的平均相对提高为 0.46%，这对 CTR 预测任务具有重要意义。(3)CGAN 在所有三个数据集上的所有度量都始终具有最佳性能，这是因为 GAN 中设计了一个全局交互模块来学习高阶交互并平衡多个特征的不同影响。其主要作用是显式地捕获原始特征和学习到的交互特征之间的关系，使得模型能够细粒度的学习高、低阶特征之间的交互信息。此外，我们还利用注意力机制来提取不同交互特征和原始嵌入特征的重要性，使得模型的准确性大大提高;(3)由于使用了相同的数据集，因此从实验结果可以看出 CGAN 算法比 FWAI 算法的准确率更高。

3.4.6 消融实验

在本节中，我们将讨论全局交互模块(GAN)对模型性能的影响。为了方便起见，我们用 NO-GAN 表示从模型中删除全局交互模块。实验结果如表 3.2 所示。从实验数据可以发现，当模型加入 GAN 后，预测效果有很大提升。这说明，GAN 层对于提升模型的性能是十分必要的，它主要作用是显式地捕获原始特征和生成的交互特征之间的关系，

中国知网 https://www.cnki.net

此外，还利用注意力机制来提取不同交互特征和原始嵌入特征的重要性，提高了模型的准确率。总体来说，本组实验验证了 GAN 的有效性。

表 3.2 GAN 对模型性能的提升

Tab.3.2 GAN improves model performance

Data Sets	Models	AUC	LogLoss
Criteo	CGAN	0.8107	0.4461
	NO-GAN	0.8064	0.4513
KDD12	CGAN	0.7884	0.1542
	NO-GAN	0.7725	0.1607
MovieLens-1M	CGAN	0.8632	0.3791
	NO-GAN	0.8517	0.3874

3.5 本章小结

在本章中，我们提出了一种基于全局注意网络与特征交互的点击率预测模型，以进一步提高 CTR 预测的性能。具体来说，设计了一个全局交互模块，来学习高阶交互并平衡多个特征的不同影响。其主要作用是显式地捕获原始特征(即低阶)和生成的交互特征(即高阶)之间的关系。此外，我们利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。在三个公共数据集上的实验结果证明了我们提出的方法的有效性。消融研究进一步说明 GAN 模块的有效性，这可能为未来的工作带来一些启发。

中国知网 https://www.cnki.net

第四章 基于特征交互的点击率预测原型系统的设计与实现

本章主要介绍了基于特征交互的点击率预测原型系统，该系统主要是利用第二章与第三章介绍的点击率预测算法，完成广告点击率预测任务。然后详细介绍了各模块的功能，并对其实验结果进行分析和可视化，最后证明了系统的有效性。

4.1 引言

近年来，随着大数据时代的到来，人们制造的信息数据与日剧增。但海量数据在帮助我们了解世界的同时也提出了一个全新的难题——如何从数据汪洋之中寻找自己所需的东西。目前来看，推荐系统[63-65]是解决上述“信息过载”问题最好的方法。而点击率预测是推荐系统中一个很重要的研究方向。

投放广告获得收益是互联网公司收入的重要来源之一，越来越多的企业开始重视这个领域。网络广告的投放形式丰富多彩。对于平台来说，准确的预测不仅可以改善用户体验，还可以提高服务提供商的利润。对于投放广告的商家来说，广告代表着自己的品牌形象，而且广告的质量决定着它会带来多少实际营销收益，对于用户来说，如果平台推荐的广告和自己的实际需求相符合，那么用户就会越来越喜欢使用平台，这样平台推荐的广告被用户接受的概率也会提升。

广告点击率预测(CTR)指的是在特定情形下，系统根据推荐算法预测某个广告被用户点击的概率大小。在网络广告中，点击率可以准确的反应出广告被用户接受的概率，进而构造出用户画像。互联网公司经常采用机器学习[66]算法等去预测点击率，进而根据预测结果对广告候选集进行排序，使将要展示到用户面前的广告更加符合其个人偏好以及行为习惯，提高用户对平台的依赖程度。

广告点击率预测对于平台、广告主和用户三方都十分重要。广告点击率预测能够让平台更加人性化的推荐广告。在用户注册和使用平台时，会产生大量的个人日志信息，通过对这些特征进行分析能够得出用户的行为偏好，从而向其推荐符合他自己广告内容，进而提高广告的点击概率。使平台实现更高的收入，并帮助广告主精准锁定目标人群，提高广告带来的收益。基于这种目的下，各大互联网公司纷纷开始重视并研究如何提高广告的点击率。

本章根据第二章和第三章所提出的点击率预测算法，设计了一个基于特征交互的广告点击率预测原型系统。该系统利用收集到的用户特征来计算广告被点击的概率，从而帮助平台为每一位用户推荐最符合其偏好的广告，精准的推荐可以使用户越来越依赖平台，成为平台的忠实用户。

中国知网 https://www.cnki.net

4.2 系统可行性分析

系统可行性分析指的是从多个不同的角度对系统是否可行进行分析研究。目的是用最小的成本来确定某个系统是否可以开发。想达到这个目的，就必须从多个不同角度去分析该系统的利弊，以此决定系统的任务和目标是否可以现实、系统开发完成后所带来的经济效益能否能达到之前的预期。我们从社会效益可行性、技术与安全可行性、功能可行性三个方面进行分析。

社会效益可行性：近年来，随着大数据时代的到来，网络广告发展迅速。越来越多的企业开始重视这个领域。网络广告的投放形式丰富多彩。对于平台来说，准确的预测不仅可以改善用户体验，还可以提高服务提供商的利润。对于投放广告的商家来说，广告代表着自己的品牌形象，而且广告的质量决定着它会带来多少实际营销收益，对于用户来说，如果平台推荐的广告和自己的实际需求相符合，那么用户就会越来越喜欢使用平台，这样平台推荐的广告被用户接受的概率也会提升。而该系统使用第二章提到的FWAI 算法可以精确的计算点击率，而且开发了很多不同功能模块。能够满足平台、商家、用户的不同需求。因此，是十分可行的。

技术与安全可行性：该系统的开发使用的是 Python 编程语言，该语言有很强的面向对象特性，而且有着大量可调用的库，使得开发的效率更高。另外，我们在设计时考虑到了用户的隐私安全问题。设置了信息加密技术、防火墙、身份认证等技术来保证用户的信息安全。因此，该系统从技术和安全性两方面考虑是可行的

功能可行性，在进行点击率预测时，一个用户的信息越多、越丰富，则预测的结果更准确。在该系统中我们开发了六个功能模块，每个模块下面又包含了不同的功能，这样的设计不仅可以快速、准确的构造用户图像，也可以满足用户的各种需求。所以，该系统在功能需求上是可行的。

4.3 系统设计

本节主要根据前一节系统可行性分析的结果进行系统设计，运用高效、科学的方法，设计出可以满足上述需求的系统。先对系统总体功能进行简单分析，然后对每一个功能模块进行详细介绍。

4.3.1 系统总体功能图

基于特征交互的点击率预测系统分为六个模块，分别为是访客分析、访问习惯分析、网站受访页面、用户定义分群、全网汇总信息、用户信息六个模块。系统功能模块图如图 4.1 所示。

中国知网 https://www.cnki.net

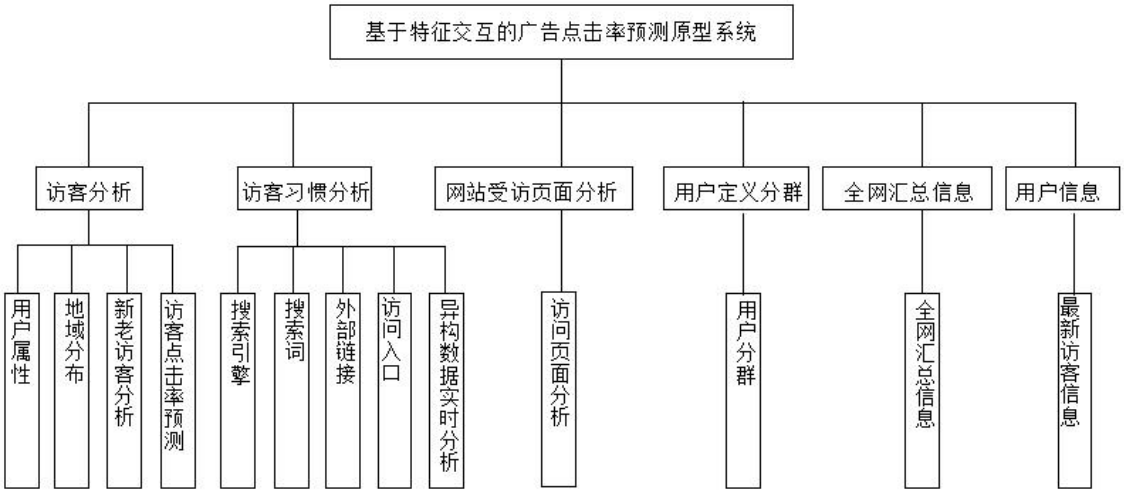

图 4.1 系统总体功能图

Fig.4.1 Overall system function diagram

4.3.2 系统页面设计

实验系统总体包括六大功能模块，分别如下：

(1)访客分析：此模块为访客分析，主要功能有：用户属性、地域分布。详情如图 4.2 所示：

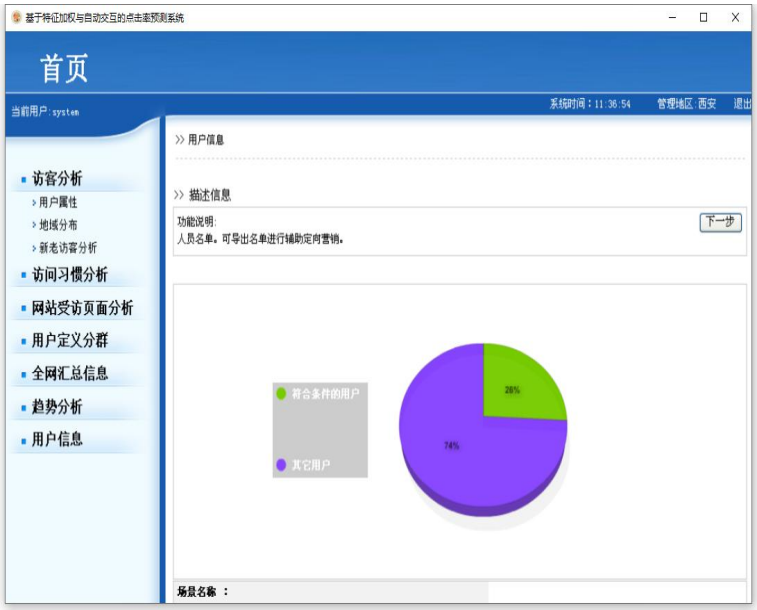

图 4.2 访客分析

Fig.4.2 Visitor analysis

进入用户属性页面后，我们可以点击不同的功能按钮，进行相应的操作。这个界面主要包括统计概述、在线状况、时段流量、访问用户、访问来源、页面分析、导出数据、访问统计、统计概述等信息。

中国知网 https://www.cnki.net

进入地域分布页面后，我们可以点击不同的功能按钮，进行相应的操作。如：常规信息、远程监控、控制设置、地域状态、安全设置。该模块主要是统计用户的地域分布。

点击访客分析功能里的访客点击率预测子功能，进入访客点击率预测页面。进入访客点击率预测页面后，界面上部分为导航栏，一共有 7 个子功能，分别是：访问简报、在线状况、时段分析、访问用户、访问来源、搜索引擎、页面分析。我们可以点击不同的功能按钮查看信息。这些不同类型的信息就是不同的特征。在此系统中我们使用第二章介绍的 FWAI 算法对特征进行加权计算，最后进行预测。

(2)访问习惯分析：此模块用于分析用户的访问习惯，主要功能有：搜索引擎、搜索词、外部链接、访问入口、异构数据实时分析。如图 4.3 所示：

图 4.3 搜索引擎界面

Fig.4.3 Search engine interface

进入搜索引擎页面后，我们可以点击不同的功能按钮，进行相应的操作。主要功能有：用户管理、数据类型、文件采集、参数配置、分类管理、插件管理、引擎管理、集群状态、引索字段、企业搜索等。

点击访问搜索词子功能，进入搜索词页面。进入搜索词页面后，我们可以输入关键字，进行搜索。可以看到每一天信息的访客数、IP 数、浏览量、平均发访问时长、调出率等详细信息。

点击外部链接子功能，进入外部链接页面。进入外部链接页面后，我们可以点击不同的功能按钮，进行过滤、确认、总计等各种相应的操作。

点击访问习惯分析功能里的的访问入口子功能，进入访问入口页面。详情如图所示：

中国知网 https://www.cnki.net

在这里我们可以看到指标概览、流量分析、新房客分析、吸引力分析、转化分析等不同按钮。通过对不同数据的分析，我们可以更好的去进行预测。

系统用户在系统的相关命令下进入到异构数据实时分析界面，并通过系统来了解到相关信息，用户可以根据自己的需要在系统上获得异构数据实时分析的相关操作流程，并按照系统的提示来设置相关功能，从而能较快地完成其有关的操作需求。

(3)网站受访页面分析：点击系统的网站受访页面分析功能，进入网站受访页面分析页面。进入该页面后，我们可以点击不同的功能按钮，进行相应的操作，如图 4.4 所示。详细功能操作包括：指标概览、页面价值分析、入口页分析、退出页分析、自定义指标、页面 URL、浏览量、贡献下游浏览量、平均停留时长、总计。

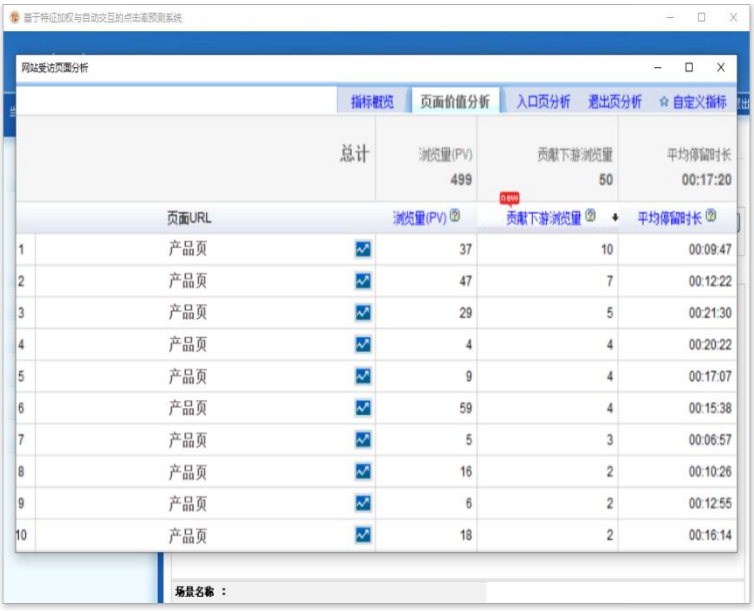

图 4.4 网站受访页面分析

Fig.4.4 Website interview page analysis

(4)用户定义分群：点击系统的用户定义分功能，进入用户定义分群页面。该模块主要用来分析和存储所有用户行为信息，根据不同的划分标准，将用户分为不同的群体。目的是当为某个用户推荐一款产品时，可以优先推荐和他具有类似习惯的用户群体所浏览过的产品。如图 4.5 所示：

中国知网 https://www.cnki.net

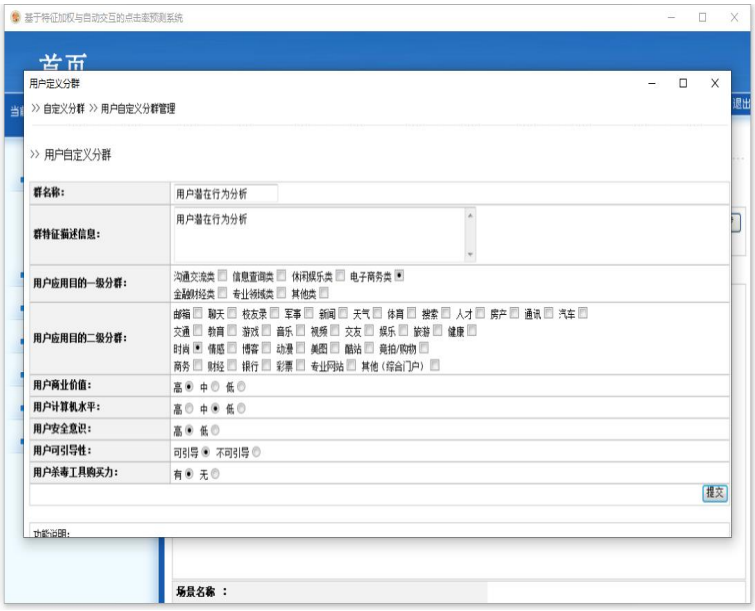

图 4.5 用户定义分群

Fig.4.5 User-defined clustering

（5）全网汇总信息：点击系统的全网汇总信息功能，进入全网汇总信息页面。进入该页面后，我们可以点击不同的功能按钮查看想知道的信息。如：全网热门网站(表示点击率排名最高的前网站名)；点击次数(查看网站被点击次数)；全网占例(查看全网占例)；全网排名(查看全网排名)。如图 4.6 所示：

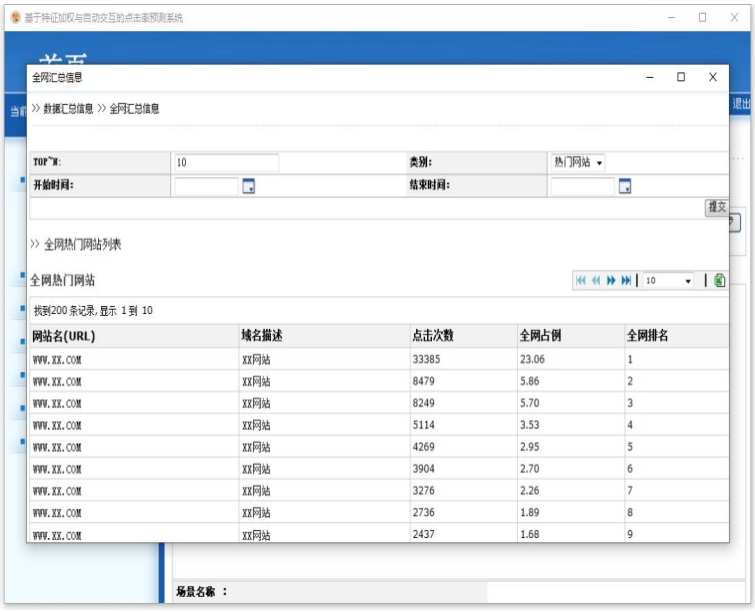

图 4.6 全网汇总信息

Fig.4.6 Network summary information

中国知网 https://www.cnki.net

（6）用户信息：该模块用来查看访客的信息。主要功能是最新访客。点击用户信息功能的最新访客子功能，进入最新访客页面后，我们可以看到点击不同的数据，如：地域、入口页面、查询、最后停留页面、最后响应操作、查看详情。该模块主要用来查看访客的信息。如图 4.7 所示：

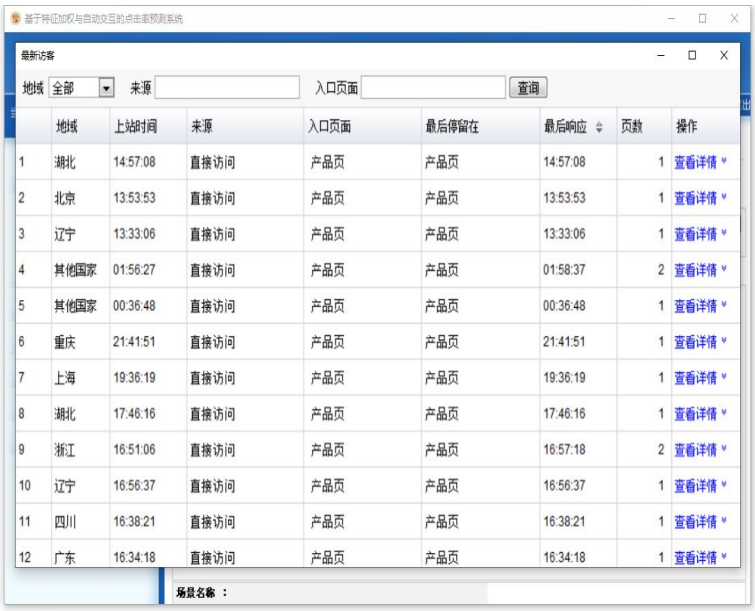

图 4.7 用户信息

Fig.4.7 User informationr

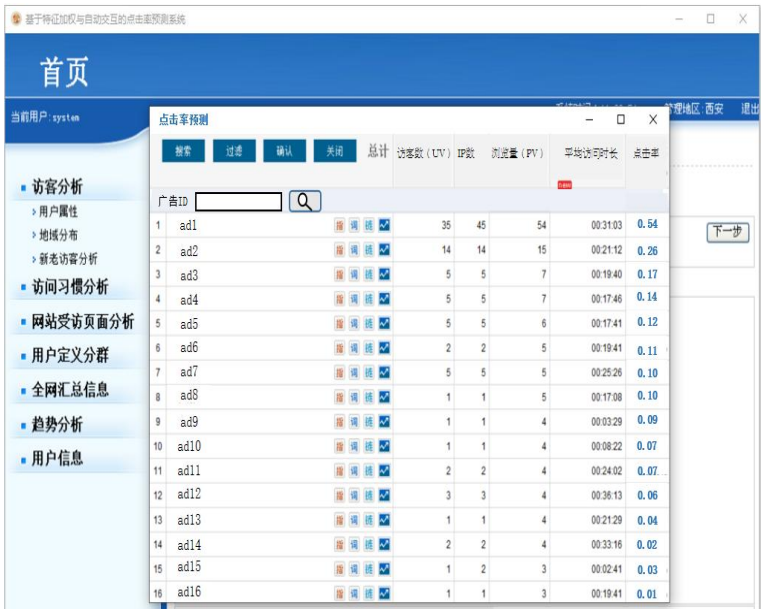

图 4.8 广告点击率预测结果图

Fig.4.8 Advertisement click rate forecast results graph

中国知网 https://www.cnki.net

4.3.3 广告点击率预测模块结果展示

此模块属于该系统最重要的子模块，主要通过收集用户的各种信息来进行预测，这些不同类型的信息就是不同的特征。首先，我们引入 ECANet 模块对特征进行加权计算；然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互；接着将两者相结合进行预测，得到每个候选广告的点击率值。最后，根据概率大小对候选集里面的广告进行降序排列，然后根据提前设置的广告展示个数 n 选取排在表中前 n 个的广告并将其推荐给目标用户。界面如图 4.8 所示：

4.4 系统开发环境

开发的硬件环境：显卡型号；集成显卡；硬盘容量：512GB SSD；声卡；集成声卡；CPU 速度：3.1GHz

运行的硬件环境：处理器 4.4GHz；硬盘：240-256GB；显存：2GB；速度：DDR4

开发该软件的操作系统：Windows 8.1 Professional32 位操作系统

软件开发环境 / 开发工具：PyCharm

该软件的运行平台 / 操作系统：操作系统:windows7 以上

软件运行支撑环境 / 支持软件：网络协议:TCP/IP 协议；WindowsServer2022+IIS6

深度学习框架：TensorFlow 2.0

数据库：MySQL 5.7

4.5 本章小结

本章介绍了具体设计与实现广告点击率预测系统的过程。分为三个部分，首先在需求分析部分，本章通过社会效益可行性、技术与安全可行性、功能可行性三个方面进行分析，得到一个系统所需要满足的基本需求。然后介绍了系统总体功能图，该系统主要分为六个模块，分别为是访客分析、访问习惯分析、网站受访页面、用户定义分群、全网汇总信息、用户信息六个模块。在这其中，访客分析、全网汇总信息、是系统中比较重要的模块，我们对所有的模块都进行了详细介绍。然后是点击率预测模型的结果部型的结果部分，最后我们对开发系统所需要的硬件环境和软件环境进行了简单说明。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 总结

近年来，点击率预测任务的研究成为了推荐系统领域的热门话题之一。在点击率预测任务中模型的输入数据数量极多而且特征维度很高，在进行特征选择时容易存在信息干扰或丢失，且不同的交互方式也会影响预测性能。鉴于此，本文主要针对点击率预测任务中的特征选择和特征交互方面进行了深入研究，其主要研究内容包括：

(1)提出了一种基于特征加权与自动交互的预测模型，用于学习原始特征权重并进行自动交互。主要从两个方面进行改进：首先，通过引入 ECANet 模块提出一种不降维的特征加权方法，有效解决了以往的加权算法会导致信息丢失问题。然后分别用多头自注意网络和深度神经网络(DNN)去自动学习显式和隐式的特征交互，最后将两者相结合进行预测。使得模型不但具备良好的解释性，而且能够同时以显式和隐式的方式自动学习任意低阶和高阶的特征交互。

(2)提出了一种基于全局注意网络的点击率预测模型。该算法设计了一个全局交互模块(GAN)来学习高阶交互并平衡多个特征的不同影响；并且利用注意力机制来提取不同交互特征和原始嵌入特征的重要性。有效解决了现有模型忽略低阶和高阶特征之间相互作用的重要性等问题。最后，通过在三个数据集的离线实验结果，证明了我们提出的方法的有效性。

(3)在 win7 开发环境下，以 python 为开发语言，设计了一个基于特征交互的点击率预测原型系统。用于广告点击率预测，然后详细介绍系统的功能页面和开发该系统所用到的技术，该系统利用收集到的用户特征来计算候选广告的点击率大小，从而更精准的对用户投放符合其偏好的广告。

5.2 展望

本文主要对基于特征交互的点击率预测算法进行研究，但由于时间和实验硬件条件所限，本论文研究并不充分，仍然有部分问题有待进行深入研究。

首先，本文提出的 FWAI 算法由于实验条件的限制没有进行在线测试。而在线 A/B 测试可以通过用户行为结果数据不断对其用户体验进行仔细更改，进而更好地了解为什么修改的某些元素会影响用户行为。在未来的工作中，我们希望可以在真实的生产环境中进行在线 A/B 测试，从而不断优化我们的算法。

其次，点击率预测在实际使用时需要在极短的时间内处理大量数据，因此时间复杂度的高低决定着算法是否可行。由于我们提出的两个算法都是基于深度学习的，所以未

中国知网 https://www.cnki.net

来我们的研究应该着眼于降低时间花费上。而并行化方法可以有效解决面对规模庞大的数据量时处理能力低效的问题。所以，可以考虑通过并行化结构来解决算法的时间消耗问题。

中国知网 https://www.cnki.net

参 考 文 献

[1] H Brendan McMahan, Gary Holt, David Sculley, Michael Young, Dietmar Ebner, Julian Grady, Lan Nie, Todd Phillips, Eugene Davydov, Daniel Golovin, et al. Ad click prediction: a view from the trenches[C].In Proceedings of SIGKDD . ACM, 2013:1222–1230.

[2] Chang Y W,Hsieh C J,Chang K W,et al.Training and testing low-degree polynomial data mappings via linear SVM[J].Journal of Machine Learning Research,2010, 11 (11):1471-1490.

[3] Steffen Rendle. Factorization machines[C].In Data Mining (ICDM), 2010 IEEE 10th International Conference on. IEEE,2010: 995–1000.

[4] Yuchin Juan, Damien Lefortier, and Olivier Chapelle. Field-aware factorization machines in a real-world online advertising system[C].In Proceedings of the 26th International Conference on World Wide Web Companion. International World Wide Web Conferences Steering Committee,2017: 680–688.

[5] Zekun Li, Zeyu Cui, Shu Wu, Xiaoyu Zhang, and Liang Wang. 2019. Fi-GNN:Modeling Feature Interactions via Graph Neural Networks for CTR Prediction[C].In Proceedings of the 28th International Conference on Information and KnowledgeManagement (CIKM). 539–548.

[6] Bin Liu, Chenxu Zhu, Guilin Li, Weinan Zhang, Jincai Lai, Ruiming Tang, Xiuqiang He, Zhenguo Li, and Yong Yu. 2020. AutoFIS: Automatic Feature Interaction Selection in Factorization Models for Click-Through Rate Prediction[C]. In Proceedings of the 26th International Conference on Knowledge Discovery and Data Mining (SIGKDD). ACM, 2636–2645.

[7] Yanru Qu, Han Cai, Kan Ren, Weinan Zhang, Yong Yu, Ying Wen, and Jun Wang. Product-based neural networks for user response prediction[C].In Data Mining(ICDM), 2016 IEEE 16th International Conference on. IEEE, 2016:1149–1154.

[8] Xiangnan He and Tat-Seng Chua.Neural factorization machines for sparse predictive analyticsIn[C].In Proceedings of SIGIR.ACM. 2017:355–364.

[9] Weinan Zhang, Tianming Du, and Jun Wang. Deep learning over multi-field categorical data[C].In European conference on information retrieval.Springer,2016:45–57.

中国知网 https://www.cnki.net

[10] Heng-Tze Cheng, Levent Koc, Jeremiah Harmsen, Tal Shaked, Tushar Chandra,Hrishi Aradhye, Glen Anderson, Greg Corrado, Wei Chai, Mustafa Ispir, et al. Wide & deep learning for recommender systems[C].In Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. ACM,2016: 7–10.

[11] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He.DeepFM: A Factorization-machine Based Neural Network for CTR Prediction[C].In Proceedings of the 26th International Joint Conference on Artificial Intelligence.AAAI Press,2017:1725–1731.

[12] Jianxun Lian, Xiaohuan Zhou, Fuzheng Zhang, Zhongxia Chen, Xing Xie, and Guangzhong Sun. xDeepFM: Combining Explicit and Implicit Feature Interactions for Recommender Systems[C].In Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2018:1754–1763.

[13] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need[C].In Advances in Neural Information Processing Systems, 2017:6000–6010.

[14] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks[C]. In 2018 IEEE Conference on Computer Vision and Pattern Recognition, CVPR , 2018:7132–7141.

[15] Zhang T Ye, W Yang, B Zhang, L Ren, X Liu, D Sun, J Zhang S Zhang H & Zhao W. Frequency-Aware Contrastive Learning for Neural Machine Translation. Proceedings of the AAAI Conference on Artificial Intelligence,2022,36(10):11712-11720.

[16] Wang, D Wei, H Zhang, Z Huang, S Xie, J, & Chen, J. Non-parametric Online Learning from Human Feedback for Neural Machine Translation. Proceedings of the AAAI Conference on Artificial Intelligence, 2022,36(10):11431-11439.

[17] Badrinarayanan V, Kendall A, Cipolla R. SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017:1-1.

[18] Chen L C , Papandreou G , Kokkinos I , et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40

中国知网 https://www.cnki.net

(4):834-848. Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio.Neural machine translation by jointly learning to align and translate[C].In International Conference on Learning Representations,2015:1409.0473.

[19]Dabre R , Chu C , Kunchukuttan A. A Survey of Multilingual Neural Machine Translation[J]. ACM Computing Surveys, 2020:53(5):1-38.

[20]Jun Xiao, Hao Ye, Xiangnan He, Hanwang Zhang, Fei Wu, and Tat-Seng Chua. Attentional factorization machines: learning the weight of feature interactions via attention networks[C].In Proceedings of the 26th International Joint Conference on Artificial Intelligence. AAAI Press, 2017:3119–3125.

[21]Weiping Song, Chence Shi, Zhiping Xiao, Zhijian Duan, Yewen Xu, Ming Zhang, and Jian Tang. Autoint: Automatic feature interaction learning via self-attentive neural networks.[C].In CIKM, 2019:1161–1170.

[22]Zeyu Li, Wei Cheng, Yang Chen, Haifeng Chen, and Wei Wang. Interpretable Click-Through Rate Prediction through Hierarchical Attention[C]. In Proceedings of the 13th International Conference on Web Search and Data Mining (WSDM '20). Association for Computing Machinery,2020:313–321.

[23]Q. Wang, B. Wu, P. Zhu, P. Li, W. Zuo and Q. Hu.ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C].2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR),2020:11531-11539.

[24]Qiang Liu, Feng Yu, Shu Wu, and Liang Wang. A convolutional click prediction model[C]. In Proceedings of the 24th ACM International on Conference on Information and Knowledge Management. ACM, 2015:1743–1746.

[25]R. Li, Z. Wu, J. Jia, S. Zhao and H. Meng, Dilated Residual Network with Multi-head Self-attention for Speech Emotion Recognition[C]. ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2019: 6675-6679.

[26]Yanru Qu, Han Cai, Kan Ren, Weinan Zhang, Yong Yu, Ying Wen, and Jun Wang. Product-based neural networks for user response prediction[C]. In 2016 IEEE 16th International Conference on Data Mining (ICDM). IEEE, 2016:1149–1154.

[27]Huang T, Zhang Z, Zhang J. FiBiNET: combining feature importance and bilinear

中国知网 https://www.cnki.net

feature interaction for click-through rate prediction[C]//Proceedings of the 13th AC M Conference on Recommender Systems.Copenhagen,2019: 169-177.

[28] Xinran He, Junfeng Pan, Ou Jin, Tianbing Xu, Bo Liu, Tao Xu, Yanxin Shi, Anto ine Atallah, Ralf Herbrich, Stuart Bowers, et al.Practical lessons from predicting cl icks on ads at facebook[C].In Proceedings of the Eighth International Workshop o n Data Mining for Online Advertising. ACM,2014: 1–9.

[29] Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix factorization techniques for recommender systems[J].Computer,2009:30–37.

[30] Thore Graepel, Joaquin Quinonero Candela, Thomas Borchert, and Ralf Herbrich. Web-scale Bayesian click-through rate prediction for sponsored search advertising i n Microsoft's bing search engine [C].In Proceedings of ICML,2010:13–20.

[31] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zh u, and Kun Gai. Deep Interest Evolution Network for Click-Through Rate Predict ion[C]. In AAAI, 2019:5941–5948.

[32] Gujing Han, Min Zhang, Wenzhao Wu, Min He, Kaipei Liu, Liang Qin, Xia Liu. Improved U-Net based insulator image segmentation method based on attention me chanisms[J].Energy Reports,2021: 210–217.

[33] Gera D , Balasubramanian S . Landmark Guidance Independent Spatio-Channel A ttention and Complementary Context Information based Facial Expression Recogniti on[J]. Pattern Recognition Letters, 2021:58–66.

[34] Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C].Proce edings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 3146-3154.

[35] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Pr oceedings of the European conference on computer vision (ECCV). 2018: 3-19.

[36] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun.Deep residual learning for image recognition[C].In Proceedings of the IEEE conference on computer visio n and pattern recognition, 2016:770–778.

[37] Sainbayar Sukhbaatar, Jason Weston, Rob Fergus, et al.End-to-end memory networ ks[C].In Advances in neural information processing systems. 2015:2440–2448.

[38] Alexander M. Rush, Sumit Chopra, and Jason Weston. 2015. A Neural Attention

中国知网 https://www.cnki.net

Model for Abstractive Sentence Summarizationn [C]. In Proceedings of EMNLP.ACM.2015:379–389.

[39] Xiangnan He, Zhankui He, Jingkuan Song, Zhenguang Liu, Yu-Gang Jiang, and Tat-Seng Chua. 2018. NAIS: Neural attentive item similarity model for recommendation[J].IEEE Transactions on Knowledge and Data Engineering.2018:2354–2366.

[40] Weiping Song, Zhiping Xiao, Yifan Wang, Laurent Charlin, Ming Zhang, and Jian Tang. Session-based Social Recommendation via Dynamic Graph Attention Networks[C]. Proceedings of WSDM. ACM.2019: 555–563.

[41] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need[C].In Advances in Neural Information Processing Systems, 2017:6000–6010.

[42] Pecoraro R, Basile V, Bono V. Local multi-head channel self-attention for facial expression recognition[J]. Information, 2022, 13(9): 419.

[43] R. Li, Z. Wu, J. Jia, S. Zhao and H. Meng, Dilated Residual Network with Multi-head Self-attention for Speech Emotion Recognition[C]. ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2019: 6675-6679.

[44] Lobo J M . AUC: a misleading measure of the performance of predictive distribution models[J]. Global Ecology & Biogeography, 2010:17(2):145-151.

[45] Vovk V.The fundamental nature of the log loss function[M].Fields of Logic and Computation II. Springer, Cham,2015:307-318.

[46] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang.Deep & Cross Network for Ad Click Predictions[C].In Proceedings of the KDD. ACM.2017:1–7.

[47] Mathieu Blondel, Akinori Fujino, Naonori Ueda, and Masakazu Ishihata.Higher-order factorization machines[C].In Advances in Neural Information Processing Systems. 2016:3351–3359.

[48] Zhou, G., Mou, N., Fan, Y., Pi, Q., Bian, W., Zhou, C., Zhu, X., & Gai, K. Deep Interest Evolution Network for Click-Through Rate Prediction[C]. Proceedings of the AAAI Conference on Artificial Intelligence,2019:33(01), 5941-5948.

[49] H. Brendan McMahan, Gary Holt, D. Sculley, Michael Young, Dietmar Ebner, Juli

中国知网 https://www.cnki.net

an Grady, Lan Nie, Todd Phillips, Eugene Davydov, Daniel Golovin, Sharat Chikkerur, Dan Liu, Martin Wattenberg, Arnar Mar Hrafnkelsson, Tom Boulos, and Jeremy Kubica. Ad click prediction: a view from the trenches[C]. In Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining (KDD '13). Association for Computing Machinery,2013:1222–1230.

[50]Zhu C, Chen B ,Zhang W , et al. AIM: Automatic Interaction Machine for Click-Through Rate Prediction[J].IEEE Transactions on Knowledge and Data Engineering, 2021:3389 - 3403.

[51]Rao, HaidiShi, XianzhangRodrigue, Ahoussou KouassiFeng, JuanjuanXia, Yingchun Elhoseny, MohamedYuan, XiaohuiGu, Lichuan. Feature selection based on artificial bee colony and gradient boosting decision tree[J]. Applied Soft Computing, 2019: 74.634-642

[52]Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition[C]. In Proceedings of the IEEE conference on computer vision and pattern recognition. 2016:770–778.

[53]Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks[C]. In Advances in neural information processing systems. 2012:1097–1105.

[54]Keysers D , Deselaers T , Gollan C , et al. Deformation Models for Image Recognition[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2007: 29(8):1422-1435.

[55]Zhu Y , Zhuang F , Wang J , et al. Deep Subdomain Adaptation Network for Image Classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020: PP(99):1-10.

[56]Guo W , Su R , Tan R , et al. Dual Graph enhanced Embedding Neural Network for CTRPrediction[J]. In Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining (KDD '21), 2021:496–504.

[57]Feng Li, Zhenrui Chen, Pengjie Wang, Yi Ren, Di Zhang, and Xiaoyu Zhu. Graph Intention Network for Click-through Rate Prediction in Sponsored Search[C]. In Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR'19), 2019:961–964.

中国知网 https://www.cnki.net

[58]Huang Z， Tao M， Zhang B . Deep User Match Network for Click-Through Rate Prediction[C]. SIGIR '21: The 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2021,11:1890–1894

[59]Lyu, Z., Dong, Y., Huo, C., & Ren, W. Deep Match to Rank Model for Personalized Click-Through Rate Prediction[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020,34(01):156-163.

[60]Jiarui Qin, Weinan Zhang, Xin Wu, Jiarui Jin, Yuchen Fang, and Yong Yu. User Behavior Retrieval for Click-Through Rate Prediction[C]. In Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval ,2020: 2347–2356.

[61]Yang Sun, Junwei Pan, Alex Zhang, and Aaron Flores. FM2: Field-matrixed Factorization Machines for Recommender Systems[C]. In Proceedings of the Web Conference 2021 (WWW '21),2021: 2828–2837.

[62]Jiancan Wu, Xiang Wang, Fuli Feng, Xiangnan He, Liang Chen, Jianxun Lian, and Xing Xie.Self-supervised Graph Learning for Recommendation[C]. In Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '21), 2021:726–735.

[63]蒋兴渝,黄贤英,陈雨晶,徐福.特征重要性动态提取的广告点击率预测模型[J].小型微型计算机系统, 2022(005):043.

[64]陈锦霞. 基于自注意力机制的混合推荐模型的研究与应用[D]. 上海:上海交通大学, 2019.

[65]Xiangnan He, Lizi Liao, Hanwang Zhang, Liqiang Nie, Xia Hu, and Tat-Seng Chua. Neural Collaborative Filtering[C]. In Proceedings of the 26th International Conference on World Wide Web (WWW '17). International World Wide Web Conferences Steering Committee, Republic and Canton of Geneva, CHE, 2017:173–182.

中国知网 https://www.cnki.net